4 - The Multivariate Gaussian Distribution

Characterizing Properties · Mahalanobis Distance ·
Conditional Distributions · Regression Fallacy

Applied Statistics

Unat Teksen

March 12, 2026

1 The Setup — Why the Gaussian?

- **Goal:** Model a p-dimensional random vector $\underline{x} \in \mathbb{R}^p$ with a joint probability distribution.
- **Why Gaussian?**
  - Many natural phenomena are approximately Gaussian.
  - Closed under linear transformations — a key mathematical convenience.
  - Central Limit Theorem: sample means converge to Gaussian.
  - Fully characterized by only two parameters: $\underline{\mu}$ and Σ.
- **Parameters:**
  - $\underline{\mu} \in \mathbb{R}^p$ — mean vector
  - $\Sigma \in \mathbb{R}^{p \times p}$ — covariance matrix, positive definite (p.d.)

2 Definition of the Multivariate Gaussian

Definition. $\underline{x} \sim \mathcal{N}_p(\underline{\mu}, \Sigma)$ if for every Borel set $B \subseteq \mathbb{R}^p$:

$$\mathbb{P}[\underline{x} \in B] = \int_B f_{\underline{x}}(t)\, dt \tag{1}$$

where the density is:

$$f_{\underline{x}}(t) = \frac{1}{\sqrt{(2\pi)^p |\Sigma|}} \exp\left(-\frac{1}{2}(t - \underline{\mu})^\top \Sigma^{-1} (t - \underline{\mu}) \right), \quad t \in \mathbb{R}^p \tag{2}$$

- **Remarks:**
  - $E[\underline{x}] = \underline{\mu}$
  - $\mathrm{Cov}(\underline{x}) = \Sigma$

- **Contours — geometric intuition:**
  - Level sets of $f_{\underline{x}}$ satisfy:

$$f_{\underline{x}}(t) = c \iff (t - \underline{\mu})^\top \Sigma^{-1} (t - \underline{\mu}) = \text{const} \tag{3}$$

  - This defines an **ellipsoid** in $\mathbb{R}^p$ centered at $\underline{\mu}$.
  - The **eigenvectors** of Σ give the axes of the ellipsoid.
  - The **square roots of eigenvalues** $\sqrt{\lambda_i}$ give the half-lengths.
  - If $\Sigma = I$: contours are perfect **spheres**.
  - Larger $\lambda_i \Rightarrow$ ellipsoid stretched along eigenvector $\underline{e}_i$.
- **Eigendecomposition of Σ:**

$$\Sigma = \sum_i \lambda_i \underline{e}_i \underline{e}_i^\top, \quad \Sigma^{1/2} = \sum_i \sqrt{\lambda_i}\, \underline{e}_i \underline{e}_i^\top, \quad \Sigma^{-1/2} = \sum_i \frac{1}{\sqrt{\lambda_i}} \underline{e}_i \underline{e}_i^\top \tag{4}$$

3 Characterizing Theorem and Corollary

Theorem (Characterization).

$$\underline{x} \sim \mathcal{N}_p(\underline{\mu}, \Sigma) \iff \forall\, \underline{a} \in \mathbb{R}^p, \quad \underline{a}^\top \underline{x} \sim \mathcal{N}_1\big(\underline{a}^\top \underline{\mu},\ \underline{a}^\top \Sigma\, \underline{a}\big) \tag{5}$$

- **Why powerful?** Reduces the p-dimensional problem to 1D — every projection is Gaussian.
- **Proof strategy:** All subsequent proofs use this: to show $Y \sim \mathcal{N}_q$, show $\underline{a}^\top Y \sim \mathcal{N}_1$ for all $\underline{a}$.

Corollary (Marginals). If $\underline{x} \sim \mathcal{N}_p(\underline{\mu}, \Sigma)$, then each component:

$$x_i \sim \mathcal{N}_1(\mu_i,\ \sigma_{ii}), \quad i = 1, \ldots, p \tag{6}$$

where μ_i is the i-th entry of $\underline{\mu}$ and σ_{ii} is the (i, i) entry of Σ.

- **Proof:** Take $\underline{a} = (0, \ldots, 0, 1, 0, \ldots, 0)^\top$ with 1 at position i.

Warning — the converse FAILS. Gaussian marginals do **not** imply a joint Gaussian distribution. A distribution can have all Gaussian marginals, zero correlations, and still not be jointly Gaussian (e.g. pie-slice shaped density — circular in some quadrants, zero elsewhere). The $\Leftarrow$ arrow is **crossed out** in the notes for this reason.

4 Linear Transformations Preserve Gaussianity

Proposition. If $\underline{x} \sim \mathcal{N}_p(\underline{\mu}, \Sigma)$ and A is a $q \times p$ matrix, then:

$$A\underline{x} \sim \mathcal{N}_q\big(A\underline{\mu},\ A\Sigma A^\top\big) \tag{7}$$

- **Proof sketch:** For any $\underline{a} \in \mathbb{R}^q$:

$$\underline{a}^\top(A\underline{x}) = (A^\top \underline{a})^\top \underline{x} \xrightarrow{\text{Theorem}} \mathcal{N}_1\big(\underline{a}^\top A\underline{\mu},\ \underline{a}^\top A\Sigma A^\top \underline{a}\big)$$

- Apply the Theorem again $\Rightarrow A\underline{x} \sim \mathcal{N}_q(A\underline{\mu}, A\Sigma A^\top)$.
- **Special cases:**
  - **Translation:** $\underline{x} + \underline{d} \sim \mathcal{N}_p(\underline{\mu} + \underline{d}, \Sigma)$ for any $\underline{d} \in \mathbb{R}^p$.
  - **Marginals:** $A = [I_q \mid \mathbf{0}]$ gives $\underline{x}_1 \sim \mathcal{N}_q(\underline{\mu}_1, \Sigma_{11})$.
  - **Standardization:** $A = \Sigma^{-1/2}$ gives $\Sigma^{-1/2}(\underline{x} - \underline{\mu}) \sim \mathcal{N}_p(\underline{0}, I)$.

Constructing Any Gaussian from i.i.d. Standard Normals

- Let $z_1, \ldots, z_p \overset{\text{iid}}{\sim} \mathcal{N}_1(0,1)$, stacked as $\underline{z} = (z_1, \ldots, z_p)^\top$.
- Then $\underline{z} \sim \mathcal{N}_p(\underline{0}, I)$ (joint density factors into product of univariate densities).
- For any $\underline{\mu} \in \mathbb{R}^p$ and positive definite Σ:

$$\underline{x} = \Sigma^{1/2}\underline{z} + \underline{\mu} \sim \mathcal{N}_p(\underline{\mu}, \Sigma) \tag{8}$$

- **Intuition:** Every multivariate Gaussian is an affinely transformed sphere of i.i.d. standard normals. $\Sigma^{1/2}$ stretches and rotates the sphere into an ellipsoid.

5 Mahalanobis Distance and the Chi-squared Distribution

Definition

For $\underline{x} \sim \mathcal{N}_p(\underline{\mu}, \Sigma)$, the **squared Mahalanobis distance** is:

$$W = (\underline{x} - \underline{\mu})^\top \Sigma^{-1} (\underline{x} - \underline{\mu}) \tag{9}$$

- Σ^{-1} corrects for different variances and correlations across directions.
- When $\Sigma = I$: $W = \|\underline{x} - \underline{\mu}\|^2$ (ordinary squared Euclidean distance).
- **Intuition:** Σ^{-1} transforms the ellipsoidal geometry into a sphere — making all directions equally scaled.

Key Result

Theorem.

$$W = (\underline{x} - \underline{\mu})^\top \Sigma^{-1} (\underline{x} - \underline{\mu}) \sim \chi^2(p) \tag{10}$$

- **Proof:** Let $\underline{z} = \Sigma^{-1/2}(\underline{x} - \underline{\mu}) \sim \mathcal{N}_p(\underline{0}, I)$. Then:

$$W = (\underline{x} - \underline{\mu})^\top \Sigma^{-1/2} \cdot \Sigma^{1/2}(\underline{x} - \underline{\mu}) = \underline{z}^\top \underline{z} = \sum_{i=1}^{p} z_i^2 \tag{11}$$

- Since $z_i \overset{\text{iid}}{\sim} \mathcal{N}(0,1)$, we have $z_i^2 \sim \chi^2(1)$, so $\sum z_i^2 \sim \chi^2(p)$.
- **Geometric intuition:** In the standardized (spherical) space, W is the squared Euclidean distance from the origin. Summing p squared standard normals is the definition of $\chi^2(p)$.

Observation: Relation to $d^2_{\Sigma^{-1}}$

- Insert $I = \Sigma^{-1/2}\Sigma^{1/2}$:

$$W = (\underline{x} - \underline{\mu})^\top \Sigma^{-1/2} \cdot \Sigma^{1/2}(\underline{x} - \underline{\mu}) = \underline{z}^\top \underline{z} = \sum_{i=1}^{p} z_i^2$$

- $z_i \sim \mathcal{N}(0,1) \Rightarrow z_i^2 \sim \chi^2(1)$, and $z_1^2, \ldots, z_p^2 \overset{\text{iid}}{\sim} \chi^2(1) \Rightarrow \sum z_i^2 \sim \chi^2(p)$.

6 Confidence Ellipsoids

Since $W \sim \chi^2(p)$, denoting the $(1-\alpha)$ quantile as $\chi^2_{1-\alpha}(p)$:

$$\mathbb{P}\big[(\underline{x} - \underline{\mu})^\top \Sigma^{-1}(\underline{x} - \underline{\mu}) \leq \chi^2_{1-\alpha}(p)\big] = 1 - \alpha \tag{12}$$

- The set satisfying the inequality is an **ellipsoid** in $\mathbb{R}^p$:

$$\mathcal{E}_{\chi^2_{1-\alpha}(p)}(\underline{\mu}) = \big\{\underline{x} \in \mathbb{R}^p : (\underline{x} - \underline{\mu})^\top \Sigma^{-1}(\underline{x} - \underline{\mu}) \leq \chi^2_{1-\alpha}(p)\big\} \tag{13}$$

- **Axes:** along eigenvectors $\underline{e}_i$ of Σ.
- **Half-lengths:** $\sqrt{\lambda_i} \cdot \sqrt{\chi^2_{1-\alpha}(p)}$ along each axis.
- **The inversion (inverse problem):**

$$\mathbb{P}\big[(\underline{x} - \underline{\mu})^\top \Sigma^{-1}(\underline{x} - \underline{\mu}) \leq \chi^2_{1-\alpha}(p)\big] = 1 - \alpha = \mathbb{P}\Big[\underline{\mu} \in \mathcal{E}_{\chi^2_{1-\alpha}(p)}(\underline{x})\Big] \tag{14}$$

- The two events $\{\underline{x} \in \mathcal{E}(\underline{\mu})\}$ and $\{\underline{\mu} \in \mathcal{E}(\underline{x})\}$ are **equivalent**.
- **Interpretation:** After observing $\underline{x}$, the ellipsoid centered at $\underline{x}$ contains the unknown $\underline{\mu}$ with probability $1 - \alpha$ — this is a **confidence region** for $\underline{\mu}$.

7 Block Structure and Marginal Distributions

Notation Setup

- Partition $\underline{x} \in \mathbb{R}^p$ into two blocks:

$$\underline{x} = \begin{pmatrix} \underline{x}_1 \\ \underline{x}_2 \end{pmatrix}, \quad \underline{x}_1 \in \mathbb{R}^q, \quad \underline{x}_2 \in \mathbb{R}^{p-q} \tag{15}$$

- Mean and covariance partition accordingly:

$$\underline{\mu} = \begin{pmatrix} \underline{\mu}_1 \\ \underline{\mu}_2 \end{pmatrix}, \qquad \Sigma = \begin{bmatrix} \Sigma_{11}^{q\times q} & \Sigma_{12}^{q\times(p-q)} \\ \Sigma_{21}^{(p-q)\times q} & \Sigma_{22}^{(p-q)\times(p-q)} \end{bmatrix} \tag{16}$$

- **Meaning of each block:**
  - $\Sigma_{11} = \mathrm{Cov}(\underline{x}_1)$ — variance within $\underline{x}_1$
  - $\Sigma_{22} = \mathrm{Cov}(\underline{x}_2)$ — variance within $\underline{x}_2$
  - $\Sigma_{12} = \mathrm{Cov}(\underline{x}_1, \underline{x}_2)$ — the **information bridge** between blocks; $\Sigma_{21} = \Sigma_{12}^\top$

Proposition — Marginals

If $\underline{x} \sim \mathcal{N}_p\left(\begin{pmatrix} \underline{\mu}_1 \\ \underline{\mu}_2 \end{pmatrix}, \begin{bmatrix} \Sigma_{11} & \Sigma_{12} \\ \Sigma_{21} & \Sigma_{22} \end{bmatrix}\right)$, then:

$$\underline{x}_1 \sim \mathcal{N}_q(\underline{\mu}_1, \Sigma_{11}), \qquad \underline{x}_2 \sim \mathcal{N}_{p-q}(\underline{\mu}_2, \Sigma_{22}) \tag{17}$$

- **Proof:** Apply $A = [I_{q\times q} \mid \mathbf{0}_{q\times(p-q)}]$. Then $A\underline{x} = \underline{x}_1$ and $A\Sigma A^\top = \Sigma_{11}$.
- **Role:** These marginals are the **baseline** — what we know about $\underline{x}_1$ *before* observing $\underline{x}_2$.

8 Independence is Equivalent to Zero Cross-Covariance

Proposition. For $\underline{x} \sim \mathcal{N}_p$:

$$\Sigma_{12} = \mathbf{0} \iff \underline{x}_1 \perp\!\!\!\perp \underline{x}_2 \tag{18}$$

- **Proof:** When $\Sigma_{12} = \mathbf{0}$, the joint density factors:

$$f_{\underline{x}}(t_1, t_2) = f_{\underline{x}_1}(t_1) \cdot f_{\underline{x}_2}(t_2)$$

  Density factoring $\iff$ independence. (Proof that density factors is an exercise.)
- **Why remarkable?**
  - In general: independence $\Rightarrow$ zero covariance, but **not** vice versa.
  - For Gaussians only: zero covariance $\iff$ independence.
  - Example where the converse fails in general: $X \sim \mathcal{N}(0,1)$, $Y = X^2$. Then $\mathrm{Cov}(X,Y) = 0$ but Y is completely determined by X.
- **Practical consequence:** To check independence of two Gaussian blocks, just check whether $\Sigma_{12} = \mathbf{0}$.

9 Conditional Distribution of Gaussian Blocks

Theorem (Conditional Distribution).

$$\underline{x}_1 \mid \underline{X}_2 = \underline{x}_2 \sim \mathcal{N}_q\Big(\underline{\mu}_1 + \Sigma_{12}\Sigma_{22}^{-1}(\underline{x}_2 - \underline{\mu}_2),\ \ \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}\Big) \tag{19}$$

- **Conditional mean (regression function):**

$$E[\underline{x}_1 \mid \underline{X}_2 = \underline{x}_2] = \underbrace{\underline{\mu}_1}_{\text{prior mean}} + \underbrace{\Sigma_{12}\Sigma_{22}^{-1}}_{\text{regression matrix}} \cdot \underbrace{(\underline{x}_2 - \underline{\mu}_2)}_{\text{deviation of } x_2 \text{ from its mean}} \tag{20}$$

  - Linear in $\underline{x}_2$ — this is the **regression function**.
  - $\Sigma_{12}\Sigma_{22}^{-1}$: how much $\underline{x}_1$'s mean shifts per unit deviation of $\underline{x}_2$.
  - If $\Sigma_{12} = \mathbf{0}$: no shift — $\underline{x}_2$ carries no information about $\underline{x}_1$.

- **Conditional covariance (Schur complement):**

$$\mathrm{Cov}(\underline{x}_1 \mid \underline{X}_2 = \underline{x}_2) = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} \tag{21}$$

  - Always $\leq \Sigma_{11}$ — observing $\underline{x}_2$ **never increases** uncertainty.
  - **Does NOT depend on the observed value $\underline{x}_2$** — variance reduction is always the same.
  - If $\Sigma_{12} = \mathbf{0}$: equals Σ_{11} — no reduction.

- **Summary: what changes after conditioning?**

	Before observing $\underline{x}_2$	**After observing $\underline{X}_2 = \underline{x}_2$**
Mean	$\underline{\mu}_1$	$\underline{\mu}_1 + \Sigma_{12}\Sigma_{22}^{-1}(\underline{x}_2 - \underline{\mu}_2)$
Covariance	Σ_{11}	$\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$
Distribution	$\mathcal{N}_q(\underline{\mu}_1, \Sigma_{11})$	$\mathcal{N}_q(\cdots, \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21})$

Proof Strategy

- Define the matrix:

$$A = \begin{bmatrix} I_{q\times q} & -\Sigma_{12}\Sigma_{22}^{-1} \\ \mathbf{0}_{(p-q)\times q} & I_{(p-q)\times(p-q)} \end{bmatrix} \tag{22}$$

- Apply A to $(\underline{x} - \underline{\mu})$:

$$A(\underline{x} - \underline{\mu}) = \begin{pmatrix} (\underline{x}_1 - \underline{\mu}_1) - \Sigma_{12}\Sigma_{22}^{-1}(\underline{x}_2 - \underline{\mu}_2) \\ \underline{x}_2 - \underline{\mu}_2 \end{pmatrix} =: \begin{pmatrix} \underline{u} \\ \underline{x}_2 - \underline{\mu}_2 \end{pmatrix} \tag{23}$$

- By the linear transformation proposition, covariance of $A(\underline{x} - \underline{\mu})$:

$$A\Sigma A^\top = \begin{pmatrix} \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21} & \mathbf{0} \\ \mathbf{0} & \Sigma_{22} \end{pmatrix} \tag{24}$$

- Off-diagonal block is $\mathbf{0} \Rightarrow \underline{u} \perp\!\!\!\perp (\underline{x}_2 - \underline{\mu}_2)$.

- Since $\underline{u}$ is independent of $\underline{x}_2$, conditioning on $\underline{X}_2 = \underline{x}_2$ does not change $\underline{u}$'s distribution. But:
$$\underline{x}_1 = \underline{u} + \underline{\mu}_1 + \Sigma_{12}\Sigma_{22}^{-1}(\underline{x}_2 - \underline{\mu}_2) \tag{25}$$
- When $\underline{x}_2$ is fixed, the second term is a constant $\Rightarrow$ the theorem follows.
- **Intuition for A:** A removes the linear effect of $\underline{x}_2$ from $\underline{x}_1$. The residual $\underline{u}$ is independent of $\underline{x}_2$ — conditioning only adds back a constant shift.

10 The Bivariate Case ($p = 2$) and the Regression Line

- Let $\underline{x} = (y,\, x)^\top \sim \mathcal{N}_2\left(\begin{pmatrix}\mu_y \\ \mu_x\end{pmatrix}, \begin{pmatrix}\sigma_{yy} & \sigma_{xy} \\ \sigma_{xy} & \sigma_{xx}\end{pmatrix}\right)$.
- Marginal: $y \sim \mathcal{N}_1(\mu_y,\, \sigma_{yy})$, so $\mathbb{P}\big[y \in [\mu_y \pm 1.96\sqrt{\sigma_{yy}}]\big] = 95\%$.
- Applying the conditional theorem:
$$y \mid X = x \;\sim\; \mathcal{N}_1\left(\mu_y + \frac{\sigma_{xy}}{\sigma_{xx}}(x - \mu_x),\;\; \sigma_{yy} - \frac{\sigma_{xy}^2}{\sigma_{xx}}\right) \tag{26}$$
- Define the **correlation coefficient**:
$$\boxed{\rho \;\triangleq\; \frac{\sigma_{xy}}{\sqrt{\sigma_{xx}\,\sigma_{yy}}} = \operatorname{corr}(x, y), \quad |\rho| \le 1} \tag{27}$$
- Using $\sigma_{xy} = \rho\sqrt{\sigma_{xx}\sigma_{yy}}$, the conditional distribution becomes:
$$y \mid X = x \;\sim\; \mathcal{N}_1\left(\mu_y + \rho\frac{\sqrt{\sigma_{yy}}}{\sqrt{\sigma_{xx}}}(x - \mu_x),\;\; \sigma_{yy}(1 - \rho^2)\right) \tag{28}$$
- **Regression line** (conditional mean):
$$E[y \mid X = x] = \mu_y + \rho\,\frac{\sqrt{\sigma_{yy}}}{\sqrt{\sigma_{xx}}}(x - \mu_x) \tag{29}$$
- In **standardized coordinates** ($y_{\text{std}} = (y - \mu_y)/\sqrt{\sigma_{yy}}$, $x_{\text{std}} = (x - \mu_x)/\sqrt{\sigma_{xx}}$):
$$\boxed{y_{\text{std}} = \rho \cdot x_{\text{std}}} \tag{30}$$
The slope of the regression line in standardized coordinates is exactly ρ.
- **Conditional variance:**
  - $|\rho| = 1$: zero conditional variance — y is perfectly determined by x.
  - $\rho = 0$: $\operatorname{Var}(y|X = x) = \sigma_{yy}$ — x provides no information.
  - $0 < |\rho| < 1$: variance reduced by factor $(1 - \rho^2)$.

11 Regression Fallacy

Problem: Regression Fallacy (noted in lecture as related to Nobel Prize economics mistakes)

- **Setup:** In standardized coordinates, the regression line has slope ρ, with $|\rho| \leq 1$.
- **The mathematical fact:** Since $|\rho| \leq 1$:

$$E[y_{\text{std}} \mid x_{\text{std}}] = \rho \cdot x_{\text{std}}, \quad |\rho| \leq 1 \tag{31}$$

  So if x is extreme (far from μ_x), the predicted y is **closer to** μ_y than x is to μ_x in standard deviation units.
- **Two lines to compare:**
  - **45° line** ($y_{\text{std}} = x_{\text{std}}$, slope 1): would hold if $y = x$ exactly.
  - **Regression line** ($y_{\text{std}} = \rho \cdot x_{\text{std}}$, slope $\rho < 1$): always flatter.
- **The fallacy:** People observe that extreme parents have less extreme children, and give a causal explanation ("they are less talented"). In reality:
  - This is a **mathematical inevitability**, not a biological or causal fact.
  - It follows purely from $|\rho| \leq 1$.
  - Galton's original observation: very tall fathers have tall sons, but *less tall than themselves on average.*
- **Why "regression" is called regression:** The predicted value always *regresses toward the mean* — this is the origin of the word in statistics.
- **Key exam point:** Confusing this statistical regression toward the mean with a causal mechanism is the fallacy. The math gives no causal explanation.

Summary: The Full Logical Chain

Step	Tool	Why needed?	What it gives
1	Definition $\mathcal{N}_p(\underline{\mu}, \Sigma)$	Model p-dim. data	Ellipsoid contours
2	Theorem ($\underline{a}^\top \underline{x} \sim \mathcal{N}_1$)	Reduce to 1D	Proof tool for everything
3	Corollary	Check marginals	$x_i \sim \mathcal{N}_1(\mu_i, \sigma_{ii})$
4	Linear map $A\underline{x}$	Transform Gaussian	$A\underline{x} \sim \mathcal{N}_q(A\underline{\mu}, A\Sigma A^\top)$
5	Standardization	Sphericalize	$\Sigma^{-1/2}(\underline{x} - \underline{\mu}) \sim \mathcal{N}_p(0, I)$
6	Mahalanobis $\sim \chi^2(p)$	Get known distribution	Confidence ellipsoid
7	Block Σ	Split known/unknown	Σ_{12} = information bridge
8	Indep. $\iff \Sigma_{12} = 0$	Gaussian special property	Read independence from Σ
9	Conditional theorem	**Main goal**	Mean shifts, variance shrinks
10	Regression fallacy	Apply $\lvert\rho\rvert \leq 1$	Extreme $x \to$ less extreme y

One-sentence summary: We defined the multivariate Gaussian $\rightarrow$ showed every linear projection is Gaussian $\rightarrow$ standardized to get $\chi^2(p)$ for the Mahalanobis distance $\rightarrow$ built confidence ellipsoids $\rightarrow$ split $\underline{x}$ into blocks to derive the conditional distribution $\rightarrow$ discovered the conditional mean is linear (regression) and the slope $|\rho| \leq 1$ causes inevitable regression toward the mean.

Türkçe Açıklamalar

Turkish Explanations

A Büyük Resim — Neden Gaussian? Ne Yapıyoruz?

- **Temel soru:** p tane değişkenim var. Bunların dağılımını nasıl modellerim?
- **Örnek:** Bir hastanın boy, kilo, kan basıncı, kolesterol değerleri $\to p = 4$ boyutlu vektör $\underline{x} \in \mathbb{R}^p$.
- **Neden Gaussian seçiyoruz?**
  - Doğada pek çok fenomen yaklaşık olarak Gaussian.
  - Lineer dönüşümler altında kapanıyor — matematiksel kolaylık.
  - Merkezi Limit Teoremi: büyük örneklem ortalamaları Gaussian'a gidiyor.
  - Yalnızca $\underline{\mu}$ ve Σ ile tam olarak tarif ediliyor.
- **Tüm kısmın mantıksal zinciri:**
  1. $\mathcal{N}_p(\underline{\mu}, \Sigma)$'yı tanımla $\to$ kontürler elips, Σ her şeyi belirliyor.
  2. Karakterizasyon teoremi $\to$ p boyutu tek boyuta indir, ispat aracı.
  3. Lineer dönüşüm $\to$ Gaussian kapanıyor, standartlaştırma mümkün.
  4. Standartlaştır $\to$ elipsi çembere çevir.
  5. Mahalanobis uzaklığı $\sim \chi^2(p)$ $\to$ dağılımı bilinen tek sayı elde et.
  6. Güven elipsoidi $\to$ bilinmeyen $\underline{\mu}$ için çıkarım yap.
- **Tek cümle özet:** Gaussian'ı tanımladık $\to$ özelliklerini kullanarak standart forma indirdik $\to$ standart formda uzaklığın χ^2 dağıldığını bulduk $\to$ bu χ^2'yi kullanarak bilinmeyen $\underline{\mu}$ için güven bölgesi kurduk.

B Tanım ve Geometrik Sezgi

- **Yoğunluk fonksiyonu:**

$$f_{\underline{x}}(t) = \frac{1}{\sqrt{(2\pi)^p|\Sigma|}} \exp\left(-\frac{1}{2}(t-\underline{\mu})^\top \Sigma^{-1}(t-\underline{\mu})\right)$$

- **f ne zaman büyük?**
  - exp içindeki $-\frac{1}{2}(\ldots)$ sıfıra yakın olduğunda, yani $(t-\underline{\mu})^\top\Sigma^{-1}(t-\underline{\mu})$ küçük olduğunda.
  - Bu da t'nin $\underline{\mu}$'ya **yakın** olduğu anlamına gelir.
- **Kontürler neden elips?**
  - $f_{\underline{x}}(t) = c \iff (t-\underline{\mu})^\top\Sigma^{-1}(t-\underline{\mu}) = \text{sabit}$.
  - Bu denklem $\mathbb{R}^p$'de $\underline{\mu}$ merkezli bir **elipsoid** tanımlar.
  - Σ'nın **özvektörleri** elipsin eksenlerini, $\sqrt{\lambda_i}$ ise yarı uzunlukları verir.

  - $\Sigma = I \Rightarrow$ kontürler mükemmel çember.
  - Büyük $\lambda_i \Rightarrow$ elips o yönde uzar.

- **Özdekompozisyon:**

$$\Sigma = \sum_i \lambda_i \underline{e}_i \underline{e}_i^\top, \qquad \Sigma^{1/2} = \sum_i \sqrt{\lambda_i}\, \underline{e}_i \underline{e}_i^\top, \qquad \Sigma^{-1/2} = \sum_i \frac{1}{\sqrt{\lambda_i}}\, \underline{e}_i \underline{e}_i^\top$$

- **Sınavda çıkacak soru tipi:** "Σ değişirse elips nasıl değişir?"

C Karakterizasyon Teoremi — Tüm İspatların Temeli

- **Teorem:**

$$\underline{x} \sim \mathcal{N}_p(\underline{\mu}, \Sigma) \iff \forall\, \underline{a} \in \mathbb{R}^p, \quad \underline{a}^\top \underline{x} \sim \mathcal{N}_1(\underline{a}^\top \underline{\mu},\, \underline{a}^\top \Sigma \underline{a})$$

- **Neden bu kadar kritik?**
  - Çok boyutlu Gaussian'ı doğrudan çalışmak zor.
  - Bu teorem diyor ki: p boyutlu problemi **tek boyuta indirgeyebilirsin**.
  - $\underline{a}^\top \underline{x}$ bir sayı — tek boyutlu Gaussian.
  - Tüm ispat stratejisi bunun üzerine kurulu.
- **Kullanım örneği (Image 4 ispatı):**
  - "Her $\underline{a} \in \mathbb{R}^q$ için $\underline{a}^\top (A\underline{x}) = (A^\top \underline{a})^\top \underline{x}$, teorem ile $\mathcal{N}_1$, dolayısıyla tekrar teorem ile $A\underline{x} \sim \mathcal{N}_q$."
- **Korolerin uyarısı:**
  - Marjinaller Gaussian $\not\Rightarrow$ joint Gaussian.
  - Pasta dilimi örneği: marjinaller Gaussian, kontürler elips değil.
  - Notlarda $\Leftarrow$ oku **çizili** — sınavda bu ayrım kritik!

D Lineer Dönüşüm — Gaussian'ın Altın Özelliği

- **Proposition:** $\underline{x} \sim \mathcal{N}_p(\underline{\mu}, \Sigma)$, A $q \times p$ matris ise:

$$A\underline{x} \sim \mathcal{N}_q(A\underline{\mu},\, A\Sigma A^\top)$$

- **Neden önemli?**
  - Gaussian, lineer dönüşüm altında **kapanıyor**.
  - Döndürürsek, sıkıştırırsak, projekte edersek — yine Gaussian.
  - Pek çok dağılım bunu sağlamıyor.
- **Önemli özel durumlar:**
  - **Öteleme:** $\underline{x} + \underline{d} \sim \mathcal{N}_p(\underline{\mu} + \underline{d},\, \Sigma) \to$ ortalama kayıyor, şekil değişmiyor.
  - **Marjinaller:** $\underline{a} = (0, \ldots, 1, \ldots, 0)^\top$ al $\to x_i \sim \mathcal{N}_1(\mu_i, \sigma_{ii})$.

  - **Standartlaştırma:** $A = \Sigma^{-1/2}$ al, $\underline{\mu}$'yu çıkar $\to \Sigma^{-1/2}(\underline{x} - \underline{\mu}) \sim \mathcal{N}_p(\underline{0}, I)$.

- **İnşaat:** $z_1, \ldots, z_p \overset{\text{iid}}{\sim} \mathcal{N}(0,1)$ ise:

$$\underline{x} = \Sigma^{1/2}\underline{z} + \underline{\mu} \sim \mathcal{N}_p(\underline{\mu}, \Sigma)$$

- **Sezgi:** Her çok boyutlu Gaussian, bağımsız standart normallerden oluşan bir kürenin afin dönüşümüdür. $\Sigma^{1/2}$ küreyi elipsoide uzatıp döndürür.

E Mahalanobis Uzaklığı — Çıkarımın Kalbi

- **Bu adım neden kritik?**
  - Elimizde $\underline{x} \sim \mathcal{N}_p(\underline{\mu}, \Sigma)$ var.
  - $\underline{x}$'in $\underline{\mu}$'dan ne kadar uzak olduğunu ölçmek istiyoruz.
  - Düz Öklid uzaklığı adil değil: yüksek varyanslı yönlerde küçük mesafe önemsiz, düşük varyanslı yönlerde aynı mesafe çok önemli.
  - Σ^{-1} bunu düzeltiyor.
- **Karelenmiş Mahalanobis uzaklığı:**

$$W = (\underline{x} - \underline{\mu})^\top \Sigma^{-1} (\underline{x} - \underline{\mu})$$

- **Teorem:** $W \sim \chi^2(p)$
- **İspat mantığı:**
  - $\underline{z} = \Sigma^{-1/2}(\underline{x} - \underline{\mu}) \sim \mathcal{N}_p(\underline{0}, I)$ (standartlaştırma propositionundan).
  - $W = \underline{z}^\top \underline{z} = \sum_{i=1}^p z_i^2$.
  - $z_i \overset{\text{iid}}{\sim} \mathcal{N}(0,1) \Rightarrow z_i^2 \sim \chi^2(1) \Rightarrow \sum z_i^2 \sim \chi^2(p)$.
- **Geometrik sezgi:**
  - Σ^{-1} uzayı "düzeltiyor" — elipsi çembere dönüştürüyor.
  - O çemberde $\underline{z}$'nin $\underline{0}$'dan uzaklığının karesi p bağımsız standart normalin karelerinin toplamı.
  - Bu tam olarak $\chi^2(p)$'nin tanımı.

F Güven Elipsoidi ve Ters Problem

- $W \sim \chi^2(p)$ sonucunu kullanarak:

$$\mathbb{P}\left[(\underline{x} - \underline{\mu})^\top \Sigma^{-1} (\underline{x} - \underline{\mu}) \leq \chi^2_{1-\alpha}(p)\right] = 1 - \alpha$$

- **Güven elipsoidi:**

$$\mathcal{E}_{\chi^2_{1-\alpha}(p)}(\underline{\mu}) = \left\{\underline{x} \in \mathbb{R}^p : (\underline{x} - \underline{\mu})^\top \Sigma^{-1} (\underline{x} - \underline{\mu}) \leq \chi^2_{1-\alpha}(p)\right\}$$

- **Ters problem (professor'ın sorusu):**
  - İstatistikte $\underline{\mu}$ **bilinmiyor**, $\underline{x}$ **gözlemleniyor**.
  - "$\underline{x}$, $\underline{\mu}$ etrafındaki elipsoidin içinde mi?" yerine soruyoruz:
  - "$\underline{\mu}$, $\underline{x}$ etrafındaki elipsoidin içinde mi?"

$$\mathbb{P}\left[\underline{\mu} \in \mathcal{E}_{\chi^2_{1-\alpha}(p)}(\underline{x})\right] = 1 - \alpha$$

  - İki olay eşdeğer — aynı Mahalanobis eşitsizliği, sadece merkez değişiyor.
  - Bu, $\underline{\mu}$ için $(1-\alpha)$ **güven bölgesi** inşasının temelidir.

G 2. Kısım — Blok Yapı: Amaç ve Sezgi

- **Temel soru değişti:**
  - 1. kısımda $\underline{x}$'i bir bütün olarak ele aldık.
  - Şimdi: "p değişkenim var. Bazılarını gözlemledim. Geri kalanlar hakkında ne söyleyebilirim?"
- **Neden bloklara bölüyoruz?**
  - $\underline{x}_1$: tahmin etmek istediğimiz değişkenler.
  - $\underline{x}_2$: gözlemlediğimiz / bildiğimiz değişkenler.
  - Σ_{12}: iki blok arasındaki **bilgi köprüsü**.
  - $\Sigma_{12} = \mathbf{0}$ ise Gaussian'da bağımsızlık $\rightarrow$ $\underline{x}_2$'yi bilmek hiçbir şey söylemez.
- **2. kısmın mantıksal zinciri:**
  1. Blok notasyon $\rightarrow$ Σ_{12} bilgi köprüsünü gösterir.
  2. Marjinaller Gaussian $\rightarrow$ baseline: $\underline{x}_2$'yi bilmeden önce neredeyiz?
  3. Bağımsızlık $\iff$ $\Sigma_{12} = \mathbf{0}$ $\rightarrow$ Gaussian'a özgü altın özellik.
  4. Koşullu dağılım teoremi $\rightarrow$ **asıl hedef**.
  5. Regresyon fonksiyonu $\rightarrow$ koşullu ortalama lineer.
  6. Regresyon yanılgısı $\rightarrow$ $|\rho| \leq 1$'in kaçınılmaz sonucu.
- **Tek cümle özet:** Gaussian'ı bloklara böldük $\rightarrow$ Σ_{12} blokların ne kadar "konuştuğunu" söylüyor $\rightarrow$ $\underline{x}_2$'yi gözlemlemek $\underline{x}_1$'in ortalamasını $\Sigma_{12}\Sigma_{22}^{-1}$ kadar kaydırıyor, varyansını $\Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$ kadar düşürüyor $\rightarrow$ bu kayma lineer olduğundan $|\rho| \leq 1$ ve aşırı gözlemler her zaman ortalamaya çekiliyor.

H Bağımsızlık $\iff$ $\Sigma_{12} = \mathbf{0}$: Gaussian'ın Özel Armağanı

- **Proposition:**

$$\underline{x} \sim \mathcal{N}_p \text{ ve } \Sigma_{12} = \mathbf{0} \iff \underline{x}_1 \perp\!\!\!\perp \underline{x}_2$$

- **İspat:** $\Sigma_{12} = \mathbf{0}$ olduğunda joint yoğunluk çarpanlarına ayrılıyor:

$$f_{\underline{x}}(t_1, t_2) = f_{\underline{x}_1}(t_1) \cdot f_{\underline{x}_2}(t_2)$$

  Yoğunluğun çarpan ayrışması $\iff$ bağımsızlık.

- **Neden bu bu kadar özel?**
  - Genel dağılımlarda: bağımsız $\Rightarrow$ Cov $= 0$, ama tersi **doğru değil**.
  - Örnek: $X \sim \mathcal{N}(0,1)$, $Y = X^2$. $\mathrm{Cov}(X,Y) = 0$ ama Y tamamen X'ten üretildi — bağımlı!
  - **Sadece Gaussian'da:** korelasyonsuz $\iff$ bağımsız.

- **Pratik sonuç:** Σ matrisine bakarak bağımsızlığı anlayabilirsin — başka hiçbir dağılımda bu bu kadar kolay değil.

- **Sınavda çıkacak mantık:** "$\Sigma_{12} = 0$ ise ne söyleyebilirsin?" $\rightarrow$ Gaussian varsayımı altında: tam bağımsızlık. $\rightarrow$ Gaussian varsayımı yoksa: sadece korelasyonsuzluk.

I Koşullu Dağılım Teoremi — 2. Kısmın Var Olma Sebebi

- **Teorem:**

$$\underline{x}_1 \mid \underline{X}_2 = \underline{x}_2 \sim \mathcal{N}_q\left(\underbrace{\underline{\mu}_1 + \Sigma_{12}\Sigma_{22}^{-1}(\underline{x}_2 - \underline{\mu}_2)}_{\text{yeni ortalama}},\ \underbrace{\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}}_{\text{yeni kovaryans (Schur)}}\right)$$

- **Yeni ortalamayı parçalara ayıralım:**
  - $(\underline{x}_2 - \underline{\mu}_2)$: $\underline{x}_2$'nin kendi ortalamasından ne kadar saptığı.
  - $\Sigma_{12}\Sigma_{22}^{-1}$: Bu sapmanın $\underline{x}_1$'e ne kadar yansıdığı — **regresyon katsayısı matrisi**.
  - Toplam: $\underline{x}_1$'in beklenen değeri, $\underline{x}_2$ ne kadar aşırıysa o kadar kayıyor.

- **Schur complement (yeni kovaryans) sezgisi:**
  - Σ_{11}: $\underline{x}_2$'yi bilmeden önceki belirsizlik.
  - $\Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$: $\underline{x}_2$'yi öğrenerek **sildiğimiz** belirsizlik.
  - Fark her zaman $\leq \Sigma_{11}$ — bilgi asla belirsizliği artırmaz.
  - **Kritik nokta:** Koşullu kovaryans $\underline{x}_2$'nin **hangi değer aldığına bağlı değil**. $\underline{x}_2$ aşırı mı, ortalamada mı — fark etmez. Belirsizlik azalması hep aynı. Sadece **ortalama** kayıyor.

- **A matrisinin sezgisi (ispat stratejisi):**
  - A matrisi, $\underline{x}_1$'den $\underline{x}_2$'nin "etkisini çıkarıyor."
  - Geriye kalan $\underline{u}$ artık $\underline{x}_2$'den tamamen bağımsız.
  - Koşullandırma sadece sabiti değiştiriyor, dağılımın şeklini değil.

- **Kondisyon öncesi ve sonrası özet:**

	$\underline{x}_2$**'yi bilmeden önce**	$\underline{X}_2 = \underline{x}_2$ **gözlemlendikten sonra**
Ortalama	$\underline{\mu}_1$	$\underline{\mu}_1 + \Sigma_{12}\Sigma_{22}^{-1}(\underline{x}_2 - \underline{\mu}_2)$
Kovaryans	Σ_{11}	$\Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$
Dağılım	$\mathcal{N}_q(\underline{\mu}_1, \Sigma_{11})$	$\mathcal{N}_q(\cdots, \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21})$

J Regresyon Fonksiyonu ve Regresyon Yanılgısı

- **$p = 2$ özel durumu — regresyon doğrusu:**

$$E[y \mid X = x] = \mu_y + \rho \frac{\sqrt{\sigma_{yy}}}{\sqrt{\sigma_{xx}}}(x - \mu_x)$$

- **Korelasyon katsayısı (notlarda kutu içinde):**

$$\rho \triangleq \frac{\sigma_{xy}}{\sqrt{\sigma_{xx}\sigma_{yy}}} = \mathrm{corr}(x, y), \qquad |\rho| \leq 1$$

- Standart koordinatlarda ($y_{\text{std}} = (y - \mu_y)/\sqrt{\sigma_{yy}}$, $x_{\text{std}} = (x - \mu_x)/\sqrt{\sigma_{xx}}$):

$$y_{\text{std}} = \rho \cdot x_{\text{std}}$$

  Eğim tam olarak ρ.

- **Koşullu varyans:**
  - $|\rho| = 1$: sıfır koşullu varyans — y, x'ten tamamen belirleniyor.
  - $\rho = 0$: varyans değişmiyor — x, y hakkında hiçbir şey söylemiyor.
  - $0 < |\rho| < 1$: varyans $(1 - \rho^2)$ çarpanı kadar azalıyor.

- **Regresyon yanılgısı nedir?**
  - $|\rho| \leq 1$ olduğundan regresyon doğrusunun eğimi standart koordinatlarda her zaman ≤ 1.
  - İki doğruyu karşılaştır:
    * 45 **doğrusu** ($y_{\text{std}} = x_{\text{std}}$, eğim 1): $y = x$ tam eşitliği olsaydı geçerli olurdu.
    * **Regresyon doğrusu** ($y_{\text{std}} = \rho \cdot x_{\text{std}}$, eğim $\rho < 1$): her zaman daha yatık.
  - **Matematiksel gerçek:** x aşırı olsa bile $E[y|x]$ ortalamaya daha yakın tahmin eder — "**ortalamaya doğru regresyon**."
  - **Galton'ın gözlemi:** Çok uzun babaların oğulları ortalamadan uzun ama babadan kısa. Bu biyolojik bir gerçek mi? **Hayır!** Salt $|\rho| \leq 1$'in matematiksel sonucu.
  - **Yanılgı:** "Oğullar daha az yetenekli" demek — matematiksel zorunluluğu nedensel yorumlamak.
  - Notlarda Nobel Ödülü bağlantısı: ekonomide sık yapılan hata.

- **Sınavda çıkacak mantık:**
  - Regresyonun ortalamaya doğru çekimi nedensel değil, matematiksel zorunluluktur.
  - Slope $\rho < 1$ matematiktir, biyoloji veya ekonomi değil.
  - "Neden regresyon denir?" sorusu $\rightarrow$ Galton'ın "ortalamaya doğru regresyon" gözleminden geliyor.