

8 - Sıfırdan Anlatım: Gaussian Dağılım Parametrelerinin Tahmini

Applied Statistics

Unat Teksen

March 13, 2026

1 En Temel Soru

- Elimizde bir veri var. Mesela 100 kişinin boyu. Bu veriye bakıyoruz ve şunu soruyoruz:

“Bu veriler hangi dağılımdan geliyor? Ve o dağılımın parametreleri ne?”

- Gaussian (Normal) dağılım seçiyoruz çünkü doğada çoğu şey bu şekilde dağılır. Gaussian dağılımın iki parametresi var:
 - μ (**mu**): Ortalama — verinin “merkezi” nerede?
 - Σ (**sigma**): Kovaryans — veriler ne kadar yayılmış?
- **Problem:** Bu iki parametreyi bilmiyoruz. Sadece elimizde veri var.
- **Tüm konu bu soruyu yanıtlamak için:** Parametreleri veriden nasıl tahmin ederiz, ve bu tahminlere ne kadar güvenebiliriz?

2 Açık Tahmin Ediciler — “Sezgisel Cevap”

2.1 Ne Yapıyoruz?

- Parametreleri tahmin etmek için en basit, en sezgisel yöntemi kullanıyoruz.

2.2 Ortalamayı Tahmin Et $\rightarrow$ Örneklem Ortalaması

$$\hat{\mu} = \bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

- **Örnek:** 5 kişinin boyu: 170, 175, 180, 165, 160 cm.

$$\bar{X} = \frac{170 + 175 + 180 + 165 + 160}{5} = 170 \text{ cm}$$

Popülasyonun ortalama boyunu 170 cm olarak tahmin ediyoruz.

- **Sezgi:** Sınıftaki öğrencilerin boy ortalamasını bulmak istiyorsun ama tüm öğrencileri ölçemiyorsun. 5 kişiyi ölçüyorsun, ortalamasını alıyorsun. Mantıklı, değil mi?

2.3 Yayılımı Tahmin Et → Örneklem Kovaryansı

$$S = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})^\top$$

- Her boyun 170'ten ne kadar uzakta olduğunu hesapla, karelerini al, ortalama. Bu sana verinin ne kadar yayıldığını söyler.
- **Neden $n-1$, neden n değil?** Çünkü $\bar{X}$ 'i de aynı veriden hesapladık. Bu bir “bilgi harcaması” — bir serbestlik derecesi yiyor. $n-1$ kullanmak bu hatayı düzeltiyor. Buna **Bessel düzeltmesi** denir.
- Sonuç: $\mathbb{E}[S] = \Sigma$ — tarafsız tahmin edici.

3 MLE — “Prensipli Cevap”

3.1 Ne Yapıyoruz?

- Sezgisel yöntem güzel ama *neden* o formülleri kullandığımızı açıklamıyor.
- MLE bize şunu soruyor:

“Hangi parametre değerleri bu veriyi en olası kılar?”

- **Likelihood (Olabilirlik) fonksiyonu:**

$$L(\theta \mid \text{veri}) = P(\text{veri} \mid \theta)$$

- **MLE tanımı:**

$$\hat{\theta} = \arg \max_{\theta} L(\theta \mid \text{veri})$$

- Uygulamada **log-olabilirlik** $\ell = \log L$ maksimize edilir çünkü:
 - Çarpımlar toplamlar olur — türev almak kolaylaşır.
 - Gaussian'daki üstel fonksiyon yok olur.
 - Argmax değişmez: log monoton artan bir fonksiyondur.

3.2 Küçük Örnek — Bernoulli

- 5 yazı-tura atıyorsun: **T, T, Y, T, Y** (T = tura, Y = yazı)
- Soru: Paranın tura gelme olasılığı p nedir?
- **Olabilirlik:**

$$L(p) = p^3 \cdot (1-p)^2$$

(3 tura, 2 yazı var)

- Bunu maksimize edince:

$$\hat{p} = \frac{3}{5} = 0.6$$

- **Sezgi:** Sormadan önce bile cevabı hissedebiliyordun. MLE bu sezgiyi matematiksel olarak formelleştiriyor. “Gördüğüm veriyi en olası kılacak parametre nedir?” sorusunun cevabı.

3.3 Gaussian için MLE

- Tek bir $X_i \sim N_p(\mu, \Sigma)$ gözleminin yoğunluğu:

$$\varphi_{\mu, \Sigma}(x) = \frac{1}{\sqrt{(2\pi)^p |\Sigma|}} \exp \left[-\frac{1}{2} (x - \mu)^\top \Sigma^{-1} (x - \mu) \right]$$

- iid gözlemler için log-olabilirlik:

$$\ell(\mu, \Sigma) = -\frac{n}{2} \log [(2\pi)^p |\Sigma|] - \frac{1}{2} \sum_{i=1}^n (X_i - \mu)^\top \Sigma^{-1} (X_i - \mu)$$

- Aynı mantığı Gaussian'a uygulayınca şu çıkıyor:

$$\hat{\mu} = \bar{X} \longrightarrow \text{sezgisel cevapla aynı!}$$

$$\hat{\Sigma} = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})^\top$$

- **Dikkat:** MLE n ile böler, sezgisel yöntem $n - 1$ ile böler.

Tahmin Edici	Payda	Taraflı mı?	Açıklama
S (sezgisel)	$n - 1$	Tarafsız ✓	$\mathbb{E}[S] = \Sigma$
$\hat{\Sigma}$ (MLE)	n	Taraflı ×	$\mathbb{E}[\hat{\Sigma}] = \frac{n-1}{n} \Sigma$

- **Taraflı ne demek?** $\hat{\Sigma}$ gerçek Σ 'yı sistematik olarak *küçük* tahmin eder. n büyüdükçe fark küçülür ama küçük örneklerde önemlidir.

- Bağlantı: $\hat{\Sigma} = \frac{n-1}{n} S$

4 Invariance — “Bedava Sonuçlar”

4.1 Ne Yapıyoruz?

- μ ve Σ 'nin MLE'sini bulduk. Peki başka bir şeyin MLE'sini istesek?
- **İnvariance özelliği:**

$$\widehat{h(\theta)} = h(\hat{\theta})$$

İstediğin fonksiyonu $\hat{\theta}$ 'ya uygula — o da otomatik olarak MLE olur.

4.2 Örnek

- Σ 'nin özdeğerleri $\lambda_1, \dots, \lambda_p$ 'nin MLE'si nedir?
 - **İnvariance olmadan:** Başa dön, yeni optimizasyon kur, türev al... (çok iş)
 - **İnvariance ile:** $\hat{\Sigma}$ 'nin özdeğerlerini hesapla. Bitti.

- Spectral decomposition:

$$\Sigma = \sum_{i=1}^p \lambda_i \xi_i \xi_i^\top \quad \text{değişmezlik} \quad \hat{\Sigma} = \sum_{i=1}^p \hat{\lambda}_i \hat{\xi}_i \hat{\xi}_i^\top$$

- **Sezgi:** Bir fabrikada ürünlerin ağırlığının MLE'sini buldun. Şimdi ağırlığın karesinin MLE'sini istiyorlar. Baştan fabrikaya gitmen gerekmiyor — elindeki sonucu kare al, bitti. Invariance bu.
- **Geometrik sezgi:** Σ 'yı bir varyans elipsoidi olarak düşün. Özvektörler elipsoidin eksenleri, özdeğerler o eksenlerdeki uzunluklardır. MLE bu elipsoidi veriden tahmin eder.
- **Sınav sezgisi:** “Bir şeyin fonksiyonunun MLE'si” sorulduğunda ilk düşünce her zaman değişmezlik olmalı.

5 $\bar{X}$ 'nin Dağılımı — “Tahminimiz Ne Kadar Güvenilir?”

5.1 Ne Yapıyoruz?

- $\bar{X}$ 'i hesapladık. Ama $\bar{X}$ her örnekte farklı çıkar. **Bu farklılık ne kadar büyük?**

5.2 Sonuç (Kesin Teorem)

$$\bar{X} \sim N_p\left(\mu, \frac{1}{n}\Sigma\right)$$

- Bu **kesin bir sonuçtur** — yaklaşım değil. Her $n \geq 1$ için geçerli.
- Ne anlama geliyor?
 - $\bar{X}$ 'in beklenen değeri μ : doğru yerde, sapma yok. ✓
 - $\bar{X}$ 'in yayılımı Σ/n : n büyüdükçe küçülür. ✓
- **Küçük örnek:** Boy ölçümü yapıyorsun. Gerçek ortalama $\mu = 175$ cm, $\sigma = 10$ cm.
 - 10 kişi: $\bar{X}$ yaklaşık ± 3.2 cm hata yapar.
 - 100 kişi: $\bar{X}$ yaklaşık ± 1 cm hata yapar.
 - 1000 kişi: $\bar{X}$ yaklaşık ± 0.3 cm hata yapar.
- **Sezgi:** Ne kadar çok veri, o kadar dar aralık. Bu formül tam olarak ne kadar dar olacağını söylüyor.
- **Sonuç — güven bölgesi:**

$$n(\bar{X} - \mu)^\top \Sigma^{-1}(\bar{X} - \mu) \sim \chi_p^2$$

μ için eliptik güven bölgesi — çok değişkenli z -testinin karşılığı.

6 Wishart Dağılımı — “ S ’nin Dağılımı”

6.1 Ne Yapıyoruz?

- $\bar{X}$ ’in dağılımını bulduk. Şimdi S ’nin dağılımını bulmak istiyoruz.
- **1D analoji:** $X_i \sim N(\mu, \sigma^2)$ için:

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

Bu χ^2 dağılımı *tek bir sayının* nasıl dağıldığını söylüyor.

- Çok boyutlu durumda S tek bir sayı değil, **bir matristir**. Matrisler için χ^2 ’ye ihtiyacımız var. Bu **Wishart dağılımıdır**.
- **Slogan:** *Wishart, matrisler için χ^2 ’dir.*

6.2 Tanım

$$W = \sum_{j=1}^m Z_j Z_j^\top, \quad Z_j \stackrel{\text{iid}}{\sim} N_p(0, \Sigma) \implies W \sim W_p(m, \Sigma)$$

- Her $Z_j Z_j^\top$: rank-1’lik $p \times p$ dış çarpım matrisi.
- m adet bağımsız rank-1 matrisin toplamı.
- Tıpkı $\chi_m^2 = \sum_{j=1}^m Z_j^2$ (skaler karelerin toplamı) gibi — vektör versiyonu.
- Özel durum: $p = 1$ için $W_1(m, \sigma^2) = \sigma^2 \chi_m^2$ — tam olarak ölçeklenmiş χ^2 .

6.3 Temel Teorem

$$(n-1)S \sim W_p(n-1, \Sigma), \quad \bar{X} \text{ ve } S \text{ bağımsızdır.}$$

- **Neden $n-1$?** $\sum_{i=1}^n (X_i - \bar{X}) = 0$ kısıtı bir serbestlik derecesi tüketir — 1D durumundaki χ_{n-1}^2 ile aynı neden.
- **$\bar{X}$ ve S ’nin bağımsızlığı neden önemli?**
 - Hipotez testlerinde $\bar{X}$ ve S ’yi birlikte kullanıyoruz.
 - Eğer bağımlı olsalardı, birini diğerinden bağımsız kullanamazdık.
 - Bağımsız olduğu için t -testi (1D) ve Hotelling T^2 testi (çok boyutlu) mümkün.

6.4 Neden Önemli?

- 100 farklı araştırmacı aynı deneyi yapıyor, her biri kendi S ’ini hesaplıyor. Bu 100 farklı S matrisi nasıl dağılmış? **Wishart bunu söylüyor.**

6.5 Kritik Özellikler

- **Beklenen değer:**

$$\mathbb{E}[(n-1)S] = (n-1)\Sigma \Rightarrow \mathbb{E}[S] = \Sigma \quad (\text{tarafsız}) \checkmark$$

- **Toplanabilirlik:** $W_1 \perp W_2 \Rightarrow W_1 + W_2 \sim W_p(m_1 + m_2, \Sigma)$ — tıpkı χ^2 gibi.
- **Doğrusal dönüşüm:** $AWA^\top \sim W_q(m, A\Sigma A^\top)$ — Wishart yapısı korunur.
- **Skaler projeksiyon:** $a^\top W a \sim (a^\top \Sigma a) \chi_m^2$ — matristeki istatistikten skalere köprü.
- **Pozitif tanımlılık:** $W \sim W_p(m, \Sigma)$ tersinebilir $\iff m \geq p$.
- **Kritik pratik sonuç — $n > p$ bariyeri:**

Durum	Ne olur?
$n > p$	S düzgün çalışır $\checkmark$
$n \leq p$	S tekil olur, tersini alamazsın $\times$

- **Örnek:** 10 kişiden 50 özellik ölçtün ($n = 10, p = 50$). S tekil olur, tersini alamazsın. Yüksek boyutlu istatistiğin temel problemi budur.
- **Sezgi:** S bir sayı değil, tüm bir elipsoiddir. Wishart bu elipsoidin örneklemden örnekleme nasıl “sallandığını” tanımlar. $n - 1$ büyük $\Rightarrow$ daha az sallantı.

7 Büyük Sayılar Yasası — “Yeterince Veri Toplarsak”

7.1 Ne Yapıyoruz?

- Şimdiye kadar verinin Gaussian olduğunu varsaydık. Peki ya değilse? Yine de $\bar{X}$ ’e güvenebilir miyiz?
- **BBS cevabı:** Evet. Dağılım ne olursa olsun, $\bar{X}$ gerçek μ ’ya yakınsar.
- **BBS, istatistiğin neden işe yaradığının temelidir.**

7.2 Zayıf BBS (WLLN)

$$\bar{X}_n \xrightarrow{P} \mu \quad (n \rightarrow \infty) \iff P(\|\bar{X}_n - \mu\| > \varepsilon) \rightarrow 0 \quad \forall \varepsilon > 0$$

- **Küçük örnek:** Bir zar atıyorsun. Gerçek ortalama $\mu = 3.5$.
 - 10 atış: $\bar{X}$ belki 3.2, belki 3.9 — dağınık.
 - 100 atış: 3.4 ile 3.6 arasında muhtemelen.
 - 10000 atış: neredeyse kesinlikle 3.5’e çok yakın.
- **Sezgi:** Zar dağılımı Gaussian değil — ama BBS yine de çalışıyor. Dağılım önemli değil.

7.3 Güçlü BBS (SLLN)

$$\bar{X}_n \xrightarrow{a.s.} \mu \quad (n \rightarrow \infty)$$

- Neredeyse her sonsuz veri dizisi için koşan ortalama μ 'ya yakınsar.
- WLLN: “Uzakta olma olasılığı sıfıra gider.” SLLN: “Sonunda sonsuza kadar yakın kalırsın.”
- SLLN $\Rightarrow$ WLLN (daha güçlü), ama WLLN $\nRightarrow$ SLLN.

7.4 Kovaryans İçin BBS

$$S_n \xrightarrow{P} \Sigma \quad (n \rightarrow \infty)$$

- $\bar{X}_n$ ve S_n **tutarlı tahmin edicilerdir**: gerçek parametreye olasılıkla yakınsar.
- **Tutarlılık vs. tarafsızlık**: $\hat{\Sigma}$ sonlu n için taraflı ama tutarlıdır — $n \rightarrow \infty$ için Σ 'ya yakınsar.

8 Merkezi Limit Teoremi — “Hata Ne Şekilde?”

8.1 Ne Yapıyoruz?

- BBS $\bar{X}_n \rightarrow \mu$ diyor. Ama:
 - **Ne kadar hızlı** yaklaşıyor?
 - Hata **nasıl bir şekle** sahip?
- $\bar{X}_n - \mu$ büyük n 'de sıfıra gidiyor. Sıfıra giden bir şeye bakmak anlamsız. **Büyüteç kullanıyoruz**:

$$\sqrt{n}(\bar{X}_n - \mu)$$

Neden $\sqrt{n}$? Çünkü $\text{Var}(\bar{X}_n) = \Sigma/n$ ile küçülüyor; $\sqrt{n}$ ile çarpmak tam olarak dengeler.

8.2 Çok Değişkenli MST

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{d} N_p(0, \Sigma) \quad (n \rightarrow \infty)$$

Büyük n için:

$$\bar{X}_n \sim N_p\left(\mu, \frac{\Sigma}{n}\right)$$

- **Kritik nokta**: Verinin Gaussian olması **gerekmez**. Bernoulli, Poisson, düzgün — fark etmez. Örneklem ortalaması büyük n için her zaman yaklaşık Gaussian olur.
- **Küçük örnek**: Zar atıyorsun. Zarın dağılımı Gaussian değil. Ama 1000 kez zar atıp ortalamasını alırsan, bu ortalama neredeyse Gaussian dağılır.
- **Neden Gaussian her yerde görünür?** Çünkü doğada gördüğümüz şeylerin çoğu birçok küçük etkinin toplamıdır. Ve toplamlar MST yüzünden Gaussian'a yaklaşıp.

- **Kesin sonuçla bağlantı:** Veri Gaussian ise $\bar{X}_n \sim N_p(\mu, \Sigma/n)$ tam olarak tüm n için geçerli. MST bu kesin sonucun herhangi bir dağılım için büyük n 'de *yaklaşık* geçerli olduğunu söyler.

8.3 Yakınsama Hızı

$$\|\bar{X}_n - \mu\| \sim \frac{1}{\sqrt{n}}$$

- Bu $1/\sqrt{n}$ hızı **istatistiksel tahminin temel yasasıdır:**

Hedef	Kaç kat daha fazla veri?
Hatayı yarıya indir	4 kat
Hatayı 10'a böl	100 kat
Hatayı 100'e böl	10.000 kat

8.4 Güven Bölgesi Uygulaması

- Σ biliniyorsa (büyük n , Gaussianlık gerekmez):

$$n(\bar{X}_n - \mu)^\top \Sigma^{-1}(\bar{X}_n - \mu) \sim \chi_p^2$$

- Σ bilinmiyorsa, S ile değiştir:

$$n(\bar{X}_n - \mu)^\top S^{-1}(\bar{X}_n - \mu) \sim \chi_p^2$$

- Güven bölgesi elipsoiddir — Σ küresel değilse bölge de küre değildir.

8.5 Kesin vs. Asimptotik — Tam Karşılaştırma

	Gaussian veri (her n)	Herhangi bir dağılım (büyük n)
$\bar{X}_n$ 'nin dağılımı	Tam olarak $N_p(\mu, \Sigma/n)$	Yaklaşık $N_p(\mu, \Sigma/n)$
$(n-1)S$ 'nin dağılımı	Tam olarak $W_p(n-1, \Sigma)$	Basit kesin form yok
$\bar{X}_n$ ve S	Bağımsız (kesin)	Asimptotik bağımsız
Kaynak	Gaussian kapanma özelliği	MST

- **Sınav kuralı:**
 - “Gaussian dağılımlı veri” $\Rightarrow$ kesin Wishart ve χ^2 sonuçları.
 - “Büyük örneklem” veya “genel dağılım” $\Rightarrow$ MST kullan.
 - Kesin sonuçlar her zaman daha güçlüdür (tüm n için geçerli).

9 Her Şeyi Bir Cümleyle Bağlamak

- Verinin Gaussian dağılımdan geldiğini düşünüyoruz, parametrelerini bilmiyoruz.
- **Açık tahmin** ve **MLE** ile parametreleri tahmin ediyoruz.

- **Değişmezlik** ile başka şeylerin tahminini bedavaya alıyoruz.
- $\bar{X}$ 'in dağılımı ve **Wishart** ile tahminlerimizin ne kadar güvenilir olduğunu tam olarak biliyoruz.
- **BBS** ile dağılım ne olursa olsun tahminlerin doğruya yaklaştığını öğreniyoruz.
- **MST** ile bu yaklaşmanın $1/\sqrt{n}$ hızında ve Gaussian şeklinde olduğunu biliyoruz.
- **Tek sorumuz vardı:** Bilinmeyen parametreleri nasıl tahmin ederiz ve bu tahminlere ne kadar güvenebiliriz? Tüm bu araçlar o tek soruyu yanıtlamak için.