

9 - Inference for a Multivariate Mean:

Case 1: Large Sample Size — Confidence Regions and Tests Based on the Chi-Squared Distribution.

Case 2: Any Sample Size with Gaussian Population — Hotelling's Theorem,
 T^2 Statistic and its F -Distribution.

Applied Statistics

Unat Teksen

March 16, 2026

1 Big Picture — What Are We Trying to Do?

- In univariate statistics, we estimate a scalar mean $\mu \in \mathbb{R}$, build confidence intervals, and run t-tests.
- Now we do **exactly the same**, but in p dimensions: our observations are vectors, our mean is a vector, and our variance is a matrix.
- **Core question:** Given a sample of n vectors, what can we say about the true population mean vector $\mu \in \mathbb{R}^p$?
- The lecture covers two regimes:
 - **Large n** (any population distribution) $\rightarrow$ use the **chi-squared** (χ^2) distribution (approximate).
 - **Small n , Gaussian population** $\rightarrow$ use **Hotelling's T^2** and the **F -distribution** (exact).
- **Key tool in both cases:** The **Mahalanobis distance**

$$T^2 = n(\bar{X} - \mu)'S^{-1}(\bar{X} - \mu)$$

which measures how far the sample mean $\bar{X}$ is from a hypothesized μ , properly accounting for scale and correlation.

2 Setup — Parameters and Estimators

- **Observations:**

$$X_1, \dots, X_n \stackrel{iid}{\sim} (\mu, \Sigma), \quad X_i \in \mathbb{R}^p$$

- Each X_i is a p -dimensional vector drawn independently from the same distribution.

- We do *not* assume normality yet — any distribution with finite mean and covariance works.
- **Unknown parameters:**
 - $\mu \in \mathbb{R}^p$: true population mean vector (unknown, never observed).
 - $\Sigma \in \mathbb{R}^{p \times p}$: true covariance matrix (unknown).
- **Sample mean vector** (unbiased estimator of μ):

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

- **Sample covariance matrix** (unbiased estimator of Σ):

$$S = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})' \xrightarrow{P} \Sigma \quad \text{as } n \rightarrow \infty$$

- We divide by $n-1$ (not n) for unbiasedness.
- S converges in probability to Σ : more data $\Rightarrow$ better estimate.
- **Intuition — Parameter vs. Estimator:**
 - μ is the truth that “God knows” but we don’t.
 - $\bar{X}$ is our best guess. As $n \rightarrow \infty$, $\bar{X} \rightarrow \mu$.

3 The Mahalanobis Distance

- **Definition:** The squared Mahalanobis distance between $\bar{X}$ and μ is:

$$d_S^2(\bar{X}, \mu) = n(\bar{X} - \mu)' S^{-1} (\bar{X} - \mu)$$

- **Why not Euclidean distance?**
 - Euclidean distance treats all directions equally.
 - If variable 1 has variance 100 and variable 2 has variance 1, a deviation of 5 units means completely different things in each direction.
 - S^{-1} *standardizes* the space: it shrinks directions with high variance and stretches directions with low variance.
 - It also accounts for correlations between variables.
- **Analogy to the univariate case:**
 - In $p = 1$: the standardized quantity is $z = \frac{\bar{X} - \mu}{\sigma/\sqrt{n}}$, so $z^2 = n(\bar{X} - \mu)(\sigma^2)^{-1}(\bar{X} - \mu) \sim \chi^2(1)$.
 - T^2 is the exact multivariate generalization: a scalar “distance score” that follows a known distribution.

4 Case 1: Large n — Chi-Squared Approximation

4.1 Multivariate Central Limit Theorem

- **Assumption:** n is large.
- By the **Multivariate CLT**:

$$\sqrt{n}(\bar{X} - \mu) \xrightarrow{d} N_p(\mathbf{0}, \Sigma) \quad \text{as } n \rightarrow \infty$$

- **Approximate distribution of $\bar{X}$:**

$$\bar{X} \sim N_p\left(\mu, \frac{1}{n}\Sigma\right)$$

- No distributional assumption on X_i needed — CLT handles it.
- As n grows, the covariance Σ/n shrinks: tighter concentration around μ .

4.2 Pivotal Quantity

- **Definition — Pivotal Quantity:** A function of the data and the parameter whose *distribution* does not depend on any unknown parameters.
- Since $\sqrt{n}(\bar{X} - \mu) \approx N_p(0, \Sigma)$ and using the result $Z \sim N_p(0, \Sigma) \Rightarrow Z'\Sigma^{-1}Z \sim \chi^2(p)$:

$$n(\bar{X} - \mu)'\Sigma^{-1}(\bar{X} - \mu) \sim \chi^2(p)$$

- Since Σ is unknown, replace with S (justified by $S \xrightarrow{P} \Sigma$ and Slutsky's theorem):

$$T^2 = n(\bar{X} - \mu)'S^{-1}(\bar{X} - \mu) \sim \chi^2(p)$$

- **Why $\chi^2(p)$?** It is the sum of p squared independent standard normals. S^{-1} “rotates and scales” the multivariate normal into p independent standard normals; squaring and summing gives $\chi^2(p)$.
- The distribution of T^2 does not depend on the unknown μ or Σ — this is what makes it pivotal.

4.3 Confidence Region

- Fix $\alpha \in (0, 1)$ (e.g. $\alpha = 0.05$). From the pivotal quantity:

$$P[n(\bar{X} - \mu)'S^{-1}(\bar{X} - \mu) \leq \chi_{1-\alpha}^2(p)] = 1 - \alpha$$

- **Definition — $\chi_{1-\alpha}^2(p)$:** The $(1 - \alpha)$ quantile of the $\chi^2(p)$ distribution. The cutoff such that area $1 - \alpha$ lies to the left and area α in the right tail.

- The **$(1 - \alpha)$ confidence region** for μ :

$$CR_{1-\alpha}(\mu) = \{\eta \in \mathbb{R}^p : n(\eta - \bar{X})'S^{-1}(\eta - \bar{X}) \leq \chi_{1-\alpha}^2(p)\}$$

- This is an **ellipsoid** centered at $\bar{X}$, shaped by S^{-1} .

- **Geometric intuition:**

- $p = 2$: an ellipse in the plane. If $S = I \Rightarrow$ circle. If $S_{12} \neq 0 \Rightarrow$ tilted ellipse.
- The ellipse is tilted in the direction of correlation: if height and weight are positively correlated, the ellipse tilts at 45° .

4.4 Duality: Test $\Leftrightarrow$ Confidence Region

- A key equivalence:

$$\bar{X} \in \mathcal{E}_{\chi^2_{1-\alpha}(p)}(\mu) \iff \mu \in \mathcal{E}_{\chi^2_{1-\alpha}(p)}(\bar{X})$$

- **Coverage guarantee:**

$$P[\mu \in CR_{1-\alpha}(\bar{X})] = 1 - \alpha$$

- **Interpretation:** $CR_{1-\alpha}$ is the set of all μ_0 values for which we *cannot* reject $H_0 : \mu = \mu_0$ at level α .

4.5 Hypothesis Test

- **Hypotheses:**

$$H_0 : \mu = \mu_0 \quad (\text{known}) \quad \text{vs} \quad H_1 : \mu \neq \mu_0$$

- H_0 is the “skeptic’s position” — assumed true until evidence forces us to reject it.

- **Test statistic:**

$$T_0^2 = n(\bar{X} - \mu_0)'S^{-1}(\bar{X} - \mu_0)$$

- **Under H_0 :** $T_0^2 \sim \chi^2(p)$.

- **Decision rule:** Reject H_0 if $T_0^2 > \chi^2_{1-\alpha}(p)$.

- **Why right tail only?** $T_0^2 \geq 0$ always. Large values $\Rightarrow \bar{X}$ is far from $\mu_0 \Rightarrow$ evidence against H_0 .

- **p-value:**

$$\text{p-value} = P[\chi^2(p) \geq T_0^2]$$

Reject H_0 if p-value $< \alpha$.

- **Duality:**

$$\text{Reject } H_0 : \mu = \mu_0 \iff \mu_0 \notin CR_{1-\alpha}(\bar{X})$$

5 Case 2: Small n , Gaussian Population — Hotelling’s T^2

5.1 Motivation and Setup

- **New assumption:** $X_1, \dots, X_n \stackrel{iid}{\sim} N_p(\mu, \Sigma)$.

- For small n , S is a noisy estimate of Σ . The error in S cannot be ignored.

- **Analogy:**

- Univariate, σ known $\Rightarrow$ use Z -test ($N(0, 1)$).
- Univariate, σ unknown $\Rightarrow$ use t -test ($t(n-1)$).
- Multivariate, Σ unknown, small $n \Rightarrow$ use Hotelling’s T^2 (F -distribution).

- Under the Gaussian assumption, we can derive the **exact** distribution of T^2 — no approximation needed.

5.2 The F -Distribution

- **Definition:** If $Y \sim \chi^2(n)$ and $W \sim \chi^2(m)$ are independent, then:

$$F = \frac{Y/n}{W/m} \sim F(n, m)$$

- The F -distribution is a ratio of two chi-squared random variables, each scaled by their degrees of freedom.
- **Connection to the t -distribution:** If $t \sim t(m)$, then $t^2 \sim F(1, m)$:

$$t = \frac{Z}{\sqrt{W/m}} \implies t^2 = \frac{Z^2/1}{W/m} = \frac{\chi^2(1)/1}{\chi^2(m)/m} \sim F(1, m)$$

- **What happens as $m \rightarrow \infty$?** By the Law of Large Numbers, $W/m \rightarrow 1$, so:

$$F(n, m) \xrightarrow{m \rightarrow \infty} \frac{1}{n} \chi^2(n)$$

This shows that the F and χ^2 cases are consistent: as $n \rightarrow \infty$, the exact Hotelling result recovers the large- n approximate result.

5.3 Hotelling's Theorem (1931)

- **Key independence fact:** Under the Gaussian model, $\bar{X}$ and S are **independent**. (Special property of the normal distribution, analogous to the univariate fact that $\bar{X} \perp S^2$.)
- **Hotelling's Theorem:** If $X_1, \dots, X_n \stackrel{iid}{\sim} N_p(\mu, \Sigma)$, then *exactly*:

$$T^2 = n(\bar{X} - \mu)' S^{-1} (\bar{X} - \mu) \sim \frac{(n-1)p}{n-p} F(p, n-p)$$

Equivalently:

$$\frac{n-p}{(n-1)p} T^2 \sim F(p, n-p)$$

- This is an **exact** result, valid for any $n > p$.
- **Why F instead of χ^2 ?**
 - Large n : $S \approx \Sigma$, estimation error in S is negligible $\Rightarrow \chi^2$.
 - Small n : S is random and contributes extra variability $\Rightarrow F$ (heavier tails than χ^2 , more conservative).
 - As $n \rightarrow \infty$: $F(p, n-p) \rightarrow \chi^2(p)/p$, so $T^2 \rightarrow \chi^2(p)$.
- **Hotelling's T^2 is the multivariate generalization of the (squared) t -test.**

5.4 Exact Confidence Region

- From Hotelling's theorem:

$$P\left[n(\bar{X} - \mu)'S^{-1}(\bar{X} - \mu) \leq \frac{(n-1)p}{n-p}F_{1-\alpha}(p, n-p)\right] = 1 - \alpha$$

- **Exact $(1 - \alpha)$ confidence region:**

$$CR_{1-\alpha}(\mu) = \left\{ \eta \in \mathbb{R}^p : n(\eta - \bar{X})'S^{-1}(\eta - \bar{X}) \leq \frac{(n-1)p}{n-p}F_{1-\alpha}(p, n-p) \right\}$$

- Still an **ellipsoid** centered at $\bar{X}$, but with a **larger cutoff** than the χ^2 case.
- **Why larger?** Less data $\Rightarrow$ more uncertainty $\Rightarrow$ wider region to maintain the same $1 - \alpha$ coverage.

5.5 Exact Hypothesis Test

- **Setup:** $X_1, \dots, X_n \stackrel{iid}{\sim} N_p(\mu, \Sigma)$, test $H_0 : \mu = \mu_0$ vs $H_1 : \mu \neq \mu_0$.
- **Test statistic:**

$$T_0^2 = n(\bar{X} - \mu_0)'S^{-1}(\bar{X} - \mu_0)$$

- **Under H_0 exactly:** $T_0^2 \sim \frac{(n-1)p}{n-p}F(p, n-p)$.
- **Decision rule:** Reject H_0 if:

$$T_0^2 > \frac{(n-1)p}{n-p}F_{1-\alpha}(p, n-p)$$

(equivalently: $\mu_0 \notin CR_{1-\alpha}(\mu)$).

- **p-value:** Area to the right of $\frac{n-p}{(n-1)p}T_0^2$ under the $F(p, n-p)$ density.

5.6 Comparison of the Two Cases

	Large n (any distribution)	Small n (Gaussian)
Assumption	iid, any F , n large	$X_i \sim N_p(\mu, \Sigma)$
Result	Approximate	Exact
T^2 distribution	$\chi^2(p)$	$\frac{(n-1)p}{n-p}F(p, n-p)$
Cutoff	$\chi_{1-\alpha}^2(p)$	$\frac{(n-1)p}{n-p}F_{1-\alpha}(p, n-p)$
Region size	Smaller	Larger (more conservative)
1D analogy	Z -test	t -test

6 Numerical Example

6.1 Example A: $S = I$ (No Correlation)

- **Data:** $n = 10, p = 2, \alpha = 0.1$.

$$\bar{X} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \quad S = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = I \implies S^{-1} = I$$

- **F quantile:** $F_{0.9}(2, 8) = 3.11$.
- **Threshold:**

$$\frac{(n-1)p}{n-p} F_{0.9}(2, 8) = \frac{9 \times 2}{8} \times 3.11 = \frac{18}{8} \times 3.11 \approx 6.997$$

- **Confidence region:**

$$CR_{0.9}(\mu) = \{\eta \in \mathbb{R}^2 : 10(\eta_1^2 + \eta_2^2) \leq 6.997\} = \{\eta : \eta_1^2 + \eta_2^2 \leq 0.6997\}$$

- **Shape:** A **circle** centered at the origin with radius $\sqrt{0.6997} \approx 0.8365$.
- Since $S = I$ (no correlation, equal variances), the ellipsoid is perfectly round.

6.2 Example B: S with Correlation

- **Data:** Same setup but:

$$S = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix} \implies S^{-1} = \begin{pmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{pmatrix}$$

- **Confidence region:**

$$CR_{0.9}(\mu) = \left\{ \eta \in \mathbb{R}^2 : \frac{4}{3}\eta_1^2 - \frac{4}{3}\eta_1\eta_2 + \frac{4}{3}\eta_2^2 \leq 0.6997 \right\}$$

- **Shape:** A **tilted ellipse**. The cross-term $-\frac{4}{3}\eta_1\eta_2$ causes the 45° tilt.
- Positive correlation $\Rightarrow$ the ellipse is elongated along the $(+, +)$ diagonal: both variables tend to deviate together.

7 Joint Confidence Region vs. Marginal Intervals

- **Marginal (componentwise) confidence intervals** for each μ_j separately (univariate t -intervals):

$$CI_{1-\alpha}(\mu_j) = \left[\bar{X}_j \pm t_{1-\alpha/2}(n-1) \sqrt{\frac{S_{jj}}{n}} \right]$$

- **For Example A** ($\bar{X} = \mathbf{0}$, $S = I$, $n = 10$, $\alpha = 0.1$): $t_{0.95}(9) \approx 1.833$, so:

$$CI_{0.9}(\mu_1) = CI_{0.9}(\mu_2) = \left[\pm 1.833 \times \frac{1}{\sqrt{10}} \right] = [\pm 0.5796]$$

These two intervals form a **square/rectangle** in $\mathbb{R}^2$.

- **Critical difference: Ellipse $\neq$ Rectangle.**
 - Some points are *inside the rectangle but outside the ellipse*: jointly implausible even though each coordinate looks fine individually.
 - Some points are *inside the ellipse but outside the rectangle*.
 - The rectangle ignores correlation; the ellipse encodes it through S^{-1} .
- **The multiple testing problem:**
 - Performing p separate tests each at level α does *not* control the joint error rate at α .
 - With $p = 100$ tests at $\alpha = 0.05$ each, the overall false rejection probability is far larger than 5%.
 - The joint ellipsoidal region controls the probability of all errors simultaneously.
- **Rule:** If you want to make a **joint** statement about $\mu = (\mu_1, \dots, \mu_p)$, use the **joint confidence region** (ellipsoid). Marginal intervals are only valid for separate univariate statements.

8 Key Intuitions Summary

- **T^2 is a distance.** It measures how far $\bar{X}$ is from a hypothesized μ_0 , in units adjusted for covariance. Large $T^2 \Rightarrow$ evidence against H_0 .
- **The confidence region is always an ellipsoid.** Its shape is determined by S^{-1} . Equal variances, no correlation $\Rightarrow$ sphere. Correlation $\Rightarrow$ tilted ellipsoid.
- **Test $\leftrightarrow$ confidence region duality.** Reject $H_0 : \mu = \mu_0 \iff \mu_0$ is outside the confidence ellipsoid.
- **Large $n \Rightarrow \chi^2$; small n Gaussian $\Rightarrow F$.** The difference: whether estimation error in S is negligible or not.
- **F -region is larger.** Extra uncertainty from estimating $\Sigma \Rightarrow$ more conservative (wider) region.
- **Never replace the ellipsoid with p separate intervals.** They do not have the same coverage and they ignore correlation.
- **As $n \rightarrow \infty$:** $F(p, n-p) \rightarrow \chi^2(p)/p$, so $T^2 \rightarrow \chi^2(p)$. Both cases are consistent.

Türkçe Açıklamalar

B1. Büyük Resim — Ne Yapmaya Çalışıyoruz?

- Tek değişkenli istatistikte skaler bir ortalama $\mu \in \mathbb{R}$ tahmin ediyorduk, güven aralıkları kuruyorduk, t-testleri yapıyorduk.
- Şimdi **tamamen aynı şeyi** p boyutta yapıyoruz: gözlemler vektör, ortalama vektör, varyans matrisi.
- **Temel soru:** n vektörlük bir örneklemden, gerçek popülasyon ortalama vektörü $\mu \in \mathbb{R}^p$ hakkında ne söyleyebiliriz?
- Dersin ele aldığı iki durum:
 - **Büyük n** (herhangi bir dağılım) $\rightarrow$ **ki-kare** (χ^2) dağılımı (yaklaşık).
 - **Küçük n , Gaussian popülasyon** $\rightarrow$ **Hotelling T^2 ve F -dağılımı** (tam/kesin).
- **Her iki durumda da temel araç: Mahalanobis uzaklığı**

$$T^2 = n(\bar{X} - \mu)' S^{-1} (\bar{X} - \mu)$$

Bu, örneklem ortalaması $\bar{X}$ 'in, varsayılan μ 'ya ne kadar uzak olduğunu ölçer; ölçek ve korelasyon düzgün biçimde hesaba katılır.

B2. Kurulum — Parametreler ve Tahmin Ediciler

- **Gözlemler:**

$$X_1, \dots, X_n \stackrel{iid}{\sim} (\mu, \Sigma), \quad X_i \in \mathbb{R}^p$$
 - Her X_i aynı dağılımdan bağımsız çekilmiş p -boyutlu bir vektördür.
 - Henüz normallik varsayımına ihtiyaç yok — sonlu ortalama ve kovaryans yeterli.
- **Bilinmeyen parametreler:**
 - $\mu \in \mathbb{R}^p$: gerçek popülasyon ortalama vektörü (bilinmiyor, hiç gözlemlenmiyor).
 - $\Sigma \in \mathbb{R}^{p \times p}$: gerçek kovaryans matrisi (bilinmiyor).
- **Örneklem ortalama vektörü** (μ 'nun yansız tahmincisi):

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

- **Örneklem kovaryans matrisi** (Σ 'nın yansız tahmincisi):

$$S = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})(X_i - \bar{X})' \xrightarrow{P} \Sigma$$

- $n-1$ ile bölünür (yansızlık için).
- n büyüdükçe S , Σ 'ya yakınsıyor: daha fazla veri $\Rightarrow$ daha iyi tahmin.

- **Sezgi — Parametre vs. Tahmin Edici:**

- μ gerçek değerdir, “Tanrının bildiği” ama bizim bilmediğimiz.
- $\bar{X}$ bizim en iyi tahminimiz. $n \rightarrow \infty$ oldukça $\bar{X} \rightarrow \mu$.

B3. Mahalanobis Uzaklığı

- **Tanım:** $\bar{X}$ ile μ arasındaki karesel Mahalanobis uzaklığı:

$$d_S^2(\bar{X}, \mu) = n(\bar{X} - \mu)'S^{-1}(\bar{X} - \mu)$$

- **Neden Öklid uzaklığı kullanmıyoruz?**

- Öklid uzaklığı tüm yönleri eşit muamele eder.
- Değişken 1’in varyansı 100, değişken 2’ninki 1 ise; her yönde 5 birim sapma tamamen farklı anlama gelir.
- S^{-1} uzayı *standartlaştırır*: yüksek varyanslı yönleri küçültür, düşük varyanslı yönleri büyütür. Değişkenler arası korelasyonu da hesaba katar.

- **Tek değişkenli durumla analoji:**

- $p = 1$ ’de: $z = (\bar{X} - \mu)/(\sigma/\sqrt{n})$, dolayısıyla $z^2 \sim \chi^2(1)$.
- T^2 bunun tam çok boyutlu genellemesidir: bilinen bir dağılımı olan skaler bir “uzaklık skoru.”

B4. Durum 1: Büyük n — Ki-Kare Yaklaşımı

- **Varsayım:** n büyük.
- **Çok Değişkenli Merkezi Limit Teoremi:**

$$\sqrt{n}(\bar{X} - \mu) \xrightarrow{d} N_p(\mathbf{0}, \Sigma)$$

- $\bar{X}$ ’in yaklaşık dağılımı:

$$\bar{X} \sim N_p\left(\mu, \frac{1}{n}\Sigma\right)$$

- X_i için dağılım varsayımı gerekmez — MLT halleder.
- n büyüdükçe Σ/n küçülür: μ etrafında daha sıkı yoğunlaşma.

- **Pivotal Büyüklük (Eksen Değişmez Nicelik):**

- **Tanım:** Değeri parametreye bağlı olan ama dağılımı bilinmeyen parametrelere bağlı olmayan veri fonksiyonu.

$$T^2 = n(\bar{X} - \mu)'S^{-1}(\bar{X} - \mu) \sim \chi^2(p)$$

- **Neden $\chi^2(p)$?** p bağımsız standart normalin karelerinin toplamıdır. S^{-1} , çok değişkenli normali p bağımsız standart normale dönüştürür; karelerin toplamı $\chi^2(p)$ verir.

- **(1 - α) Güven Bölgesi:**

$$CR_{1-\alpha}(\mu) = \{\eta \in \mathbb{R}^p : n(\eta - \bar{X})'S^{-1}(\eta - \bar{X}) \leq \chi_{1-\alpha}^2(p)\}$$

- $\bar{X}$ merkezli, S^{-1} tarafından şekillendirilmiş bir **elipsoid**.
- $p = 2$: $S = I \Rightarrow$ daire; $S_{12} \neq 0 \Rightarrow$ eğik elips.
- Pozitif korelasyon, elipsi 45° döndürür.

- **Hipotez Testi:**

$$H_0 : \mu = \mu_0 \quad \text{vs} \quad H_1 : \mu \neq \mu_0$$

$$T_0^2 = n(\bar{X} - \mu_0)'S^{-1}(\bar{X} - \mu_0) \sim \chi^2(p) \quad (H_0 \text{ altında})$$

$T_0^2 > \chi_{1-\alpha}^2(p)$ ise H_0 'ı reddet.

- **p-değeri:**

$$\text{p-değeri} = P[\chi^2(p) \geq T_0^2]$$

p-değeri < α ise reddet. p-değeri = 0.001 $\Rightarrow H_0$ doğruysa bu sonucu görme şansı binde bir $\Rightarrow$ reddet!

- **Dualite:**

$$H_0 : \mu = \mu_0 \text{ reddedilir} \iff \mu_0 \notin CR_{1-\alpha}(\bar{X})$$

B5. Durum 2: Küçük n , Gaussian Popülasyon — Hotelling T^2

- **Yeni varsayım:** $X_1, \dots, X_n \stackrel{iid}{\sim} N_p(\mu, \Sigma)$.
- Küçük n 'de S gürültülüdür. S 'deki hata göz ardı edilemez.

- **Analoji:**

- Tek boyutlu, σ biliniyor $\Rightarrow Z$ -testi.
- Tek boyutlu, σ bilinmiyor $\Rightarrow t$ -testi.
- Çok boyutlu, Σ bilinmiyor, küçük $n \Rightarrow$ Hotelling T^2 (F -dağılımı).

- **F -Dağılımı:** $Y \sim \chi^2(n)$ ve $W \sim \chi^2(m)$ bağımsız ise:

$$F = \frac{Y/n}{W/m} \sim F(n, m)$$

- $m \rightarrow \infty$ iken $W/m \rightarrow 1$ (Büyük Sayılar Kanunu), dolayısıyla:

$$F(n, m) \xrightarrow{m \rightarrow \infty} \frac{1}{n} \chi^2(n)$$

$n \rightarrow \infty$ iken iki durum tutarlı biçimde birleşir.

- **Hotelling Teoremi (1931):**

- Gaussian model altında $\bar{X}$ ve S **bağımsızdır** (normalin özel özelliği).
- *Tam olarak* (yaklaşık değil):

$$T^2 = n(\bar{X} - \mu)'S^{-1}(\bar{X} - \mu) \sim \frac{(n-1)p}{n-p} F(p, n-p)$$

- $n > p$ olan her n için geçerlidir.
- **Neden F , χ^2 değil?** Büyük n 'de $S \approx \Sigma \Rightarrow \chi^2$. Küçük n 'de S rastgeledir, ekstra değişkenlik katar $\Rightarrow F$ (daha ağır kuyruklar, daha muhafazakâr).
- $n \rightarrow \infty$ iken $F(p, n-p) \rightarrow \chi^2(p)/p$, yani $T^2 \rightarrow \chi^2(p)$.

- **Tam $(1 - \alpha)$ Güven Bölgesi:**

$$CR_{1-\alpha}(\mu) = \left\{ \eta \in \mathbb{R}^p : n(\eta - \bar{X})'S^{-1}(\eta - \bar{X}) \leq \frac{(n-1)p}{n-p} F_{1-\alpha}(p, n-p) \right\}$$

- Hâlâ $\bar{X}$ merkezli bir **elipsoid**, ancak χ^2 durumuna göre **daha büyük eşik**.
- Daha az veri $\Rightarrow$ daha fazla belirsizlik $\Rightarrow$ aynı $1 - \alpha$ güvenceyi korumak için daha geniş bölge.

- **Tam Hipotez Testi:**

$$H_0 : \mu = \mu_0 \text{ reddedilir} \iff T_0^2 > \frac{(n-1)p}{n-p} F_{1-\alpha}(p, n-p)$$

(eşdeğer olarak: $\mu_0 \notin CR_{1-\alpha}(\mu)$)

- **İki Durumun Karşılaştırması:**

	Büyük n (herhangi dağılım)	Küçük n (Gaussian)
Varsayım	iid, herhangi F , büyük n	$X_i \sim N_p(\mu, \Sigma)$
Sonuç	Yaklaşık	Tam
T^2 dağılımı	$\chi^2(p)$	$\frac{(n-1)p}{n-p} F(p, n-p)$
Eşik	$\chi_{1-\alpha}^2(p)$	$\frac{(n-1)p}{n-p} F_{1-\alpha}(p, n-p)$
Bölge boyutu	Küçük	Büyük (daha muhafazakâr)
1B analoji	Z -testi	t -testi

B6. Sayısal Örnek

Örnek A: $S = I$ (Korelasyon Yok)

- **Veri:** $n = 10, p = 2, \alpha = 0.1$.

$$\bar{X} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}, \quad S = I \implies S^{-1} = I$$

- $F_{0.9}(2, 8) = 3.11$ (tablodan).

- Eşik:

$$\frac{9 \times 2}{8} \times 3.11 \approx 6.997$$

- Güven bölgesi:

$$CR_{0.9}(\mu) = \{ \eta : \eta_1^2 + \eta_2^2 \leq 0.6997 \}$$

- **Şekil:** Merkezi orijin, yarıçapı $\sqrt{0.6997} \approx 0.8365$ olan bir **daire**.
- $S = I$ (korelasyon yok, eşit varyanslar) $\Rightarrow$ elipsoid tamamen yuvarlak.

Örnek B: S 'de Korelasyon Var

-

$$S = \begin{pmatrix} 1 & 0.5 \\ 0.5 & 1 \end{pmatrix} \implies S^{-1} = \begin{pmatrix} 4/3 & -2/3 \\ -2/3 & 4/3 \end{pmatrix}$$

- Güven bölgesi:

$$CR_{0.9}(\mu) = \left\{ \eta : \frac{4}{3}\eta_1^2 - \frac{4}{3}\eta_1\eta_2 + \frac{4}{3}\eta_2^2 \leq 0.6997 \right\}$$

- **Şekil: Eğik elips.** Çapraz terim $-\frac{4}{3}\eta_1\eta_2$ 45° eğime neden olur.
- Pozitif korelasyon $\Rightarrow$ elips $(+, +)$ köşegeni boyunca uzar.

B7. Ortak Güven Bölgesi ile Ayrı Ayrı Aralıkların Karşılaştırılması

- **Marjinal (bileşen bazlı) güven aralıkları** her μ_j için ayrı ayrı:

$$CI_{1-\alpha}(\mu_j) = \left[\bar{X}_j \pm t_{1-\alpha/2}(n-1) \sqrt{\frac{S_{jj}}{n}} \right]$$

- **Örnek A için** ($n = 10$, $S = I$, $\alpha = 0.1$): $t_{0.95}(9) \approx 1.833$:

$$CI_{0.9}(\mu_1) = CI_{0.9}(\mu_2) = [\pm 0.5796]$$

Bu iki aralık $\mathbb{R}^2$ 'de bir **dikdörtgen/kare** oluşturur.

- **Kritik fark: Elips $\neq$ Dikdörtgen.**

- Dikdörtgenin içinde ama elipsin dışında olan noktalar var: her koordinat tek tek makul görünse de birlikte imkânsız.
- Elipsin içinde ama dikdörtgenin dışında olan noktalar var.
- Dikdörtgen korelasyonu yok sayar; elips S^{-1} aracılığıyla onu kodlar.

- **Çoklu test problemi:**

- Her biri α düzeyinde p ayrı test yapmak, birleşik hata oranını α 'da tutmaz.
- $p = 100$ test, her biri $\alpha = 0.05$ düzeyinde $\Rightarrow$ toplam yanlış red olasılığı çok daha büyük.
- Ortak elipsoid bölge, tüm hataların olasılığını eş zamanlı kontrol eder.

- **Kural:** $\mu = (\mu_1, \dots, \mu_p)$ hakkında **ortak** bir yorum yapmak istiyorsan $\Rightarrow$ **ortak güven bölgesi** (elipsoid) kullan. Marjinal aralıklar yalnızca ayrı tek değişkenli açıklamalar için geçerlidir.

B8. Temel Sezgiler Özeti

- **T^2 bir uzaklıktır.** $\bar{X}$ 'in varsayılan μ_0 'a ne kadar uzak olduğunu kovaryansa göre düzeltilmiş birimlerle ölçer. Büyük $T^2 \Rightarrow H_0$ 'a karşı kanıt.
- **Güven bölgesi her zaman bir elipsoiddir.** Şekli S^{-1} tarafından belirlenir. Eşit varyans, korelasyon yok $\Rightarrow$ küre. Korelasyon $\Rightarrow$ eğik elipsoid.
- **Test $\leftrightarrow$ güven bölgesi dualitesi.** $H_0 : \mu = \mu_0$ 'ı reddet $\iff \mu_0$ güven elipsoidi dışında.
- **Büyük $n \Rightarrow \chi^2$; küçük n Gaussian $\Rightarrow F$.** Fark: S 'deki tahmin hatasının ihmal edilip edilemeyeceği.
- **F -bölgesi daha büyüktür.** Σ 'yı tahmin etmekten kaynaklanan ekstra belirsizlik $\Rightarrow$ daha geniş (muhafazakâr) bölge.
- **Elipsoidi p ayrı aralıkla asla değiştirme.** Aynı kapsama sahip değerler ve korelasyonu görmezden geliyorlar.
- **$n \rightarrow \infty$ iken:** $F(p, n-p) \rightarrow \chi^2(p)/p$, dolayısıyla $T^2 \rightarrow \chi^2(p)$. İki durum tutarlı.