

11 - Large Scale Hypothesis Testing:

Family Wise Error Rate and the Bonferroni Strategy.
False Discovery Rate and the Benjamini–Hochberg Strategy.
Efron’s Strategy. Inference for Multivariate Means.
The Case of Paired Data.

Applied Statistics

Unat Teksen

March 20, 2026

1 Big Picture — Why Large Scale Testing?

- In classical statistics, you test **one hypothesis** at a time (e.g. “does this drug lower blood pressure?”).
- In modern science (genomics, neuroimaging, finance), you test **hundreds or thousands** of hypotheses simultaneously.
- **The problem:** Even if none of the hypotheses are truly significant, testing $k = 1000$ hypotheses at level $\alpha = 0.05$ produces approximately 50 **false alarms** purely by chance.
- **Goal:** Develop methods that control the number/proportion of false alarms when testing many hypotheses simultaneously.
- Two main criteria emerge:
 - **FWER** (Family-Wise Error Rate): probability of making *at least one* false discovery.
 - **FDR** (False Discovery Rate): expected *proportion* of false discoveries among all discoveries.

2 Setup — The Multiple Testing Framework

- Fix k hypotheses to test simultaneously. Data:

$$X_1, \dots, X_n \stackrel{iid}{\sim} N_p(\mu, \Sigma)$$

- For each $i = 1, \dots, k$, test:

$$H_{0i} : a_i' \mu = d_{0i} \quad \text{vs} \quad H_{1i} : a_i' \mu \neq d_{0i}$$

- The **test statistic** for each test i :

$$t_{0i} = \frac{a'_i \bar{X} - d_{0i}}{\sqrt{a'_i S a_i}} \cdot \sqrt{n}$$

- **Reject** H_{0i} if $|t_{0i}| > t_{1-\alpha/2}(n-1)$.
- **Type I Error:**

$$\mathbb{P}[\text{Type I error}] = \mathbb{P}[\text{reject } H_0 \mid H_0 \text{ is true}] = \alpha$$

- This is fine for a single test. But with k simultaneous tests this rate is no longer controlled.

3 The Decision Table

- When running k tests simultaneously, outcomes fall into a 2×2 table:

	Not Reject H_0	Reject H_0	Total
H_0 true	U	V (false discoveries)	k_0
H_1 true	T (missed)	S (true discoveries)	$k - k_0$
Total		R	k

- V = **false discoveries** (rejected a true null) — bad.
- S = **true discoveries** (rejected a false null) — good.
- $R = V + S$ = total number of rejections (observable).
- k_0 = number of truly null hypotheses (unknown in practice).
- **Key challenge:** V and S are individually unobservable; only R is known.

4 Family-Wise Error Rate (FWER) and the Bonferroni Strategy

4.1 Definition of FWER

- **Definition:**

$$\text{FWER} = \mathbb{P}[V \geq 1] = \mathbb{P}[\text{at least one false discovery}]$$

- Very strict criterion: we want the probability of *any* mistake to be small.
- **Intuition:** Testing 1 000 true nulls at $\alpha = 0.05$ yields ≈ 50 false rejections by chance alone. FWER controls the probability that this happens at all.

4.2 Bonferroni's Strategy

- **Idea:** Fix $\alpha \in (0, 1)$. Test each H_{0i} at level α/k instead of α .
- **Rejection rule:** Reject H_{0i} if $|t_{0i}| > t_{1-\alpha/(2k)}(n-1)$.
- **Theorem:** Bonferroni's strategy controls FWER at level α .
- **Proof:** Let I_0 = set of true null indices, $|I_0| = k_0$. Then:

$$\text{FWER} = \mathbb{P} \left[\bigcup_{i \in I_0} \{\text{Reject } H_{0i}\} \mid \bigcap_{i \in I_0} H_{0i} \text{ true} \right] \leq \sum_{i \in I_0} \frac{\alpha}{k} = k_0 \cdot \frac{\alpha}{k} \leq \alpha$$

- **Problem:** Bonferroni is very conservative. With $k = 10\,000$ tests, each is tested at 5×10^{-6} . Many true effects are missed (high Type II error).
- **Analogy:** Like a judge requiring 1000 witnesses before convicting: no innocent person is convicted, but many guilty ones go free.

5 False Discovery Rate (FDR)

5.1 Motivation

- FWER asks: "Did I make *any* mistake?"
- FDR asks: "What *fraction* of my discoveries are mistakes?"
- Allowing a small fraction of errors while finding many true effects is a reasonable trade-off in large-scale science.

5.2 Definition of FDR

- Define the **false discovery proportion**:

$$Q = \begin{cases} 0 & \text{if } R = 0 \\ \frac{V}{R} & \text{if } R > 0 \end{cases}$$

- **Definition (FDR):**

$$\text{FDR} = \mathbb{E}[Q]$$

- **Example:** You reject 100 hypotheses, 5 are false alarms. Then $Q = 5/100 = 5\%$. FDR controls this expected proportion.

5.3 $\text{FDR} \leq \text{FWER}$

- **Case 1:** $k = k_0$ (all nulls true). Then $S = 0$, $V = R$, so $Q = \mathbf{1}[V > 0]$ and $\text{FDR} = \text{FWER}$.
- **Case 2:** $k - k_0 > 0$ (some true alternatives). Then $Q \leq \mathbf{1}[V > 0]$, so $\text{FDR} \leq \text{FWER}$.

- **Key result:**

$$\boxed{\text{FDR} \leq \text{FWER}}$$

- Controlling FDR is **less conservative** $\Rightarrow$ more power to detect true effects.

6 The Benjamini–Hochberg (BH) Procedure

6.1 Setup

- Compute p-value p_i for each test $i = 1, \dots, k$.
- Order: $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(k)}$.
- Hypothesis associated with $p_{(i)}$ is $H_{0(i)}$.

6.2 The BH Algorithm

- Fix $\alpha \in (0, 1)$. Find:

$$\hat{m} = \max \left\{ i \in \{1, \dots, k\} : p_{(i)} \leq \frac{i}{k} \alpha \right\}$$

- **Reject** $H_{0(i)}$ for all $i \leq \hat{m}$.
- **Theorem (Benjamini & Hochberg, 1995):** If p-values are independent, this controls FDR at level α .

6.3 Intuition

- Bonferroni: **flat threshold** α/k for every test.
- BH: **increasing threshold** $\frac{i}{k}\alpha$ — the further along the ranking, the higher the bar.
- **Graphical view:** Plot $p_{(i)}$ vs. rank i . Draw the line $y = \frac{i}{k}\alpha$. Find the *last* point below the line. Reject everything up to and including that point.
- BH is far more generous than Bonferroni for large k .

7 Efron's Strategy (2010)

- Provides a **Bayesian justification** for controlling FDR.
- **Idea:** Each null is true with prior probability π_0 , false with $1 - \pi_0$.
- $\text{FDR} \approx$ posterior probability that a rejected hypothesis is truly null.
- Controlling $\text{FDR} \leq \alpha$: among all discoveries, at most $\alpha \times 100\%$ are expected to be wrong.
- Leads to **strong (Bayesian) control of FDR**.
- BH implicitly estimates π_0 from data; Efron makes this explicit.

8 Dependent P-values — Benjamini & Yekutieli (2001)

- BH assumes **independent** p-values. In practice tests are often correlated (e.g. genes in the same biological pathway).
- **Result:**
 - **Positively correlated** p-values $\Rightarrow$ original BH still controls FDR. ✓
 - **Negatively correlated** p-values $\Rightarrow$ modify the threshold.
- Define:

$$C(k) = \sum_{j=1}^k \frac{1}{j} \approx \ln(k)$$

- **Modified threshold:**

$$\hat{m} = \max \left\{ i : p_{(i)} \leq \frac{i}{k \cdot C(k)} \alpha \right\}$$

- For $k = 1000$: $C(1000) \approx 7.5$, so the threshold is $\approx 7.5\times$ smaller than standard BH.

9 Inference for Multivariate Means — Paired Data

9.1 Setup

- n independent units, each observed **twice** (e.g. before/after treatment).
- Unit i : two p -dimensional vectors $X_{1i}, X_{2i} \in \mathbb{R}^p$.
- Units are independent; within a unit X_{1i} and X_{2i} are **correlated**.
- **Goal:** Infer $\delta = \mu_1 - \mu_2$; test $\mu_1 = \mu_2$.

9.2 Reduction to a One-Sample Problem

- **Key trick:** Form difference vectors $D_i = X_{1i} - X_{2i}$, $i = 1, \dots, n$.
- $D_1, \dots, D_n$ are **i.i.d.** with $\mathbb{E}[D_i] = \mu_1 - \mu_2 = \delta$.
- Model: $D_1, \dots, D_n \stackrel{iid}{\sim} N_p(\delta, \Sigma_D)$.
- Estimators:

$$\bar{D} = \frac{1}{n} \sum_{i=1}^n D_i, \quad S_D = \frac{1}{n-1} \sum_{i=1}^n (D_i - \bar{D})(D_i - \bar{D})'$$

- **Hotelling pivot:**

$$n(\bar{D} - \delta)' S_D^{-1} (\bar{D} - \delta) \sim \frac{(n-1)p}{n-p} F(p, n-p)$$

9.3 Confidence Region

- $(1 - \alpha)$ confidence region for δ :

$$CR_{1-\alpha}(\delta) = \left\{ \eta \in \mathbb{R}^p : n(\bar{D} - \eta)' S_D^{-1} (\bar{D} - \eta) \leq \frac{(n-1)p}{n-p} F_{1-\alpha}(p, n-p) \right\}$$

- An **ellipsoid** in $\mathbb{R}^p$ centred at $\bar{D}$; an **ellipse** when $p = 2$.

9.4 Hypothesis Test

- $H_0 : \delta = \delta_0$ vs $H_1 : \delta \neq \delta_0$ (usually $\delta_0 = 0$).

- **Hotelling's T^2 :**

$$T_0^2 = n(\bar{D} - \delta_0)' S_D^{-1} (\bar{D} - \delta_0)$$

- **Reject H_0** at level α if

$$T_0^2 > \frac{(n-1)p}{n-p} F_{1-\alpha}(p, n-p)$$

- **Duality:** Reject $H_0 \iff \delta_0 \notin CR_{1-\alpha}(\delta)$.
- **Geometric intuition:** Does δ_0 lie inside the confidence ellipsoid? Yes $\Rightarrow$ do not reject; No $\Rightarrow$ reject.

9.5 Simultaneous Confidence Intervals

- For any $a \in \mathbb{R}^p$:

$$\text{Sim } CI_{1-\alpha}(a'\delta) = \left[a'\bar{D} \pm \sqrt{\frac{(n-1)p}{n-p} F_{1-\alpha}(p, n-p)} \cdot \sqrt{\frac{a' S_D a}{n}} \right]$$

- For coordinate δ_j (take $a = e_j$):

$$\text{Sim } CI_{1-\alpha}(\delta_j) = \left[\bar{D}_j \pm \sqrt{\frac{(n-1)p}{n-p} F_{1-\alpha}(p, n-p)} \cdot \sqrt{\frac{S_{D,jj}}{n}} \right]$$

- Uses an F critical value (not t) because p intervals are constructed **simultaneously**.
- **Alternative:** Bonferroni uses $t_{1-\alpha/(2p)}(n-1)$. Sometimes gives narrower intervals.

Türkçe Açıklamalar

T.1 — Büyük Resim: Neden Büyük Ölçekli Test?

- Klasik istatistikte **tek hipotez** test edilir: “Bu ilaç kan basıncımı düşürüyor mu?”
- Modern bilimde (genomik, beyin görüntüleme, finans) **aynı anda binlerce hipotez** test edilir: “Bu 1 000 genin hangisi kansere bağlı?”
- **Temel problem:** 1 000 geni $\alpha = 0.05$ ile test edersen, *hiçbiri* gerçekten etkili olmasa bile salt şans eseri $1\,000 \times 0.05 = 50$ **yanlış alarm** çıkar. 50 yanlış bulguyu yayınlarsın.
- **Neden önemli?** Çünkü yanlış alarmlar kaynakları (para, zaman, insan hayatı) boşa harcar ve bilimi yanıltır.
- **Amaç:** Çok sayıda eş zamanlı test yaparken yanlış alarm sayısını veya oranını kontrol eden yöntemler geliştirmek.
- İki temel kriter:
 - **FWER:** en az bir yanlış alarm yapma *olasılığı*. “Hiç hata yapma garantisi.”
 - **FDR:** yanlış alarmların tüm alarmlar içindeki beklenen *oranı*. “Hatalarımın oranını küçük tut.”

T.2 — Kurulum: Çoklu Test Çerçevesi

- Aynı anda k hipotez test ediyoruz. Veri:

$$X_1, \dots, X_n \stackrel{iid}{\sim} N_p(\mu, \Sigma)$$

- Her $i = 1, \dots, k$ için:

$$H_{0i} : a'_i \mu = d_{0i} \quad \text{vs} \quad H_{1i} : a'_i \mu \neq d_{0i}$$

- **Test istatistiği** (i . test için):

$$t_{0i} = \frac{a'_i \bar{X} - d_{0i}}{\sqrt{a'_i S a_i}} \cdot \sqrt{n}$$

- **Tip I Hata:**

$$\mathbb{P}[\text{Tip I hata}] = \mathbb{P}[H_0 \text{ reddedilir} \mid H_0 \text{ doğrudur}] = \alpha$$

- Tek testte bu kontrol altında. Ama k eş zamanlı testte **toplam hata oranı artık kontrol edilemez.**

T.3 — Karar Tablosu

- k eş zamanlı test yapıldığında sonuçlar bir 2×2 tabloya düşer:

	H_0 Reddedilmedi	H_0 Reddedildi	Toplam
H_0 doğru	U (doğru karar)	V (yanlış alarm)	k_0
H_1 doğru	T (kaçırılan etki)	S (doğru keşif)	$k - k_0$
Toplam		R (gözlemlenen)	k

- V = **yanlış keşif sayısı** — kötü. Gerçekte etki yok ama sen “var” dedin.
- S = **doğru keşif sayısı** — iyi. Gerçekten etki var ve sen de buldun.
- $R = V + S$ = toplam red sayısı — **gözlemlenebilir tek şey bu**.
- k_0 = gerçekten null olan hipotez sayısı — pratikte **bilinmez**.
- **Temel zorluk:** V ve S 'yi ayrı ayrı göremezsin; sadece R 'yi bilersin. Yani kaç yanlış alarm yaptığını bilemezsin. İstatistiksel yöntemler bunu *kontrol etmek* için çalışır.

T.4 — FWER ve Bonferroni Stratejisi

- **Tanım:**

$$\text{FWER} = \mathbb{P}[V \geq 1] = \mathbb{P}[\text{en az bir yanlış alarm}]$$

- **Sezgi:** Yazı-tura madeni para attığını düşün. Tek atışta tura gelmesi şaşırtıcıdır. Ama 1 000 atış yaparsan tura gelmesi kaçınılmazdır. Aynı şey: 1 000 null hipotezi $\alpha = 0.05$ ile test edersen ≈ 50 yanlış alarm *beklenir*. FWER bunu kontrol eder.
- **Bonferroni stratejisi:** Her H_{0i} 'yi α/k seviyesinde test et.
- **Teorem:** Bonferroni FWER'i α seviyesinde kontrol eder.
- **İspat özeti:** Birleşim sınırı (union bound) kullanarak:

$$\text{FWER} \leq \sum_{i \in I_0} \frac{\alpha}{k} = k_0 \cdot \frac{\alpha}{k} \leq k \cdot \frac{\alpha}{k} = \alpha$$

- **Sayısal örnek:** $k = 1\,000$, $\alpha = 0.05$. Bonferroni her testi $0.05/1\,000 = 0.00005$ seviyesinde yapar. Bu çok küçük bir eşik — gerçek etkileri tespit etmek için devasa kanıt lazım.
- **Problem:** Bonferroni çok **muhafazakardır**. Gerçek 1 000 etkili gen varsa, belki sadece 20 tanesini bulabilirsin. 980 tanesini **kaçırırsın** (Tip II hata).
- **Benzetme:** Biri mahkum etmeden önce 1 000 tanık isteyen bir hakim gibidir. Hiç masum kimseyi yanlış mahkum etmezsin, ama gerçek suçluların büyük çoğunluğu serbest kalır.

T.5 — Yanlış Keşif Oranı (FDR)

- **Motivasyon:**

- FWER sorusu: “Hiç hata yaptım mı?” — çok katı.
- FDR sorusu: “Keşiflerimin *ne kadar* yanlış?” — çok daha makul.
- **Gerçekçi beklenti:** 100 gen bulduysan ve 5’i yanlış alırsa, bu bilimsel olarak kabul edilebilir.

- **Yanlış keşif oranı Q :**

$$Q = \begin{cases} 0 & \text{eğer } R = 0 \text{ (hiçbir şey reddetmedik)} \\ \frac{V}{R} & \text{eğer } R > 0 \end{cases}$$

- **Somut örnek:** 100 hipotez reddettin. Bunların 5’i aslında null’du (yanlış alarm). $Q = 5/100 = \%5$.

- **Tanım (FDR):**

$$\text{FDR} = \mathbb{E}[Q]$$

- **FDR $\leq$ FWER — Neden?**

- **Durum 1** ($k = k_0$, tüm null’lar doğru): $S = 0$, $V = R$, dolayısıyla $Q = \mathbf{1}[V > 0]$ ve $\text{FDR} = \text{FWER}$. İki kriter *aynıdır*.
- **Durum 2** ($k - k_0 > 0$, bazı gerçek etkiler var): $Q = V/R \leq 1 = \mathbf{1}[V > 0]$, dolayısıyla $\text{FDR} \leq \text{FWER}$.

$$\boxed{\text{FDR} \leq \text{FWER}}$$

- **Sonuç:** FDR kontrolü FWER kontrolünden **daha az muhafazakardır**. Küçük bir hata oranına izin vererek çok daha fazla gerçek etkiyi tespit edebilirsin. Büyük ölçekli bilimde doğru tercih genellikle FDR’dir.

T.6 — Benjamini–Hochberg (BH) Prosedürü

- **Bu neden önemli?** 1995 yılında yayınlanan bu makale istatistik tarihinin en çok atıf alan makalelerinden biridir (2026 itibarıyla 126 000+ atıf). Problemi zarif ve basit bir yöntemle çözmüştür.

- **Adımlar:**

1. Her test için p-değeri p_i hesapla.
2. P-değerlerini küçükten büyüğe sırala: $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(k)}$.
3. Şu indeksi bul:

$$\hat{m} = \max \left\{ i \in \{1, \dots, k\} : p_{(i)} \leq \frac{i}{k} \alpha \right\}$$

4. $i \leq \hat{m}$ olan tüm $H_{0(i)}$ ’leri **reddet**.

- **Teorem:** P-değerleri bağımsızsa bu prosedür FDR’yi α seviyesinde kontrol eder.
- **Grafik sezgisi — bunu hayal et:**

- Yatay eksen: sıra numarası i (1’den k ’ya).
- Dikey eksen: sıralı p-değeri $p_{(i)}$.
- $y = \frac{i}{k}\alpha$ doğrusunu çiz (orijinden geçen, eğimi α/k olan bir doğru).
- P-değeri bu doğrunun *altında kalan son noktayı* bul. O noktaya kadar olan tüm hipotezleri reddet.
- **Bonferroni ile farkı:**
 - Bonferroni: herkese aynı sabit çıta α/k .
 - BH: artan çıta $\frac{i}{k}\alpha$ — sıra ilerledikçe çıta yükselir, daha fazla hipotezi geçmesine izin verir.
 - $k = 1000$, $\alpha = 0.05$ için: Bonferroni çıtası = 0.00005 (sabit). BH çıtası $i = 500$ ’de = 0.025, $i = 1000$ ’de = 0.05. BH çok daha cömerttir.

T.7 — Efron’un Stratejisi (2010)

- **Amaç:** BH prosedürüne Bayesci bir yorum getirmek ve daha güçlü bir strateji sunmak.
- **Fikir:** Her null hipotezinin π_0 ön olasılıkla doğru (H_0 geçerli), $1 - \pi_0$ olasılıkla yanlış (H_1 geçerli) olduğunu varsay.
- Bu model altında FDR’nin anlamı çok nettir:
 - $FDR \approx$ “Reddettiğim bir hipotezin gerçekten null olma art olasılığı.”
 - Yani: “Yayınladığım bulguların en fazla $\alpha \times 100\%$ ’i yanlış olur.” Bu bilim insanları için son derece doğal bir hedef.
- **Güçlü (Bayesci) FDR kontrolü:** Frekansçı BH’den daha güçlüdür çünkü π_0 ’ı veriden açıkça tahmin eder.
- **BH ile bağlantı:** BH prosedürü örtük olarak π_0 ’ı tahmin eder; Efron bunu görünür ve sistematik hale getirir.
- **Sonuç:** Veriden π_0 tahmin ederek daha dar/güçlü güven bölgeleri elde edilebilir — bu “güçlü Bayesci FDR kontrolü” olarak adlandırılır.

T.8 — Bağımlı P-değerleri: Benjamini & Yekutieli (2001)

- **Problem:** BH teoremi bağımsız p-değerleri varsayar. Pratikte testler çoğunlukla korelasyonludur.
- **Somut örnek:** Aynı biyolojik yolda çalışan Gen 1 ve Gen 2’yi test ediyorsun. Biri etkiliyse diğeri de muhtemelen etkilidir $\Rightarrow$ p-değerleri bağımlı.
- **Sonuç (Benjamini & Yekutieli):**
 - **Pozitif korelasyon** $\Rightarrow$ orijinal BH yine de FDR’yi kontrol eder. ✓
 - **Negatif korelasyon** $\Rightarrow$ eşiği değiştir.

- **Harmonik sayı:**

$$C(k) = \sum_{j=1}^k \frac{1}{j} = 1 + \frac{1}{2} + \frac{1}{3} + \cdots + \frac{1}{k} \approx \ln(k)$$

- **Modifiye BH eşiği:**

$$\hat{m} = \max \left\{ i : p_{(i)} \leq \frac{i}{k \cdot C(k)} \alpha \right\}$$

- **Sayısal örnek:** $k = 1\,000$ için $C(1\,000) \approx 7.5$. Eşik standart BH'nin 7.5 katı daha sıkıdır. Daha muhafazakar ama genel bağımlılık altında bile geçerli.
- **Sezgi:** Bağımlılık, testler arasında “bilgi sızıntısı” yaratır. Bu sızıntıyı telafi etmek için eşiği sıkılaştırıyoruz.

T.9 — Çok Değişkenli Ortalamalar için Çıkarım: Eşleştirilmiş Veri

T.9.1 — Kurulum ve Motivasyon

- **Senaryo:** 50 hastayı ilaçtan *önce* ve *sonra* ölçüyorsun. Her hastadan $p = 3$ ölçüm var: kan basıncı, kalp atışı, kolesterol.
- Bu, **eşleştirilmiş veridir**: her birim iki kez ölçülür.
- Birim i için:

$$\begin{pmatrix} X_{1i} \\ X_{2i} \end{pmatrix}, \quad X_{1i}, X_{2i} \in \mathbb{R}^p$$

- **Yapı:**
 - Hastalar birbirinden **bağımsızdır**.
 - Aynı hastanın önce/sonra ölçümleri **korelasyonludur** (aynı kişi!).
- **Amaç:** $\mu_1 - \mu_2$ farkını tahmin et ve $\mu_1 = \mu_2$ mi test et. Yani ilaç etki etti mi?

T.9.2 — Parlak Numara: Farkları Al

- **Neden bu numara işe yarıyor?** İki korelasyonlu örnekle çalışmak zordur. Ama farklar alındığında karmaşık iki-örnekli problem sade bir **tek-örnekli probleme** dönüşür.
- Her birim için **fark vektörünü** hesapla:

$$D_i = X_{1i} - X_{2i}, \quad i = 1, \dots, n$$

- **Neden i.i.d.?** Hastalar birbirinden bağımsız, dolayısıyla $D_1, \dots, D_n$ bağımsız ve aynı dağılımlı.
- **Önemli:** $\mathbb{E}[D_i] = \mu_1 - \mu_2 = \delta$. Soru artık şu: $\delta = 0$ mı?

- Model:

$$D_1, \dots, D_n \stackrel{iid}{\sim} N_p(\delta, \Sigma_D)$$

- Tahmin ediciler:

$$\bar{D} = \frac{1}{n} \sum_{i=1}^n D_i, \quad S_D = \frac{1}{n-1} \sum_{i=1}^n (D_i - \bar{D})(D_i - \bar{D})'$$

- **Hotelling pivotu:**

$$n(\bar{D} - \delta)' S_D^{-1} (\bar{D} - \delta) \sim \frac{(n-1)p}{n-p} F(p, n-p)$$

- **Sezgi:** Tek değişkende: $\left(\frac{\bar{X} - \mu}{s/\sqrt{n}}\right)^2$ bir F dağılımı izler. Bu tam olarak onun p -boyutlu genellemesidir. $(\bar{D} - \delta)' S_D^{-1} (\bar{D} - \delta)$ ise **Mahalanobis mesafesidir**: kovaryans yapısını hesaba katan ağırlıklı uzaklık ölçüsü.

T.9.3 — Güven Bölgesi: Elips

- Tek değişkende güven **aralığı** (bir doğru parçası).
- $p = 2$ 'de güven **elipsi**, $p > 2$ 'de güven **elipsoidi**.

$$CR_{1-\alpha}(\delta) = \left\{ \eta \in \mathbb{R}^p : n(\bar{D} - \eta)' S_D^{-1} (\bar{D} - \eta) \leq \frac{(n-1)p}{n-p} F_{1-\alpha}(p, n-p) \right\}$$

- Elipsin **merkezi** $\bar{D}$ 'dir.
- Elipsin **şekli** S_D tarafından belirlenir (kovaryans yapısı: hangi yönde daha fazla belirsizlik var?).
- Elipsin **boyutu** F kritik değeri tarafından belirlenir (α küçüldükçe elips büyür).

T.9.4 — Hipotez Testi ve Geometrik Sezgi

- **Test:**

$$H_0 : \delta = \delta_0 \quad \text{vs} \quad H_1 : \delta \neq \delta_0$$

Çoğunlukla $\delta_0 = \mathbf{0}$: ilaç etki etmedi mi?

- **Hotelling T^2 istatistiği:**

$$T_0^2 = n(\bar{D} - \delta_0)' S_D^{-1} (\bar{D} - \delta_0)$$

- α seviyesinde **H_0 'ı reddet** eğer:

$$T_0^2 > \frac{(n-1)p}{n-p} F_{1-\alpha}(p, n-p)$$

- **İkilik (Duality):** H_0 reddedilir $\iff \delta_0 \notin CR_{1-\alpha}(\delta)$.
- **Geometrik sezgi — sınav için hayati:**

- $p = 2$: (δ_1, δ_2) düzleminde bir elips çiz.
- Soru sadece şu: **Orijin** $(0, 0)$ **bu elipsin içinde mi?**
- **İçindeyse** $\Rightarrow H_0$ reddedilmez. İlaç etki etmedi.
- **Dışındaysa** $\Rightarrow H_0$ reddedilir. İlaç etki etti.
- Bu sezgi formülleri ezberlemekten çok daha önemlidir.

T.9.5 — Eş Zamanlı Güven Aralıkları

- Tek değişken için güven aralığı: t kritik değeri kullanılır.
- p değişken için **eş zamanlı** güven aralıkları: F kritik değeri kullanılır — çünkü p aralığı aynı anda kuruluyoruz.
- Herhangi bir $a \in \mathbb{R}^p$ yönü için:

$$\text{Sim } CI_{1-\alpha}(a'\delta) = \left[a'\bar{D} \pm \sqrt{\frac{(n-1)p}{n-p} F_{1-\alpha}(p, n-p)} \cdot \sqrt{\frac{a'S_D a}{n}} \right]$$

- δ_j koordinatı için ($a = e_j$):

$$\text{Sim } CI_{1-\alpha}(\delta_j) = \left[\bar{D}_j \pm \sqrt{\frac{(n-1)p}{n-p} F_{1-\alpha}(p, n-p)} \cdot \sqrt{\frac{S_{D,jj}}{n}} \right]$$

- **Neden F ve t değil?** Tek bir aralık kuruyorsan t yeterli. Ama aynı anda p aralık kuruyorsan daha geniş aralıklar gerekir — yoksa genel güven seviyesi bozulur. F kritik değeri bu genişlemeyi sağlar.
- **Alternatif:** Bonferroni $t_{1-\alpha/(2p)}(n-1)$ kullanır. Bazen daha dar aralıklar verir; hangisinin daha iyi olduğu duruma göre değişir.