

14 - Two-way ANOVA. The model. Decomposition of variance. The role of interactions. Testing for treatment effects. Classification. Supervised and unsupervised classification. The basic ingredients of supervised classification: feature distributions, prior distributions, and costs of misclassification.

Applied Statistics

Unat Teksen

March 30, 2026

1 Two-Way ANOVA — Overview

- **One-way ANOVA** asks: does one treatment affect the mean?
- **Two-way ANOVA** extends this to **two treatments simultaneously**.
- **Goal:** Determine whether each treatment has a significant effect on the response, and whether the two treatments **interact** with each other.
- **Running example:** Treatment 1 = drug type (A, B, C, so $g = 3$); Treatment 2 = dose level (low, high, so $b = 2$); response = blood pressure. Each combination is replicated $n = 5$ times, giving $3 \times 2 \times 5 = 30$ observations total.
- **Notation:**
 - Treatment 1 levels: $i = 1, \dots, g$
 - Treatment 2 levels: $j = 1, \dots, b$
 - Replication index: $k = 1, \dots, n$
 - X_{ijk} = k -th observation at level i of treatment 1 and level j of treatment 2
- **Balanced design:** every cell (i, j) contains exactly n replicates. This simplifies all computations.

2 The Model

- The two-way ANOVA model is:

$$X_{ijk} = \mu + \tau_i + \beta_j + \gamma_{ij} + \varepsilon_{ijk} \quad (1)$$

- Each term has a clear interpretation:
 - μ — overall grand mean (baseline level for all observations)
 - τ_i — effect of level i of treatment 1 (how much this level shifts the mean)
 - β_j — effect of level j of treatment 2
 - γ_{ij} — **interaction** between treatment 1 at level i and treatment 2 at level j ; the extra shift that cannot be explained by τ_i and β_j alone
 - $\varepsilon_{ijk} \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$ — random error
- **Identifiability constraints** (without these, the parameters are not uniquely defined):

$$\sum_{i=1}^g \tau_i = 0, \quad \sum_{j=1}^b \beta_j = 0, \quad \sum_{i=1}^g \gamma_{ij} = 0 \quad \forall j, \quad \sum_{j=1}^b \gamma_{ij} = 0 \quad \forall i \quad (2)$$

- **Cell mean** — the true average in cell (i, j) :

$$\mu_{ij} = \mu + \tau_i + \beta_j + \gamma_{ij} \quad (3)$$

- **Degrees of freedom** for the cell means μ_{ij} :

Component	df
Grand mean μ	1
Treatment 1 effects τ_i	$g - 1$
Treatment 2 effects β_j	$b - 1$
Interaction γ_{ij}	$(g - 1)(b - 1)$
Total (cell means)	gb

3 Estimators

- Define the following sample means:

- **Grand mean:**

$$\bar{X} = \frac{1}{gbn} \sum_i \sum_j \sum_k X_{ijk} \quad (4)$$

- **Treatment 1 marginal mean** (fix i , average over j and k):

$$\bar{X}_{i..} = \frac{1}{bn} \sum_{j=1}^b \sum_{k=1}^n X_{ijk}, \quad i = 1, \dots, g \quad (5)$$

- **Treatment 2 marginal mean** (fix j , average over i and k):

$$\bar{X}_{.j} = \frac{1}{gn} \sum_{i=1}^g \sum_{k=1}^n X_{ijk} \quad (6)$$

- **Cell mean** (fix i and j , average over k):

$$\bar{X}_{ij.} = \frac{1}{n} \sum_{k=1}^n X_{ijk} \quad (7)$$

- **What each estimator estimates:**

Estimator	Estimates
$\bar{X}$	μ
$\bar{X}_{i..} - \bar{X}$	τ_i
$\bar{X}_{.j.} - \bar{X}$	β_j
$\bar{X}_{ij.} - \bar{X}_{i..} - \bar{X}_{.j.} + \bar{X}$	γ_{ij}

- **Interaction estimator intuition:** Take the cell mean, subtract the contributions from treatment 1 alone and treatment 2 alone, and add back the grand mean to avoid double subtraction. Whatever remains is the interaction.

4 Decomposition of Variance

- **Core idea:** Split total variation into interpretable pieces, each attributable to a specific source.
- The full decomposition is:

$$\underbrace{\sum_i \sum_j \sum_k (X_{ijk} - \bar{X})^2}_{SS_{\text{total}}} = \underbrace{nb \sum_i (\bar{X}_{i..} - \bar{X})^2}_{SS_{\text{treat1}}} + \underbrace{ng \sum_j (\bar{X}_{.j.} - \bar{X})^2}_{SS_{\text{treat2}}} + \underbrace{n \sum_i \sum_j (\bar{X}_{ij.} - \bar{X}_{i..} - \bar{X}_{.j.} + \bar{X})^2}_{SS_{\text{interact}}} + \underbrace{\sum_i \sum_j \sum_k (X_{ijk} - \bar{X}_{ij.})^2}_{SS_{\text{res}}} \quad (8)$$

- **Degrees of freedom:**

Source	df
SS_{treat1}	$g - 1$
SS_{treat2}	$b - 1$
SS_{interact}	$(g - 1)(b - 1)$
SS_{res}	$gb(n - 1)$
SS_{total}	$gbn - 1$

- **Plain English meaning of each SS:**

- SS_{treat1} : how much do the treatment 1 group means vary around the grand mean?
- SS_{treat2} : same for treatment 2
- SS_{interact} : how much do cell means deviate from what pure additivity would predict?
- SS_{res} : pure within-cell noise — variation among the n replicates in the same cell

- **Additive model residuals:** If the additive model (no interactions) is fitted, the interaction sum of squares is absorbed into the residuals:

$$SS_{\text{res}}(\text{add. mod}) = SS_{\text{interact}} + SS_{\text{res}}(\text{comp. mod}) \quad (9)$$

5 The Role of Interactions

- **Additive model** (no interactions, $\gamma_{ij} = 0$ for all i, j):

$$\mu_{ij} = \mu + \tau_i + \beta_j \quad (10)$$

- The effect of changing treatment 1 is the **same** regardless of which level of treatment 2 you are at.
- On an interaction plot (μ_{ij} vs. j for each i): **lines are parallel**.

- **Interaction present** ($\gamma_{ij} \neq 0$):

- The effect of treatment 1 **depends** on the level of treatment 2.
- On an interaction plot: **lines cross or diverge**.

- **Key exam intuition:** If you are given an interaction plot, check whether lines are parallel. Parallel $\Rightarrow$ no interaction. Crossing/diverging $\Rightarrow$ interaction exists.
- **Why test interactions first?** If an interaction is present, interpreting main effects alone is misleading. For example, saying "drug A is effective" is incomplete if A is only effective at high doses.

6 Testing for Treatment Effects

- All tests use the same logic: compare the signal (treatment SS) to the noise (SS_{res}) via an F -statistic. A large F means the effect is real, not just random variation.
- **Step 1 — Test for interactions:**

$$H_0 : \gamma_{ij} = 0 \forall i, j \quad \text{vs} \quad H_1 : \exists \gamma_{ij} \neq 0 \quad (11)$$

$$F_0 = \frac{SS_{\text{interact}} / ((g-1)(b-1))}{SS_{\text{res}} / gb(n-1)} \sim F((g-1)(b-1), gb(n-1)) \text{ under } H_0 \quad (12)$$

Reject H_0 at level α if $F_0 > F_{1-\alpha}((g-1)(b-1), gb(n-1))$.

- **Step 2 — Test for treatment 1 main effect** (if no interaction, use additive model):

$$H_0 : \tau_1 = \tau_2 = \dots = \tau_g = 0 \quad \text{vs} \quad H_1 : \exists \tau_i \neq 0 \quad (13)$$

$$F_0 = \frac{SS_{\text{treat1}}/(g-1)}{SS_{\text{res(add)}}/[(g-1)(b-1) + gb(n-1)]} \quad (14)$$

If the complete model is used instead:

$$F_0 = \frac{SS_{\text{treat1}}/(g-1)}{SS_{\text{res(comp)}}/gb(n-1)} \quad (15)$$

- **Step 3 — Test for treatment 2 main effect** analogously:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_b = 0 \quad \text{vs} \quad H_1 : \exists \beta_j \neq 0 \quad (16)$$

$$F_0 = \frac{SS_{\text{treat2}}/(b-1)}{SS_{\text{res(add)}}/[(g-1)(b-1) + gb(n-1)]} \quad (17)$$

- **Decision rule for all tests:** Reject H_0 at level α if $F_0 > F_{1-\alpha}(\text{numerator df, denominator df})$.

7 Classification — Introduction

- **Big picture shift:** ANOVA compared known groups. Classification assigns unknowns to groups.
- **Setup:** Every unit is represented by a pair (x, ℓ) :
 - $x \in \mathbb{R}^p$ — vector of p features (measurements)
 - $\ell \in \{1, 2, \dots, g\}$ — label (group membership)
- **A classifier** is a function:

$$\delta : \mathbb{R}^p \rightarrow \{1, 2, \dots, g\} \quad (18)$$

$\delta(x) = c$ means observation with features x is assigned to group c .

- **Example:** $p = 2$ features are height and weight; groups are {healthy, obese, underweight}. The classifier takes measurements and assigns a group label.
- **Classification regions:** A classifier is equivalent to partitioning $\mathbb{R}^p$ into g regions:

$$R_c = \{x \in \mathbb{R}^p : \delta(x) = c\} = \delta^{-1}(\{c\}) \quad (19)$$

These satisfy:

- $R_i \cap R_j = \emptyset$ if $i \neq j$ (no overlap)
- $\bigcup_{i=1}^g R_i = \mathbb{R}^p$ (complete coverage)

- **Intuition:** Think of feature space as a plane divided into colored zones. Any new x that falls in zone c is assigned to group c .

8 Supervised and Unsupervised Classification

- **Supervised classification (Discriminant Analysis):**
 - Training set of n units, each with **known** label ℓ
 - Features $X_1, \dots, X_p$ observed for each unit
 - **Goal:** Learn a classifier δ from labeled data, then apply it to new unlabeled units
 - Analogy: a teacher shows you examples with correct answers; you learn the rule
- **Unsupervised classification (Cluster Analysis):**
 - Training set where labels ℓ are **unknown**
 - Only features $X_1, \dots, X_p$ are observed
 - **Goals:** Estimate the number of groups g , estimate group memberships, and learn δ
 - Analogy: you see examples with no answers and must discover groupings yourself
- **Key difference:** In supervised learning you know who belongs where during training. In unsupervised learning you do not.

9 Basic Ingredients of Supervised Classification

- Three ingredients are needed to build an optimal classifier.

9.1 Ingredient 1: Feature Distributions

- Within each group i , the features follow a distribution f_i :

$$X \mid \ell = i \sim f_i, \quad i \in \{1, 2, \dots, g\} \quad (20)$$

- $f_1, f_2, \dots, f_g$ are **all different** — this is what makes classification possible. If all groups had the same distribution, no classifier could separate them.
- **Example:** Classifying emails as spam or not. In spam emails, the word “FREE” appears frequently (high probability under f_1); in normal emails it rarely appears (low probability under f_2). The classifier uses this difference.
- **Intuition:** f_i tells you what a typical observation from group i looks like. The more separated the f_i 's are, the easier classification becomes.

9.2 Ingredient 2: Prior Distribution

- The prior probability that a randomly chosen unit belongs to group i :

$$P[\ell = i] = p_i \geq 0, \quad \sum_{i=1}^g p_i = 1 \quad (21)$$

- This is your belief about group frequencies **before** looking at any features.
- **Example:** In a hospital, 90% of patients are healthy ($p_1 = 0.9$) and 10% are sick ($p_2 = 0.1$). When a patient's features are ambiguous, the high prior for “healthy” tips the classification.
- **Intuition:** The prior is your starting belief. The feature distribution updates it. Together they produce the posterior probability used for classification.

9.3 Ingredient 3: Costs of Misclassification

- Define:

$$c(i | j) = \text{cost of classifying a unit as group } i \text{ when it truly belongs to group } j \quad (22)$$

- **Key properties:**
 - $c(i | i) = 0$ — correct classification has zero cost
 - $c(i | j) \neq c(j | i)$ in general — **symmetry is not required**
- **Medical example:**
 - $c(\text{healthy} | \text{sick})$: telling a sick person they are fine $\rightarrow$ **very high cost** (no treatment, potentially fatal)
 - $c(\text{sick} | \text{healthy})$: telling a healthy person they are sick $\rightarrow$ **low cost** (unnecessary tests, some stress)
- **Consequence:** A good classifier does not just minimize the *number* of errors; it minimizes *cost-weighted* errors. You may deliberately accept more of the cheaper error to avoid the expensive one.
- **Exam intuition:** If asked “which error is worse and how does it affect the classifier?” — identify the asymmetry in costs and argue which type of mistake the classifier should be biased to avoid.
- **Summary table of all three ingredients:**

Ingredient	Symbol	Answers
Feature distribution	f_i	What does group i look like in feature space?
Prior	p_i	How common is group i in the population?
Misclassification cost	$c(i j)$	How bad is each type of error?

Türkçe Açıklamalar

1. İki-Yönlü ANOVA — Genel Bakış

- **Hikaye ile başlayalım:** Bir ilaç şirketisin. İki şeyi aynı anda test ediyorsun:
 - **Tedavi 1 = İlaç türü:** A, B, C $\rightarrow g = 3$ seviye
 - **Tedavi 2 = Doz:** Düşük, Yüksek $\rightarrow b = 2$ seviye
 - Her kombinasyona $n = 5$ hasta koyuyorsun $\rightarrow$ toplamda $3 \times 2 \times 5 = 30$ hasta
 - Her hastada kan basıncı ölçüyorsun $\rightarrow$ bu senin X_{ijk}
- **X_{ijk} ne demek?** i . ilaç türü, j . doz, k . hasta ölçümü. Örnek: $X_{231} =$ B ilacı, yüksek doz, 1. hasta.
- **Ne sormak istiyoruz? — 3 soru:**
 - İlaç türü kan basıncını etkiliyor mu?
 - Doz kan basıncını etkiliyor mu?
 - İlaç türünün etkisi doza göre değişiyor mu? (**etkileşim**)
- **Dengeli tasarım:** Her (i, j) hücresinde tam olarak n tekrar vardır. Tüm hesaplamaları büyük ölçüde basitleştirir.

2. Model

- İki yönlü ANOVA modeli:

$$X_{ijk} = \mu + \tau_i + \beta_j + \gamma_{ij} + \varepsilon_{ijk}$$

- Her terimin yorumu — ilaç örneği üzerinden:
 - μ — tüm hastaların genel ortalaması
 - τ_i — “B ilacı ortalamayı +5 kaydırıyor” gibi, ilaç türünün etkisi
 - β_j — “yüksek doz ortalamayı -3 kaydırıyor” gibi, dozun etkisi
 - γ_{ij} — **etkileşim:** “B ilacı sadece yüksek dozda işe yarıyor” gibi, τ_i ve β_j ile açıklanamayan ek etki
 - $\varepsilon_{ijk} \stackrel{\text{iid}}{\sim} N(0, \sigma^2)$ — ölçüm gürültüsü
- **Kısıtlar** — parametreler özgün biçimde tanımlanabilsin diye:

$$\sum_i \tau_i = 0, \quad \sum_j \beta_j = 0, \quad \sum_i \gamma_{ij} = 0 \quad \forall j, \quad \sum_j \gamma_{ij} = 0 \quad \forall i$$

- **Hücre ortalaması** — (i, j) kombinasyonundaki gerçek ortalama:

$$\mu_{ij} = \mu + \tau_i + \beta_j + \gamma_{ij}$$

3. Tahmin Ediciler

- Belirli indisler üzerinden ortalama alarak parametreleri tahmin ederiz:
 - **Genel ortalama** $\bar{X}$: tüm gözlemlerin ortalaması $\rightarrow \mu$ 'yu tahmin eder
 - **Tedavi 1 marjinal ortalaması** $\bar{X}_{i..}$: i sabit, j ve k üzerinden ortalama $\rightarrow \tau_i$ 'yi tahmin eder
 - **Tedavi 2 marjinal ortalaması** $\bar{X}_{.j.}$: j sabit, i ve k üzerinden ortalama $\rightarrow \beta_j$ 'yi tahmin eder
 - **Hücre ortalaması** $\bar{X}_{ij.}$: i ve j sabit, k üzerinden ortalama $\rightarrow \mu_{ij}$ 'yi tahmin eder

- **Etkileşim tahmini:**

$$\hat{\gamma}_{ij} = \bar{X}_{ij.} - \bar{X}_{i..} - \bar{X}_{.j.} + \bar{X}$$

- **Sezgi:** Hücre ortalamasını al, tedavi 1 ve tedavi 2'nin tek başına katkılarını çıkar, çift çıkarma yapmamak için büyük ortalamayı geri ekle. Geri kalan etkileşimdir.

4. Varyansın Ayrışımı

- **Temel fikir:** Toplam değişkenliği anlamlı parçalara böl. Her parça “bu kaynak ne kadar değişkenliğe yol açıyor?” sorusunu yanıtlar.

$$SS_{\text{total}} = SS_{\text{treat1}} + SS_{\text{treat2}} + SS_{\text{interact}} + SS_{\text{res}}$$

- Her parçanın sade anlamı:
 - SS_{treat1} : İlaç türü gruplarının ortalamaları birbirinden ne kadar farklı?
 - SS_{treat2} : Doz grupları için aynı soru.
 - SS_{interact} : Hücre ortalamaları, “sadece ilaç + sadece doz” tahmininden ne kadar sapıyor?
 - SS_{res} : Aynı hücredeki n hastanın birbirinden ne kadar farklı? Saf gürültü.
- **F-testlerinde kullanım:** Her SS, SS_{res} ile karşılaştırılır. Sinyal (tedavi SS) gürültüden (SS_{res}) büyük mü?
- **Katkısal model için not:** Etkileşim yoksa, etkileşim kareler toplamı artık hatalara eklenir:

$$SS_{\text{res}}(\text{katkısal}) = SS_{\text{interact}} + SS_{\text{res}}(\text{tam model})$$

5. Etkileşimlerin Rolü

- **Etkileşim yok — katkısal model** ($\gamma_{ij} = 0$):
 - Tedavi 1'in etkisi, hangi doz seviyesinde olduğundan **bağımsızdır**.
 - “A ilacı her dozda aynı etkiyi yapıyor.”
 - Etkileşim grafiğinde: **çizgiler paralel**.
- **Etkileşim var** ($\gamma_{ij} \neq 0$):

- Tedavi 1'in etkisi, doz seviyesine **bağlıdır**.
- “A ilacı düşük dozda kötü çalışıyor ama yüksek dozda çok iyi — B ilacı tam tersi.”
- Etkileşim grafiğinde: **çizgiler kesişiyor veya ayrışıyor**.
- **Sınav sorusu buradan gelir:** Grafik verilir, “etkileşim var mı?” diye sorulur. Çizgiler paralelse → yok. Kesişiyorsa → var.
- **Neden önce etkileşimi test ederiz?** Etkileşim varsa “A ilacı etkilidir” demek anlamsız. A ilacı hangi dozda etkili? Bunu bilmeden ana etkiye bakmak yanıltıcı olur.

6. Tedavi Etkilerinin Test Edilmesi

- **Genel mantık:** Her F-testi “sinyal gürültüden büyük mü?” sorusunu sorar. Büyük $F_0 \rightarrow$ etki gerçek, rastgele değil.
- **Adım 1 — Önce etkileşimi test et:**

$$H_0 : \gamma_{ij} = 0 \quad \forall i, j \quad \text{vs} \quad H_1 : \exists \gamma_{ij} \neq 0$$

$$F_0 = \frac{SS_{\text{interact}} / (g-1)(b-1)}{SS_{\text{res}} / gb(n-1)}$$

$F_0 > F_{\text{tablo}}$ ise etkileşim vardır, H_0 reddedilir.

- **Adım 2 — Tedavi 1 ana etkisi** (etkileşim yoksa, katkısız model):

$$F_0 = \frac{SS_{\text{treat1}} / (g-1)}{SS_{\text{res}}(\text{katkısız}) / [(g-1)(b-1) + gb(n-1)]}$$

- **Adım 3 — Tedavi 2 ana etkisi** benzer şekilde.
- **Genel karar kuralı:** $F_0 > F_{1-\alpha}(\text{pay s.d., payda s.d.})$ ise H_0 reddedilir.

7. Sınıflandırma — Giriş

- **Büyük resim değişimi:** ANOVA bilinen grupları karşılaştırıyordu. Artık soru farklı: “*Elime yeni bir gözlem geldi — hangi gruba ait?*”
- Her birim bir çift (x, ℓ) ile temsil edilir:
 - $x \in \mathbb{R}^p$ — p adet özelliğin vektörü (ölçümler)
 - $\ell \in \{1, 2, \dots, g\}$ — etiket (grup üyeliği)

- **Sınıflandırıcı:**

$$\delta : \mathbb{R}^p \rightarrow \{1, 2, \dots, g\}$$

$\delta(x) = c \Rightarrow$ “ x özelliklerini gösteren birim c grubuna atandı.”

- **Örnek:** $p = 2$ özellik: boy ve kilo. Gruplar: {sağlıklı, obez, zayıf}. Sınıflandırıcı ölçümleri alır ve bir grup etiketi atar.

- **Sınıflandırma bölgeleri:** Sınıflandırıcı, $\mathbb{R}^p$ 'yi g bölgeye böler:

$$R_c = \{x \in \mathbb{R}^p : \delta(x) = c\}$$

- $R_i \cap R_j = \emptyset$ — bölgeler çakışmaz
- $\bigcup_i R_i = \mathbb{R}^p$ — her nokta bir gruba atanır
- **Sezgi:** Özellik uzayını renkli bölgelere bölünmüş büyük bir düzlem olarak düşün. Yeni gelen x hangi renkli bölgeye düşüyorsa o gruba atanır.

8. Gözetimli ve Gözetimsiz Sınıflandırma

- **Gözetimli Sınıflandırma (Diskriminant Analizi):**
 - Eğitim kümesindeki her birimin etiketi **bilinir**.
 - Özellikler $X_1, \dots, X_p$ her birim için gözlemlenir.
 - **Amaç:** Etiketli veriden δ 'yı öğren, yeni birimlere uygula.
 - **Benzetme:** Öğretmen sana doğru cevaplarla örnekler gösterir; sen kuralı öğrenirsin.
- **Gözetimsiz Sınıflandırma (Küme Analizi):**
 - Etiketler **bilinmez**; yalnızca özellikler gözlemlenir.
 - **Amaçlar:** Grup sayısı g 'yi tahmin et, grup üyeliklerini bul, δ 'yı öğren.
 - **Benzetme:** Cevap anahtarı olmayan örnekler görürsün; grupları kendin keşfetmen gerekir.
- **Temel fark:** Gözetimli öğrenmede eğitim sırasında kimin nereye ait olduğunu biliyorsun. Gözetimsizde bilmiyorsun.

9. Gözetimli Sınıflandırmanın Temel Bileşenleri

- İyi bir sınıflandırıcı oluşturmak için **3 bileşen** gerekir.

Bileşen 1: Özellik Dağılımları

- Her i grubunda özellikler f_i dağılımını izler:

$$X \mid \ell = i \sim f_i, \quad i \in \{1, 2, \dots, g\}$$

- $f_1, f_2, \dots, f_g$ **birbirinden farklıdır** — sınıflandırmayı mümkün kılan budur. Dağılımlar aynı olsaydı, hiçbir sınıflandırıcı grupları ayırt edemezdi.
- **Örnek:** Spam e-posta sınıflandırması:
 - Grup 1 (spam): “ÜCRETSİZ” kelimesi çok sık geçiyor $\rightarrow f_1$ altında yüksek olasılık
 - Grup 2 (spam değil): “ÜCRETSİZ” nadiren geçiyor $\rightarrow f_2$ altında düşük olasılık
- **Sezgi:** f_i sana “ i grubundan tipik bir gözlem nasıl görünür?” sorusunu yanıtlar. f_i 'ler ne kadar ayrışıkça sınıflandırma o kadar kolaydır.

Bileşen 2: Önsel Dağılım

- Herhangi bir özelliğe bakmadan, rastgele seçilen bir birimin i grubuna ait olma olasılığı:

$$P[\ell = i] = p_i \geq 0, \quad \sum_{i=1}^g p_i = 1$$

- Bu, **veriye bakmadan önceki** inancındır.
- Örnek:** Bir hastanede hastaların %90'ı sağlıklı ($p_1 = 0.9$), %10'u hasta ($p_2 = 0.1$). Bir hastanın özellikleri belirsiz olduğunda — hem sağlıklı hem de hasta olabilir gibi görünüyorsa — yüksek önsel olasılık “sağlıklı” kararına doğru iter.
- Sezgi:** Önsel dağılım başlangıç inancındır. Özellik dağılımı bunu günceller. İkisi birlikte sınıflandırma için kullanılan son olasılığı üretir.

Bileşen 3: Yanlış Sınıflandırma Maliyetleri

- Tanım:

$c(i | j)$ = gerçekte j grubuna ait bir birimi i grubuna atama maliyeti

- Temel özellikler:**
 - $c(i | i) = 0$ — doğru sınıflandırmanın maliyeti sıfır
 - $c(i | j) \neq c(j | i)$ genel olarak — **simetri zorunlu değildir**
- Tıbbi örnek — neden simetri önemli değil:**
 - $c(\text{sağlıklı} | \text{hasta})$: hasta birine “iyisin” demek → **çok yüksek maliyet** (tedavi görmüyor, ölüm riski var)
 - $c(\text{hasta} | \text{sağlıklı})$: sağlıklı birine “hastası” demek → **düşük maliyet** (gereksiz testler, biraz stres)
 - Yani $c(\text{sağlıklı} | \text{hasta}) \gg c(\text{hasta} | \text{sağlıklı})$
- Sonuç:** İyi bir sınıflandırıcı yalnızca hata *sayısını* değil, *maliyete göre ağırlıklandırılmış* hataları minimize eder. Pahalı hatadan kaçınmak için ucuz hatayı daha fazla yapmayı kabul edebilirsiniz.
- Sınav sezgisi:** “Hangi hata daha maliyetli ve bu sınıflandırıcıyı nasıl etkiler?” sorusunda şunu yap: maliyet asimetrisini belirle, sınıflandırıcının hangi hatadan kaçınmaya yöneleceğini açıkla.
- 3 bileşenin özet tablosu:**

Bileşen	Sembol	Yanıtladığı soru
Özellik dağılımı	f_i	i grubu özellik uzayında nasıl görünür?
Önsel dağılım	p_i	i grubu popülasyonda ne kadar yaygın?
Yanlış sınıf. maliyeti	$c(i j)$	Her hata türü ne kadar kötü?