

17 - Support Vector Machines

Applied Statistics

Unat Teksen

April 10, 2026

1 Big Picture — What Are We Trying to Do?

- We have a **supervised classification problem** with exactly two groups (dichotomous).
- The training set is:

$$\mathbb{X} = \begin{bmatrix} \underline{x}_1 & \ell_1 \\ \vdots & \vdots \\ \underline{x}_n & \ell_n \end{bmatrix}, \quad \underline{x}_i \in \mathbb{R}^p, \quad \ell_i \in \{1, 2\}$$

- **Goal:** Find a **hyperplane** $\mathcal{L}$ that separates the two groups with the largest possible gap.
- The hyperplane defines a partition of $\mathbb{R}^p$ into two regions R_1 and R_2 , which is equivalent to a classifier: $\{R_1, R_2\} \leftrightarrow \delta$.
- Why not just any separating line? A larger gap (margin) means new points are less likely to be misclassified — the classifier is more **robust**.
- **Comparison with LDA:** LDA also outputs a hyperplane, but uses all data points to estimate the mean and variance. SVM only uses the points closest to the boundary.

2 When Does a Separating Hyperplane Exist?

- Let $CH(A)$, $CH(B)$ be the **convex hulls** of sets A and B — the smallest convex sets containing A and B respectively.
- **Theorem (Geometric Form of Hahn–Banach):** A separating hyperplane exists between $A, B \subseteq \mathbb{R}^p$ if:
 1. $CH(A), CH(B) \neq \emptyset$ (always true when $A, B \neq \emptyset$)
 2. $CH(A) \cap CH(B) = \emptyset$ (the convex hulls do not overlap)
 3. Either $CH(A)$ or $CH(B)$ is an open set
- **Note:** Condition 3 can be replaced by: $CH(A)$ and $CH(B)$ are both closed and at least one is compact.

- For finite datasets, condition 3 is automatically satisfied — we only need to check **condition 2**.
- **Intuition for convex hull:** Imagine stretching a rubber band around all points in a group. If the rubber bands of the two groups do not overlap, a separating line exists.

3 The Hyperplane — Mathematical Definition

- A hyperplane $\mathcal{L}$ in $\mathbb{R}^p$ is an affine subspace of dimension $p - 1$.
- It is identified by a **direction vector** $\underline{\beta} \in \mathbb{R}^p$ orthogonal to it, normalized so that $\|\underline{\beta}\| = 1$.
- The hyperplane is the set of all points $\underline{x}$ satisfying:

$$\underline{\beta}^T \underline{x} = \beta_0 \iff \beta_1 x_1 + \beta_2 x_2 + \cdots + \beta_p x_p = \beta_0$$

- The quantity $\underline{\beta}^T \underline{x} - \beta_0$ measures the **signed distance** from point $\underline{x}$ to $\mathcal{L}$.
- For any $\underline{x} \in \mathcal{L}$: the projection $\pi_{\underline{\beta}} \underline{x} = \underline{x}_0$ where $\underline{x}_0 \in \mathcal{L} \cap \text{Span}(\underline{\beta})$ and $\beta_0 = \|\underline{x}_0\|$.
- **Classifier rule:**

- $\underline{x} \in \text{Plus (Group 1)} \iff \underline{\beta}^T \underline{x} > \beta_0$
- $\underline{x} \in \text{Minus (Group 2)} \iff \underline{\beta}^T \underline{x} < \beta_0$

4 Re-Parametrisation and the Margin

- Re-encode the labels for mathematical convenience:

$$y_i = \begin{cases} +1 & \text{if } \ell_i = 1 \text{ (Group 1, Plus)} \\ -1 & \text{if } \ell_i = 2 \text{ (Group 2, Minus)} \end{cases}$$

- If the hyperplane correctly separates all points, then for all $i = 1, \dots, n$:

$$y_i (\underline{\beta}^T \underline{x}_i - \beta_0) \geq 0$$

- Moreover, $y_i (\underline{\beta}^T \underline{x}_i - \beta_0)$ is the **unsigned distance** (distance without sign) from $\underline{x}_i$ to the hyperplane $\mathcal{L}$.
- Define the **margin**:

$$M_1 = \min_i y_i (\underline{\beta}^T \underline{x}_i - \beta_0) \geq 0$$

M_1 is the distance from the hyperplane to the *nearest* point on either side.

5 The Optimal Separating Hyperplane

- **Definition:** The **optimal separating hyperplane** is found by solving:

$$\max_{\underline{\beta}, \beta_0} M \quad \text{such that} \quad \|\underline{\beta}\| = 1 \quad \text{and} \quad y_i(\underline{\beta}^T \underline{x}_i - \beta_0) \geq M \quad \forall i = 1, \dots, n$$

- In plain words: find the hyperplane that **maximises the gap** (margin) to the nearest point on each side.
- The constraint $\|\underline{\beta}\| = 1$ is necessary to fix the scale — without it, $\underline{\beta}$ could be scaled arbitrarily and the margin would be meaningless.
- This is a well-posed convex optimisation problem.

6 Support Vectors

- **Definition:** The **support vectors** are the points in the training set that are *closest* to the optimal separating hyperplane — the points that lie on the margin boundary.
- Only the support vectors influence the position of the hyperplane. All other points can be moved freely without changing the boundary.
- **Key consequence:** SVM is very **robust to modifications** of the dataset with respect to points that are not support vectors.
- **Contrast with LDA:**
 - LDA uses the entire dataset to estimate the mean and variance.
 - Moving any single point in LDA moves the mean and therefore the boundary.
 - In SVM, only moving a support vector changes the boundary.
- **Note:** LDA is based on the probability of belonging to a group (priors and likelihoods), whereas SVM is a **geometric direct method** with no probabilities and no priors.

7 When the Groups Are Not Linearly Separable

7.1 Approach 1 — Soft Margin (Allow Some Misclassification)

- Introduce **slack variables** $\varepsilon_i \geq 0$ for each point:

$$\|\underline{\beta}\| = 1 \quad \text{and} \quad y_i(\underline{\beta}^T \underline{x}_i - \beta_0) \geq M(1 - \varepsilon_i) \quad \forall i$$

with a **budget constraint**:

$$\varepsilon_i \geq 0 \quad \text{and} \quad \sum_{i=1}^n \varepsilon_i \leq C$$

- Interpretation of ε_i :
 - $\varepsilon_i = 0$: point is correctly classified, outside the margin. Perfect.

- $0 < \varepsilon_i < 1$: point is inside the margin but on the correct side. Minor violation.
- $\varepsilon_i > 1$: point is on the **wrong side** of the hyperplane — **misclassified**.
- The full soft-margin optimisation problem is:

$$\max_{\underline{\beta}, \beta_0} M \quad \text{such that} \quad \|\underline{\beta}\| = 1, \quad y_i(\underline{\beta}^T \underline{x}_i - \beta_0) \geq M(1 - \varepsilon_i), \quad \varepsilon_i \geq 0, \quad \sum_i \varepsilon_i \leq C$$
- **Tuning parameter C :**
 - Small $C \Rightarrow$ strict, few violations allowed $\Rightarrow$ narrow margin.
 - Large $C \Rightarrow$ relaxed, many violations allowed $\Rightarrow$ wide margin but more misclassifications.
 - C must be **tuned** (e.g. via cross-validation) until a good enough classifier is found.
- Misclassified points ($\varepsilon_i > 1$) are those on the wrong side of the partition *outside* the margin — the points outside the dotted lines in the standard SVM figure.

7.2 Approach 2 — Kernel Methods (Non-Linear Boundary)

- **Key idea:** A linear method is linear with respect to its *input features*, not necessarily with respect to the original variables.
- If the boundary between the two groups is non-linear in the original features, we can **transform** the feature space.
- **Example:** Suppose $\mathbb{X}$ has two original features z_1, z_2 . We build new features:

$$x_1 = z_1, \quad x_2 = z_2, \quad x_3 = z_1^2, \quad x_4 = z_2^2, \quad x_5 = z_1 z_2, \quad x_6 = \sin(z_1), \quad \dots, \quad x_p = \log(z_2)$$

- The hyperplane in this expanded space:

$$\mathcal{L} : \beta_1 x_1 + \dots + \beta_p x_p = \beta_0$$

is **not linear** in the original features z_1, z_2 . For example:

$$\beta_1 z_1 + \beta_2 z_2 + \beta_3 z_1^2 + \dots = \beta_0$$

- **Why it works:** By increasing p , the groups become easier to separate linearly. But due to the **curse of dimensionality**, if p is too large there is a risk of **overfitting**.
- **Note:** We do not need Kernel functions for this — we can build non-linear features directly and still use a linear SVM. Kernel functions are a separate (more efficient) approach to the same idea.

8 SVM vs. LDA — Summary Comparison

- Both SVM and LDA are almost equal: we can find a good SVM and then modify LDA accordingly.

- Both work very well when the two groups are separated or almost separated.
- When groups heavily overlap, **logistic regression** works better.
- **LDA**: uses all data, estimates mean and variance, probability-based, sensitive to outliers.
- **SVM**: uses only support vectors, geometry-based, no probabilities, no priors, robust to outliers.

9 Multi-Class SVM ($K > 2$ Groups)

- When there are more than 2 groups, two strategies are used:
- **OVA — One-Versus-All:**
 - Train K binary classifiers. Classifier k separates group k from all others.
 - Assign new point x^* to the class with the largest posterior $\hat{f}_k(x^*)$.
 - Fits K different binary (2-class) classifiers.
- **OVO — One-Versus-One:**
 - Build $\binom{K}{2}$ pairwise classifiers, one for every pair of groups.
 - Assign x^* to the class that wins the most pairwise competitions.
 - **Note:** If K is too large, we must use OVO.

Türkçe Açıklamalar

A Büyük Resim — Ne Yapmaya Çalışıyoruz?

- Elimizde iki gruplu bir **gözetimli sınıflandırma problemi** var (dikotomik).
- Eğitim seti:

$$\mathbb{X} = \begin{bmatrix} \underline{x}_1 & \ell_1 \\ \vdots & \vdots \\ \underline{x}_n & \ell_n \end{bmatrix}, \quad \underline{x}_i \in \mathbb{R}^p, \quad \ell_i \in \{1, 2\}$$

- **Amaç:** İki grubu en geniş boşlukla ayıran bir **hiper-düzlem** $\mathcal{L}$ bulmak.
- Hiper-düzlem, $\mathbb{R}^p$ 'yi iki bölgeye ayırır: R_1 ve R_2 . Bu da bir sınıflandırıcıya eşdeğerdir: $\{R_1, R_2\} \leftrightarrow \delta$.
- Neden sadece herhangi bir ayırıcı değil? Büyük bir boşluk (marj), yeni noktaların yanlış sınıflandırılma olasılığını azaltır — sınıflandırıcı daha **gürbüz** olur.
- **LDA ile karşılaştırma:** LDA da bir hiper-düzlem üretir ancak ortalama ve varyansı tüm veri noktalarını kullanarak tahmin eder. SVM ise yalnızca sınıra en yakın noktaları kullanır.

B Ayırıcı Hiper-Düzlem Ne Zaman Var Olur?

- $CH(A)$ ve $CH(B)$, sırasıyla A ve B kümelerinin **konveks zarflarıdır** — A ve B 'yi içeren en küçük konveks kümeler.
- **Teorem (Hahn–Banach'ın Geometrik Formu):** $A, B \subseteq \mathbb{R}^p$ arasında ayırıcı bir hiper-düzlem mevcuttur, eğer:
 1. $CH(A), CH(B) \neq \emptyset$ ($A, B \neq \emptyset$ ise her zaman sağlanır)
 2. $CH(A) \cap CH(B) = \emptyset$ (konveks zarflar çakışmıyor)
 3. $CH(A)$ veya $CH(B)$ 'den en az biri açık kümedir
- **Not:** 3. koşul şununla değiştirilebilir: $CH(A)$ ve $CH(B)$ her ikisi de kapalı kümedir ve en az biri kompaktır.
- Sonlu veri setlerinde 3. koşul otomatik sağlanır — yalnızca **2. koşulu** kontrol etmek yeterlidir.
- **Konveks zarf sezgisi:** Bir grubun tüm noktalarının etrafına lastik bant gerin. İki grubun lastik bantları çakışmıyorsa, ayırıcı bir çizgi vardır.

C Hiper-Düzlem — Matematiksel Tanım

- $\mathbb{R}^p$ 'deki bir hiper-düzlem $\mathcal{L}$, boyutu $p - 1$ olan bir afin alt uzaydır.
- Buna dik olan ve $\|\underline{\beta}\| = 1$ ile normleştirilmiş bir **yön vektörü** $\underline{\beta} \in \mathbb{R}^p$ ile tanımlanır.

- Hiper-düzlem, şu koşulu sağlayan tüm $\underline{x}$ noktalarının kümesidir:

$$\underline{\beta}^T \underline{x} = \beta_0 \iff \beta_1 x_1 + \beta_2 x_2 + \dots + \beta_p x_p = \beta_0$$

- $\underline{\beta}^T \underline{x} - \beta_0$ ifadesi, $\underline{x}$ noktasının $\mathcal{L}$ 'ye **işaretli uzaklığını** ölçer.
- **Sınıflandırıcı kuralı:**
 - $\underline{x} \in \text{Plus (Grup 1)} \iff \underline{\beta}^T \underline{x} > \beta_0$
 - $\underline{x} \in \text{Minus (Grup 2)} \iff \underline{\beta}^T \underline{x} < \beta_0$

D Yeniden Parametreleme ve Marj

- Matematiksel kolaylık için etiketler yeniden kodlanır:

$$y_i = \begin{cases} +1 & \ell_i = 1 \text{ ise (Grup 1, Plus)} \\ -1 & \ell_i = 2 \text{ ise (Grup 2, Minus)} \end{cases}$$

- Hiper-düzlem tüm noktaları doğru sınıflandırıyorsa, tüm i için:

$$y_i (\underline{\beta}^T \underline{x}_i - \beta_0) \geq 0$$

- Ayrıca $y_i (\underline{\beta}^T \underline{x}_i - \beta_0)$, $\underline{x}_i$ noktasının hiper-düzleme **işaretsiz uzaklığıdır**.
- **Marj** tanımı:

$$M_1 = \min_i y_i (\underline{\beta}^T \underline{x}_i - \beta_0) \geq 0$$

M_1 , hiper-düzlemden her iki taraftaki en yakın noktaya olan uzaklıktır.

E Optimal Ayırıcı Hiper-Düzlem

- **Tanım: Optimal ayırıcı hiper-düzlem** şu problem çözülerek bulunur:

$$\max_{\underline{\beta}, \beta_0} M \quad \text{öyle ki} \quad \|\underline{\beta}\| = 1 \quad \text{ve} \quad y_i (\underline{\beta}^T \underline{x}_i - \beta_0) \geq M \quad \forall i = 1, \dots, n$$

- Sade anlatımla: en yakın noktaya olan **boşluğu (marjı) maksimize eden** hiper-düzlemi bul.
- $\|\underline{\beta}\| = 1$ kısıtı ölçeği sabitler — bu olmadan $\underline{\beta}$ keyfi ölçeklenebilir ve marj anlamsız olur.
- Bu, iyi tanımlı bir konveks optimizasyon problemidir.




Figure 1: SVM: Support Vectors

F Destek Vektörleri

- **Tanım: Destek vektörleri**, eğitim setindeki optimal ayırıcı hiper-düzleme en yakın noktalardır — marj sınırı üzerinde bulunan noktalardır.
- Yalnızca destek vektörleri hiper-düzlemin konumunu etkiler. Diğer tüm noktalar serbestçe taşınabilir, sınır değişmez.
- **Temel sonuç:** SVM, destek vektörü olmayan noktalara yapılan değişikliklere karşı çok **gürbüzdür (dayanıklıdır)**.
- **LDA ile karşılaştırma:**
 - LDA, ortalama ve varyansı tahmin etmek için tüm veri setini kullanır.
 - LDA’da tek bir noktayı taşımak ortalamayı ve dolayısıyla sınırı kaydırır.
 - SVM’de yalnızca bir destek vektörünü taşımak sınırı değiştirir.
- **Not:** LDA, bir gruba ait olma olasılığına (önsel dağılım ve olabilirlik) dayalıdır. SVM ise olasılık ve önsel dağılım içermeyen **geometrik ve doğrudan bir yöntemdir**.

G Gruplar Doğrusal Ayrışmıyorsa

G.1 Yaklaşım 1 — Yumuşak Marj (Bazı Yanlış Sınıflandırmalara İzin Ver)

- Her nokta için **gevşeklik değişkeni** $\varepsilon_i \geq 0$ tanıtlır:

$$\|\underline{\beta}\| = 1 \text{ ve } y_i(\underline{\beta}^T \underline{x}_i - \beta_0) \geq M(1 - \varepsilon_i) \quad \forall i$$

Bütçe kısıtı ile birlikte:

$$\varepsilon_i \geq 0 \text{ ve } \sum_{i=1}^n \varepsilon_i \leq C$$

- ε_i ’nin yorumu:

– $\varepsilon_i = 0$: nokta doğru sınıflandırılmış, marjın dışında. Mükemmel.

- $0 < \varepsilon_i < 1$: nokta marjın içinde ama doğru tarafta. Küçük ihlal.
- $\varepsilon_i > 1$: nokta **yanlış tarafta** — **yanlış sınıflandırılmış**.
- Tam yumuşak marj optimizasyon problemi:

$$\max_{\underline{\beta}, \beta_0} M \quad \text{öyle ki} \quad \|\underline{\beta}\| = 1, \quad y_i(\underline{\beta}^T \underline{x}_i - \beta_0) \geq M(1 - \varepsilon_i), \quad \varepsilon_i \geq 0, \quad \sum_i \varepsilon_i \leq C$$
- **Ayar parametresi C :**
 - Küçük $C \Rightarrow$ katı, az ihlale izin verilir $\Rightarrow$ dar marj.
 - Büyük $C \Rightarrow$ esnek, çok ihlale izin verilir $\Rightarrow$ geniş marj ama daha fazla yanlış sınıflandırma.
 - C , **ayarlanmalıdır** (örn. çapraz doğrulama ile).
- Yanlış sınıflandırılmış noktalar ($\varepsilon_i > 1$), bölünme sınırının yanlış tarafında ve marjın dışında kalan noktalardır.

G.2 Yaklaşım 2 — Kernel Yöntemleri (Doğrusal Olmayan Sınır)

- **Temel fikir:** Doğrusal bir yöntem, giriş özelliklerine göre doğrusaldır — orijinal değişkenlere göre değil.
- Orijinal özellikler doğrusal bir sınır oluşturmak için yetersiz kalıyorsa, **özellik uzayını dönüştürebiliriz**.
- **Örnek:** $\mathbb{X}$ 'in iki orijinal özelliği z_1, z_2 olsun. Yeni özellikler türetiriz:

$$x_1 = z_1, \quad x_2 = z_2, \quad x_3 = z_1^2, \quad x_4 = z_2^2, \quad x_5 = z_1 z_2, \quad x_6 = \sin(z_1), \quad \dots, \quad x_p = \log(z_2)$$

- Bu genişletilmiş uzaydaki hiper-düzlem:

$$\mathcal{L} : \beta_1 x_1 + \dots + \beta_p x_p = \beta_0$$

orijinal z_1, z_2 özelliklerinde **doğrusal değildir**. Örneğin:

$$\beta_1 z_1 + \beta_2 z_2 + \beta_3 z_1^2 + \dots = \beta_0$$

- **Neden işe yarıyor:** p arttıkça, gruplar doğrusal olarak daha kolay ayrışır. Ancak **boyutun laneti** nedeniyle p çok büyüyünce **aşırı öğrenme (overfitting)** riski doğar.
- **Not:** Bunun için Kernel fonksiyonlarına gerek yoktur — doğrusal olmayan özellikleri doğrudan oluşturup doğrusal bir SVM kullanmak mümkündür.

H SVM ile LDA Karşılaştırması

- SVM ve LDA birbirine çok yakındır: iyi bir SVM bulunabilir ve ardından LDA buna göre düzenlenebilir.
- Her ikisi de iki grup ayrışıyor ya da neredeyse ayrışıyorsa çok iyi çalışır.

- Gruplar büyük ölçüde örtüşüyorsa **lojistik regresyon** daha iyi sonuç verir.
- **LDA**: Tüm veriyi kullanır, ortalama ve varyansı tahmin eder, olasılık tabanlıdır, aykırı değerlere duyarlıdır.
- **SVM**: Yalnızca destek vektörlerini kullanır, geometri tabanlıdır, olasılık ve önsel dağılım içermez, aykırı değerlere dayanıklıdır.

I Çok Sınıflı SVM ($K > 2$ Grup)

- İki den fazla grup olduğunda iki strateji kullanılır:
- **OVA — Bire Karşı Hepsisi**:
 - K tane ikili sınıflandırıcı eğitilir. k . sınıflandırıcı, k . grubu diğer tüm gruplardan ayırır.
 - Yeni x^* noktası, en büyük $\hat{f}_k(x^*)$ değerini veren sınıfa atanır.
 - K farklı ikili (2-sınıflı) sınıflandırıcı kurulur.
- **OVO — Bire Karşı Bir**:
 - Her grup çifti için $\binom{K}{2}$ ikili sınıflandırıcı kurulur.
 - x^* , ikili karşılaşmaların en fazlasını kazanan sınıfa atanır.
 - **Not**: K çok büyükse OVO kullanılmalıdır.