

18 — Unsupervised Classification: Dissimilarities and Distances, Linkages, Hierarchical Agglomerative Clustering, Dendrogram, Cophenetic Distance and Correlation Coefficient

Applied Statistics

Unat Teksen

April 13, 2026

1 The Big Picture: Unsupervised Classification

- **Context:** In supervised learning we have observations *and* labels. In **unsupervised classification (cluster analysis)** the labels are *hidden*.
- **Training set:** $\mathbb{X} = [\underline{x}_1^T, \dots, \underline{x}_n^T]^T$ where $\underline{x}_i \in \mathbb{R}^p$. Features can be categorical or quantitative. No labels are provided.
- **Two goals:**
 - Estimate the hidden labels $\hat{\ell}_i$ for $i = 1, \dots, \hat{g}$.
 - Estimate the number of groups $\hat{g}$ — this is *also* unknown.
- **Core idea:** Units in the same cluster are *more similar* (less dissimilar) than units in different clusters.
- **Two main approaches:**
 - **Parametric:** Assumes each cluster follows a distribution (often Gaussian). Uses maximum likelihood. Example: *Expectation–Maximisation (EM)* algorithm — units in the same group share a Gaussian with similar variance.
 - **Non-parametric (our focus):** No distributional assumptions. Uses only a notion of similarity / dissimilarity.
- **Small example:** A supermarket has purchase records for 1000 customers. No labels exist, but we want to find groups of customers with similar habits to send targeted campaigns. This is clustering.

2 Dissimilarity Functions and Properties

- A **dissimilarity function** is:

$$d : \mathbb{R}^p \times \mathbb{R}^p \rightarrow [0, \infty)$$

It takes two observations and returns a non-negative number measuring how different they are. It is **not necessarily a distance**.

- **Required properties:**

1. **Weak identity:** $\forall \underline{x} \in \mathbb{R}^p : d(\underline{x}, \underline{x}) = 0$

The dissimilarity matrix has zeros on the diagonal.

Note: two different *units* can have $d = 0$ if they share the same feature vector.

Example: two people both have 2 eyes — $d = 0$ under that feature.

2. **Strong identity:** $\forall \underline{x}, \underline{y} \in \mathbb{R}^p : d(\underline{x}, \underline{y}) = 0 \iff \underline{x} = \underline{y}$

Stronger version. *Counterexample:* for $f, g \in L^2$,

$$d(f, g) = \|f - g\|_{L^2}^2 = 0 \not\Rightarrow f = g$$

(f and g may differ on a set of measure zero.)

3. **Symmetry:** $d(\underline{x}, \underline{y}) = d(\underline{y}, \underline{x}) \quad \forall \underline{x}, \underline{y} \in \mathbb{R}^p$

Counterexample: Kullback–Leibler (KL) divergence is not symmetric.

Fix: symmetrise by averaging: $\tilde{d}(\underline{x}, \underline{y}) = \frac{1}{2}(d(\underline{x}, \underline{y}) + d(\underline{y}, \underline{x}))$

4. **Triangle inequality:** $d(\underline{x}, \underline{y}) \leq d(\underline{x}, \underline{z}) + d(\underline{z}, \underline{y}) \quad \forall \underline{x}, \underline{y}, \underline{z} \in \mathbb{R}^p$

The direct path is never longer than any detour.

Note: the professor's notes write a chain of inequalities here — the correct statement is a sum on the right-hand side.

5. **Ultra-metric inequality:** $d(\underline{x}, \underline{y}) \leq \max(d(\underline{x}, \underline{z}), d(\underline{z}, \underline{y})) \quad \forall \underline{x}, \underline{y}, \underline{z} \in \mathbb{R}^p$

Stronger than property 4 — it *implies* the triangle inequality.

3 Types of Dissimilarity Measures

- **Formal definitions:**

- Properties 1', 2, 3 $\Rightarrow d$ is a **metric (distance)**.
- Properties 1, 2, 3 $\Rightarrow d$ is a **pseudo-metric** (two different points can have $d = 0$).
- Properties 1', 2, 4 $\Rightarrow d$ is an **ultra-metric**.

- **Key insight:** Clustering algorithms start from a dissimilarity (possibly weaker than a pseudo-metric) and produce the *closest ultra-metric* to it. The cophenetic distance (Section 11) is always an ultra-metric.

4 Dissimilarities and Distances: Examples

4.1 Euclidean Distance

- Standard geometric distance:

$$d(\underline{x}, \underline{y}) = \sqrt{(\underline{x} - \underline{y})^T (\underline{x} - \underline{y})} = \sqrt{\sum_{i=1}^p (x_i - y_i)^2}$$

- **Problem:** All features are treated as equally scaled. A 1 kg difference in bread eaten and a 1 euro difference in expenses would be weighted identically.
- **Solution:** Standardise each feature first (divide by its standard deviation), then apply Euclidean distance. This ensures each feature is on the same scale (unit = one standard deviation).
- **Note:** Minimising Euclidean distance of a point cloud gives the **mean (barycentre)**.
- **Small example:** Person A = (height 170, weight 70), Person B = (height 180, weight 75):

$$d = \sqrt{(170 - 180)^2 + (70 - 75)^2} = \sqrt{100 + 25} = \sqrt{125} \approx 11.2$$

4.2 Mahalanobis Distance

- Rescales by the inverse covariance matrix Σ^{-1} :
- $$d_{\Sigma^{-1}}(\underline{x}, \underline{y}) = \sqrt{(\underline{x} - \underline{y})^T \Sigma^{-1} (\underline{x} - \underline{y})}$$
- Accounts for both different scales *and* correlations between features.
 - **Problem:** Assumes the same covariance structure Σ across all clusters — which cannot be verified without knowing the clusters.
 - **Note:** Standardisation = Mahalanobis using only the *diagonal* of Σ (ignores off-diagonal correlations).

4.3 Minkowski Family (ℓ_m distances)

- A family parameterised by $m \geq 1$:

$$d(\underline{x}, \underline{y}) = \left(\sum_{i=1}^p |x_i - y_i|^m \right)^{1/m}$$

- Special cases:
 - $m = 2$: **Euclidean**. Minimiser of a point cloud = **mean**.
 - $m = 1$: **Manhattan**. Named after the New York grid: you can only move along streets and avenues, not diagonally. Minimiser of a point cloud = **median**.
 - $m \rightarrow \infty$: ℓ_∞ — takes the **maximum coordinate-wise difference**.
 - $m < 1$: Triangle inequality fails, but every component becomes important.

4.4 Canberra Distance

- For $\underline{x}, \underline{y} \in (\mathbb{R}^p)^+$ (non-negative components only):

$$d(\underline{x}, \underline{y}) = \sum_{i=1}^p \frac{|x_i - y_i|}{x_i + y_i}$$

- **Useful for economic quantities:** a difference of 10 between 20 and 30 weighs more than the same 10 between 1000 and 1010 (scale-relative sensitivity).

5 Dissimilarities for Categorical Variables

- Suppose $\underline{x} \in \{0, 1\}^p$ via **one-hot encoding**.
- **Example:** Colour $\in \{\text{blue, red, brown}\} \rightarrow (x_1, x_2)$:
 - $x_1 = 1$ if blue, $x_1 = 0$ otherwise.
 - $x_2 = 1$ if red, $x_2 = 0$ otherwise.
 - Blue = (1, 0), Red = (0, 1), Brown = (0, 0), (1, 1) impossible.
- For binary $\underline{x}, \underline{y} \in \{0, 1\}^p$:

$$d^2(\underline{x}, \underline{y}) = \sum_{i=1}^p (x_i - y_i)^2 = \text{number of discordances between } \underline{x} \text{ and } \underline{y}$$

- **Contingency table generalisation:** Let $a + b + c + D = p$ where:

	$y = 1$	$y = 0$
$x = 1$	a	b
$x = 0$	c	D

Then $b + c = \text{number of discordances}$. Alternative measures:

- **Euclidean:** $d_e^2(x, y) = b + c$
- **Percentage dissimilarity:** $d^2(\underline{x}, \underline{y}) = \frac{b + c}{p}$
- **Jaccard-like:** $d^2(\underline{x}, \underline{y}) = 1 - \frac{a}{p}$
- **Why alternatives?** Joint zeros (D : both units have 0) may be uninformative — two people both “not blue, not red, not green...” is not real evidence of similarity.

6 Mixed Variables and Variable Clustering

6.1 Mixed Quantitative and Categorical Variables

- Combine with a convex combination ($\lambda \in (0, 1)$):

$$d(\underline{x}, \underline{y})^2 = \lambda d_Q^2(\underline{x}^q, \underline{y}^q) + (1 - \lambda) d_C^2(\underline{x}^c, \underline{y}^c)$$

where q denotes the quantitative part and c the categorical part.

6.2 Clustering Variables (Not Units)

- Sometimes we cluster **variables** (columns of $\mathbb{X}$), not observations.
- **Question:** Which variables measure the same underlying thing?
- Natural similarity: **correlation**.

$$d^2(\text{Var}_i, \text{Var}_j) = 2(1 - \text{Cor}(\underline{X}_i, \underline{X}_j))$$

- This yields the **cosine distance**: correlation is the cosine of the angle between two centred variable vectors. Perfectly correlated variables have angle 0 (distance 0); uncorrelated variables have angle 90°.

7 The Dissimilarity Matrix

- Once a dissimilarity d is chosen, the training set is converted into the **dissimilarity matrix**:

$$D = [d_{ij}], \quad d_{ij} = d(\underline{x}_i, \underline{x}_j), \quad i, j = 1, \dots, n$$

D is $n \times n$ and is the **sole input to all clustering algorithms**.

- Properties of D :
 - Symmetric dissimilarity $\Rightarrow D$ is symmetric: $d_{ij} = d_{ji}$.
 - Property 1 satisfied $\Rightarrow$ zeros on the diagonal.
 - Both hold $\Rightarrow$ store only the lower triangular part.
- **Important**: The clustering algorithm needs only D , not the original data $\mathbb{X}$.
- **Key principle**: Every clustering problem has its own right dissimilarity function. Choosing correctly is the fundamental modelling decision.

8 Dissimilarities Between Sets: Linkages

- Once points form clusters $U, V \subset \mathbb{R}^p$, we need to measure the distance **between two clusters**.
- **Single Linkage (sl) — closest pair**:

$$d_{sl}(U, V) = \min\{d(\underline{x}, \underline{y}) : \underline{x} \in U, \underline{y} \in V\}$$

- **Complete Linkage (cl) — farthest pair**:

$$d_{cl}(U, V) = \max\{d(\underline{x}, \underline{y}) : \underline{x} \in U, \underline{y} \in V\}$$

- **Average Linkage (av) — mean over all pairs**:

$$d_{av}(U, V) = \frac{1}{|U| \cdot |V|} \sum_{\underline{x} \in U, \underline{y} \in V} d(\underline{x}, \underline{y})$$

- **Visual intuition**: Imagine two clouds of points. Single = gap between nearest neighbours from each cloud. Complete = gap between the two most distant opponents. Average = mean gap over every possible pairing.

9 Hierarchical Agglomerative Clustering (HAC)

- **Type:** Iterative, bottom-up (agglomerative) algorithm.
- **Input:** Dissimilarity matrix D only — original data not needed.
- **Opposite:** Hierarchical *Divisive* Clustering starts from one cluster and splits top-down.
- **Algorithm:**
 1. **Initialisation:** Each unit is its own cluster (n clusters total).
 2. **Repeat until one cluster remains:**
 - Step 1: Find the two clusters with the smallest dissimilarity and **merge** them.
 - Step 2: Recompute the dissimilarity matrix D using the chosen linkage rule.
 3. **Stop** when only one cluster remains.
- **Output:** A hierarchy of clusterings visualised as a dendrogram.

9.1 Worked Example: HAC with Single Linkage ($n = 5$)

- **Bold** entries mark the current minimum — the pair merged next.
- Single linkage update rule: $d(\{i, j\}, k) = \min(d(i, k), d(j, k))$

D_0 — Initial matrix

	1	2	3	4	5
1	0				
2	2	0			
3	6	5	0		
4	10	9	4	0	
5	9	8	5	3	0

Iter. 1: $\mathbf{d(1, 2) = 2} \rightarrow$ merge $\{1, 2\}$

$$d(\{1, 2\}, 3) = \min(6, 5) = 5$$

$$d(\{1, 2\}, 4) = \min(10, 9) = 9$$

$$d(\{1, 2\}, 5) = \min(9, 8) = 8$$

D_2 — After merging $\{4, 5\}$

	$\{1, 2\}$	3	$\{4, 5\}$
$\{1, 2\}$	0		
3	5	0	
$\{4, 5\}$	8	4	0

Iter. 3: $\mathbf{d(3, \{4, 5\}) = 4} \rightarrow$ merge $\{3, 4, 5\}$

$$d(\{3, 4, 5\}, \{1, 2\}) = \min(5, 8) = 5$$

D_1 — After merging $\{1, 2\}$

	$\{1, 2\}$	3	4	5
$\{1, 2\}$	0			
3	5	0		
4	9	4	0	
5	8	5	3	0

Iter. 2: $\mathbf{d(4, 5) = 3} \rightarrow$ merge $\{4, 5\}$

$$d(\{4, 5\}, \{1, 2\}) = \min(10, 9, 9, 8) = 8$$

$$d(\{4, 5\}, 3) = \min(4, 5) = 4$$

D_3 — After merging $\{3, 4, 5\}$

	$\{1, 2\}$	$\{3, 4, 5\}$
$\{1, 2\}$	0	
$\{3, 4, 5\}$	5	0

Iter. 4: $\mathbf{d(\{1, 2\}, \{3, 4, 5\}) = 5}$

Merge all $\rightarrow \{1, 2, 3, 4, 5\}$.

Algorithm complete!

9.2 Merge History Summary

Iteration	Clusters Merged	Merge Distance	New Cluster
1	{1} and {2}	2	{1, 2}
2	{4} and {5}	3	{4, 5}
3	{3} and {4, 5}	4	{3, 4, 5}
4	{1, 2} and {3, 4, 5}	5	{1, 2, 3, 4, 5}

10 The Dendrogram

- The **dendrogram** is the graphical representation of the HAC algorithm.
- **Vertical axis:** dissimilarity at which each merge occurred.
- **Horizontal axis:** individual units, ordered so that no branches cross each other.
- **Reading:** the height at which two branches join = the dissimilarity at which those two clusters were merged.
- **Computationally expensive:** Finding the crossing-free unit ordering requires exploring permutations of the units on the x-axis — this is the expensive part, not the algorithm itself.

10.1 Dendrogram Events from the Worked Example

Height (distance)	Event
2	Units 1 and 2 merge $\rightarrow$ {1, 2}
3	Units 4 and 5 merge $\rightarrow$ {4, 5}
4	Unit 3 and cluster {4, 5} merge $\rightarrow$ {3, 4, 5}
5	Clusters {1, 2} and {3, 4, 5} merge $\rightarrow$ {1, 2, 3, 4, 5}

10.2 Cutting the Dendrogram

- Draw a **horizontal line** at height h . Count how many vertical branches it intersects = number of clusters at that cut.
- **Example cuts from the worked example:**

Cut height	Number of clusters	Resulting clusters
0.5	5	{1}, {2}, {3}, {4}, {5}
3.5	3	{1, 2}, {3}, {4, 5}
4.5	2	{1, 2}, {3, 4, 5}

- **Rule of thumb:** Cut where there is a large jump in height — a big gap suggests a natural separation between clusters.
- **Stability trick:** Jitter the data (add small random noise) and re-run. If the chosen cut gives the same clusters, the structure is real.

11 Cophenetic Distance

- **Definition:** For each pair (i, j) , the **cophenetic distance** c_{ij} is the height in the dendrogram at which units i and j *first appear in the same cluster*.
- All c_{ij} values form the **cophenetic matrix** $C = [c_{ij}]$.
- **Key fact:** The cophenetic distance is always an **ultra-metric**.
- **Interpretation:** Clustering finds the *closest ultra-metric* to the original dissimilarity D . The cophenetic matrix is that ultra-metric.

11.1 Cophenetic Matrix from the Worked Example

	1	2	3	4	5
1	0				
2	2	0			
3	5	5	0		
4	5	5	4	0	
5	5	5	4	3	0

- $c_{12} = 2$: units 1 and 2 first share a cluster when merged at height 2.
- $c_{45} = 3$: units 4 and 5 first share a cluster at height 3.
- $c_{13} = 5$: units 1 and 3 do not share a cluster until $\{1, 2\}$ and $\{3, 4, 5\}$ merge at height 5.

12 Cophenetic Correlation Coefficient (CPCC)

- Each pair (i, j) now has **two** numbers:
 - d_{ij} : original dissimilarity from matrix D .
 - c_{ij} : cophenetic distance from matrix C .
- Plot all points (d_{ij}, c_{ij}) as a scatterplot (x-axis: d , y-axis: c). A good clustering $\Rightarrow$ points lie close to a line.

- **Definition:**

$$|\text{cpcc}| = |\text{Corr}\{(d_{ij}, c_{ij}) : i, j = 1, \dots, n\}| = |\text{Corr}(D, C)|$$

- **Interpretation:**

- $|\text{cpcc}| \approx 1$: The dendrogram faithfully represents the original dissimilarities. Good clustering.
- $|\text{cpcc}| \approx 0$: The dendrogram captures no structure. Bad clustering.
- Since it is a correlation: $|\text{cpcc}| \in [-1, 1]$.

- **Note:** The correlation between two matrices is computed as the correlation between all corresponding off-diagonal entries treated as a vector of points.

- **Practical use — model selection:**

- Try all three linkages: single, complete, average.
- Choose the linkage with the highest $|cpcc|$.
- This linkage produces the dendrogram that best preserves the original distance structure of the data.

13 Practical Notes: Linkage Choice

- **Single Linkage — chain effect:**

- Only *one* nearby pair is needed to merge two clusters.
- Produces long, thin, chain-like clusters.
- **Use when:** true clusters are elongated, crescent-shaped, or filamentary.
- **Avoid when:** true clusters are compact blobs that happen to be near each other — they will erroneously be merged.

- **Complete Linkage:**

- Requires the *farthest* pair between two clusters to be close.
- Produces compact, ellipsoidal clusters.
- Imposes ellipsoidal shape even when the true structure differs.
- **Use when:** clusters are expected to be round, compact blobs.

- **Average Linkage:**

- Middle ground — generally the safest default choice.
- Also biased toward ellipsoidal clusters, but less extremely than complete linkage.

- **Summary:**

Linkage	Cluster shape produced	Known issue
Single	Elongated, irregular	Chain effect
Complete	Compact, ellipsoidal	Forced ellipsoidal shape
Average	Compact, moderate	Mild ellipsoidal bias

— TÜRKÇE AÇIKLAMALAR —

1 Büyük Resim: Denetimsiz Sınıflandırma

- **Bağlam:** Denetimli öğrenmede hem veriler hem de etiketler var. **Denetimsiz sınıflandırmada (kümeleme analizinde)** etiketler *gizlidir* — kimsenin hangi gruba ait olduğunu bilmiyoruz.
- **Eğitim seti:** $\mathbb{X} = [\underline{x}_1^T, \dots, \underline{x}_n^T]^T$ burada $\underline{x}_i \in \mathbb{R}^p$. Özellikler kategorik ya da sayısal olabilir. Etiket yok.
- **İki hedef:**
 - Gizli etiketleri $\hat{\ell}_i$ tahmin et ($i = 1, \dots, \hat{g}$).
 - Grup sayısını $\hat{g}$ tahmin et — bu da bilinmiyor!
- **Temel fikir:** Aynı kümedeki birimler birbirine *daha benzer* (daha az benzemez) olmalı; farklı kümelerdekiler daha az benzer.
- **İki ana yaklaşım:**
 - **Parametrik:** Her küme bir dağılımdan (genellikle Gauss) geldiği varsayılır. Maksimum olabilirlik kullanılır. Örnek: *Expectation-Maximisation (EM) algoritması* — aynı gruptaki birimler benzer varyanslı bir Gauss dağılımı paylaşır.
 - **Parametrik olmayan (odak noktamız):** Dağılım varsayımı yok. Yalnızca benzerlik/benzemezlik kavramı kullanılır.
- **Küçük örnek:** Bir marketin 1000 müşterisinin alışveriş kayıtları var. Etiket yok ama benzer alışkanlıklara sahip grupları bulmak istiyoruz (örneğin hedefli kampanya göndermek için). İşte bu kümeleme!

2 Benzemezlik Fonksiyonları ve Özellikleri

- Bir **benzemezlik fonksiyonu:**

$$d : \mathbb{R}^p \times \mathbb{R}^p \rightarrow [0, \infty)$$

İki gözlem arasındaki farkı sayısal olarak ifade eder. Mutlaka matematiksel anlamda bir mesafe olmak zorunda değildir.

- **Gerekli özellikler:**

1. **Zayıf özdeşlik:** $d(\underline{x}, \underline{x}) = 0$

Benzemezlik matrisi köşegeninde sıfırlar bulunur.

Not: Farklı iki birim, aynı özellik vektörüne sahipse $d = 0$ olabilir. Örnek: tek özelliğimiz göz sayısı ise iki farklı insan arasında $d = 0$.

2. **Güçlü özdeşlik:** $d(\underline{x}, \underline{y}) = 0 \iff \underline{x} = \underline{y}$

Daha güçlü versiyon.

Karşı örnek: L^2 fonksiyonları için $\|f - g\|_{L^2}^2 = 0$, $f = g$ anlamına gelmez (f ve g ölçüsü sıfır olan bir kümede farklı olabilir).

3. **Simetri:** $d(\underline{x}, \underline{y}) = d(\underline{y}, \underline{x})$

Sıra önemli değil.

Karşı örnek: Kullback-Leibler (KL) ıraksaması simetrik değildir.

Düzeltilme: $\tilde{d}(\underline{x}, \underline{y}) = \frac{d(\underline{x}, \underline{y}) + d(\underline{y}, \underline{x})}{2}$ ile simetrik hale getirilebilir.

4. **Üçgen eşitsizliği:** $d(\underline{x}, \underline{y}) \leq d(\underline{x}, \underline{z}) + d(\underline{z}, \underline{y})$

Doğrudan yol, üçüncü bir noktadan geçmekten asla daha uzun olamaz.

Not: Profesörün notlarında sağ taraf yanlış yazılmış — doğrusu toplam, zincirleme eşitsizlik değil.

5. **Ultra-metrik eşitsizliği:** $d(\underline{x}, \underline{y}) \leq \max(d(\underline{x}, \underline{z}), d(\underline{z}, \underline{y}))$

Toplamdan daha güçlü — 4. özelliği içerir.

3 Benzemezlik Ölçüsü Türleri

- **Tanımlar:**

- 1', 2, 3 $\Rightarrow$ **metrik (uzaklık)**

- 1, 2, 3 $\Rightarrow$ **yarı-metrik** (iki farklı nokta $d = 0$ 'a sahip olabilir)

- 1', 2, 4 $\Rightarrow$ **ultra-metrik**

- **Önemli içgörü:** Kümeleme algoritmaları bir benzemezliği alır ve ona en yakın ultra-metriği üretir. Kofenetik mesafe (bkz. Bölüm 11) her zaman ultra-metriktir.

4 Benzemezlik ve Mesafe Örnekleri

4.1 Öklid Mesafesi

- Standart geometrik mesafe:

$$d(\underline{x}, \underline{y}) = \sqrt{\sum_{i=1}^p (x_i - y_i)^2}$$

- **Problem:** Tüm özellikleri eşit ölçekli sayar. Ekmek tüketimindeki (kg) 1 birimlik fark ile yıllık harcamadaki (€) 1 birimlik fark aynı ağırlıkla işlenir — bu anlamsız.
- **Çözüm:** Önce standardize et (her özelliği standart sapmasına böl), sonra Öklid uygula. Bu sayede her özellik aynı ölçekte olur.
- *Not:* Nokta bulutunun Öklid mesafesini minimize etmek **ortalamayı (barisentri)** verir.
- **Küçük örnek:** Kişi A: (boy=170, kilo=70), Kişi B: (boy=180, kilo=75):

$$d = \sqrt{(170 - 180)^2 + (70 - 75)^2} = \sqrt{100 + 25} = \sqrt{125} \approx 11.2$$

4.2 Mahalanobis Mesafesi

- Ters kovaryans matrisi Σ^{-1} ile ölçekleme:

$$d_{\Sigma^{-1}}(\underline{x}, \underline{y}) = \sqrt{(\underline{x} - \underline{y})^T \Sigma^{-1} (\underline{x} - \underline{y})}$$

- Hem farklı ölçekleri hem de özellikler arası korelasyonları hesaba katar.
- **Problem:** Tüm kümelerde aynı kovaryans yapısı Σ varsayılır — kümeleri bilmeden bunu doğrulayamayız.
- *Not:* Standardizasyon = Σ 'nın yalnızca *köşegenini* kullanan Mahalanobis mesafesidir (köşegen dışı korelasyonları yoksayar).

4.3 Minkowski Ailesi

- m parametresiyle bir uzaklık ailesi:

$$d(\underline{x}, \underline{y}) = \left(\sum_{i=1}^p |x_i - y_i|^m \right)^{1/m}$$

- Özel durumlar:
 - $m = 2$: **Öklid**. Nokta bulutunu minimize eder $\rightarrow$ **ortalama**.
 - $m = 1$: **Manhattan**. New York'tan adını alır: binalara rağmen yalnızca cadde ve sokaklarda yürürsün. Minimize edicisi $\rightarrow$ **medyan**.
 - $m \rightarrow \infty$: ℓ_∞ — koordinatlar arasındaki **maksimum farkı** alır.
 - $m < 1$: Üçgen eşitsizliği sağlanmaz, ama her bileşen önemli hale gelir.

4.4 Canberra Mesafesi

- Negatif olmayan bileşenler için:

$$d(\underline{x}, \underline{y}) = \sum_{i=1}^p \frac{|x_i - y_i|}{x_i + y_i}$$

- **Ekonomik büyüklükler için kullanışlı:** 20 ile 30 arasındaki 10 birimlik fark, 1000 ile 1010 arasındaki 10 birimlik farktan *çok daha ağır* basar. Oran bazlıdır.

5 Kategorik Değişkenler İçin Benzemezlikler

- $\underline{x} \in \{0, 1\}^p$ olduğunu varsay (**one-hot encoding** ile).
- **Örnek:** Renk $\in \{\text{mavi}, \text{kırmızı}, \text{kahverengi}\} \rightarrow (x_1, x_2)$:
 - $x_1 = 1$ mavi ise, $x_2 = 0$ değilse.
 - $x_2 = 1$ kırmızı ise, $x_1 = 0$ değilse.
 - Mavi = (1, 0), Kırmızı = (0, 1), Kahverengi = (0, 0), (1, 1) imkansız.

- İkili $\underline{x}, \underline{y} \in \{0, 1\}^p$ için:

$$d^2(\underline{x}, \underline{y}) = \text{uyumsuz bileşen sayısı}$$

- **Uyumluluk tablosu genellemesi:** $a + b + c + D = p$ olmak üzere:

	$y = 1$	$y = 0$
$x = 1$	a	b
$x = 0$	c	D

Alternatif ölçüler:

- **Öklid:** $d_e^2(x, y) = b + c$
- **Yüzde uyumsuzluk:** $d^2(\underline{x}, \underline{y}) = \frac{b + c}{p}$
- **Jaccard benzeri:** $d^2(\underline{x}, \underline{y}) = 1 - \frac{a}{p}$
- **Neden alternatifler?** D (her ikisi de 0) bilgi taşıyor olabilir — iki kişinin aynı şeyi *yapmıyor* olması gerçek bir benzerlik kanıtı değildir.

6 Karma Değişkenler ve Değişken Kümeleme

6.1 Karma Nicel ve Kategorik Değişkenler

- Dışbükey kombinasyonla birleştir ($\lambda \in (0, 1)$):

$$d(\underline{x}, \underline{y})^2 = \lambda d_Q^2(\underline{x}^q, \underline{y}^q) + (1 - \lambda) d_C^2(\underline{x}^c, \underline{y}^c)$$

q = nicel kısım, c = kategorik kısım.

6.2 Değişkenleri Kümeleme

- Bazen birimleri değil, **değişkenleri** kümeliyoruz.
- **Soru:** Hangi değişkenler aynı şeyi ölçüyor?
- Doğal benzerlik ölçüsü: **korelasyon**

$$d^2(\text{Var}_i, \text{Var}_j) = 2(1 - \text{Cor}(\underline{X}_i, \underline{X}_j))$$

- Bu formül **kosinüs mesafesini** verir: korelasyon, iki merkezlenmiş değişken vektörü arasındaki açının kosinüsüdür. Tam korelasyon $\rightarrow$ açı = 0 $\rightarrow$ mesafe = 0. Korelasyon yok $\rightarrow$ açı = 90° $\rightarrow$ büyük mesafe.

7 Benzemezlik Matrisi

- d seçildikten sonra eğitim seti **benzemezlik matrisine** dönüştürülür:

$$D = [d_{ij}], \quad d_{ij} = d(\underline{x}_i, \underline{x}_j), \quad i, j = 1, \dots, n$$

D , $n \times n$ boyutundadır ve tüm kümeleme algoritmalarının **tek girdisidir**.

- Özellikleri:
 - Simetrik $d \Rightarrow D$ simetriktir: $d_{ij} = d_{ji}$.
 - Özellik 1 sağlanıyorsa $\Rightarrow$ köşegen sıfır.
 - Her ikisi de sağlanıyorsa $\Rightarrow$ yalnızca alt üçgeni sakla.
- **Önemli:** Algoritma yalnızca D 'ye ihtiyaç duyar, orijinal veriye değil!
- **Temel ilke:** Her kümeleme problemi kendine özgü bir benzemezlik fonksiyonu gerektirir — doğru seçim en kritik modelleme kararıdır.

8 Kümeler Arası Benzemezlik: Bağlantı Türleri (Linkage)

- Noktalar kümeler haline geldiğinde, U ve V kümeleri arasındaki mesafeyi tanımlamamız gerekir.
- **Tek Bağlantı (Single Linkage) — en yakın çift:**

$$d_{sl}(U, V) = \min\{d(\underline{x}, \underline{y}) : \underline{x} \in U, \underline{y} \in V\}$$

- **Tam Bağlantı (Complete Linkage) — en uzak çift:**

$$d_{cl}(U, V) = \max\{d(\underline{x}, \underline{y}) : \underline{x} \in U, \underline{y} \in V\}$$

- **Ortalama Bağlantı (Average Linkage):**

$$d_{av}(U, V) = \frac{1}{|U| \cdot |V|} \sum_{\underline{x} \in U, \underline{y} \in V} d(\underline{x}, \underline{y})$$

- **Görsel sezgi:** İki nokta bulutu düşün. Single = iki bulut arasındaki en yakın komşu çifti. Complete = en uzak rakip çift. Average = tüm olası çiftlerin ortalaması.

9 Hiyerarşik Birleştirici Kümeleme (HAC)

- **Tür:** Yinelemeli, aşağıdan yukarıya (birleştirici) algoritma.
- **Girdi:** Yalnızca D matrisi — orijinal verilere gerek yok.
- **Karşıtı:** Hiyerarşik Bölücü Kümeleme (yukarıdan aşağıya, tek kümeden başlar).

- **Algoritma:**

1. **Başlangıç:** Her birim kendi başına bir küme (n küme).
2. **Tek küme kalana kadar tekrarla:**
 - Adım 1: En küçük benzemezliğe sahip iki kümeyi bul, **birleştir**.
 - Adım 2: Seçilen bağlantı kuralıyla D 'yi güncelle.
3. **Dur:** Tek bir küme kalınca.

- **Çıktı:** Dendrogram olarak görselleştirilen küme hiyerarşisi.

9.1 Örnek: Single Linkage ile HAC ($n = 5$)

Başlangıç benzemezlik matrisi D_0 :

1. **Adım:** En küçük değer $d(1, 2) = 2$. Birleştir: $\{1, 2\}$.
Güncelleme (single linkage, minimum al):
 - $d(\{1, 2\}, 3) = \min(6, 5) = 5$
 - $d(\{1, 2\}, 4) = \min(10, 9) = 9$
 - $d(\{1, 2\}, 5) = \min(9, 8) = 8$

Güncellenmiş matris D_1 :

2. **Adım:** En küçük değer $d(4, 5) = 3$. Birleştir: $\{4, 5\}$.
Güncelleme:
 - $d(\{4, 5\}, \{1, 2\}) = \min(10, 9, 9, 8) = 8$
 - $d(\{4, 5\}, 3) = \min(4, 5) = 4$

Güncellenmiş matris D_2 :

3. **Adım:** En küçük değer $d(3, \{4, 5\}) = 4$. Birleştir: $\{3, 4, 5\}$.
Güncelleme:
 - $d(\{3, 4, 5\}, \{1, 2\}) = \min(5, 8) = 5$

4. **Adım:** Kalan iki küme: $d(\{1, 2\}, \{3, 4, 5\}) = 5$. Birleştir. Algoritma tamamlandı!

9.2 Birleşme Özet Tablosu

Adım	Birleştirilen Kümeler	Birleşme Mesafesi	Yeni Küme
1	$\{1\}$ ve $\{2\}$	2	$\{1, 2\}$
2	$\{4\}$ ve $\{5\}$	3	$\{4, 5\}$
3	$\{3\}$ ve $\{4, 5\}$	4	$\{3, 4, 5\}$
4	$\{1, 2\}$ ve $\{3, 4, 5\}$	5	$\{1, 2, 3, 4, 5\}$

10 Dendrogram

- **Dendrogram:** HAC algoritmasının grafik temsidir.
- **Dikey eksen:** Her birleşmenin gerçekleştiği mesafe/yükseklik.

- **Yatay eksen:** Bireysel birimler, dalların birbirini kesmemesi için sıralanmış.
- **Okuma:** İki dalın birleştiği yükseklik = o iki kümenin birleştirildiği benzemezlik.
- **Hesaplamalı maliyet:** Kesişmesiz birim sıralaması bulmak permütasyonların keşfedilmesini gerektirir — pahalı olan kısım algoritmanın kendisi değil, *çizim* kısmıdır.

10.1 Örnekten Dendrogram Olayları

Yükseklik (mesafe) Olay	
2	1 ve 2 birimleri birleşir $\rightarrow \{1, 2\}$
3	4 ve 5 birimleri birleşir $\rightarrow \{4, 5\}$
4	3 birimi ve $\{4, 5\}$ kümesi birleşir $\rightarrow \{3, 4, 5\}$
5	$\{1, 2\}$ ve $\{3, 4, 5\}$ birleşir $\rightarrow \{1, 2, 3, 4, 5\}$

10.2 Dendrogramı Kesmek

- h yüksekliğinde yatay bir çizgi çiz. Kestiği dikey dal sayısı = o andaki küme sayısı.
- **Örnek kesimler:**

Kesim yüksekliği	Küme sayısı	Oluşan kümeler
0.5	5	$\{1\}, \{2\}, \{3\}, \{4\}, \{5\}$
3.5	3	$\{1, 2\}, \{3\}, \{4, 5\}$
4.5	2	$\{1, 2\}, \{3, 4, 5\}$

- **Pratik kural:** Yükseklikte büyük bir sıçrama olan yerde kes — büyük boşluk, kümeler arasında doğal bir ayrışma olduğuna işaret eder.
- **Kararlılık testi:** Veriye küçük rastgele gürültü (jitter) ekle ve yeniden çalıştır. Aynı kümeler oluşuyorsa yapı gerçektir.

11 Kofenetik Mesafe

- **Tanım:** Her (i, j) çifti için, **kofenetik mesafe** c_{ij} , i ve j birimlerinin dendrogramda *ilk kez aynı kümede görüldüğü* yüksekliktir.
- Tüm c_{ij} değerleri **kofenetik matris** $C = [c_{ij}]$ 'yi oluşturur.
- **Temel özellik:** Kofenetik mesafe her zaman bir **ultra-metriktir**.
- **Yorum:** Kümeleme, orijinal benzemezlik D 'ye en yakın ultra-metriği bulur. Kofenetik matris o ultra-metriktir.

11.1 Örnekten Kofenetik Matris

	1	2	3	4	5
1	0				
2	2	0			
3	5	5	0		
4	5	5	4	0	
5	5	5	4	3	0

- $c_{12} = 2$: Birimler 1 ve 2, yükseklik 2’de birleşir.
- $c_{45} = 3$: Birimler 4 ve 5, yükseklik 3’te birleşir.
- $c_{13} = 5$: Birimler 1 ve 3, ancak $\{1, 2\}$ ile $\{3, 4, 5\}$ yükseklik 5’te birleşince aynı kümede bulunur.

12 Kofenetik Korelasyon Katsayısı (CPCC)

- Her (i, j) çiftinin **iki** mesafesi var:
 - d_{ij} : D matrisinden orijinal benzemezlik.
 - c_{ij} : C matrisinden kofenetik mesafe.
- Tüm (d_{ij}, c_{ij}) noktalarını bir dağılım grafiğine koy (x-ekseni: d , y-ekseni: c). İyi kümeleme $\Rightarrow$ noktalar bir doğru etrafında kümelenir.

- **Tanım:**

$$|\text{cpcc}| = |\text{Corr}\{(d_{ij}, c_{ij}) : i, j = 1, \dots, n\}| = |\text{Corr}(D, C)|$$

- **Yorum:**

- $|\text{cpcc}| \approx 1$: Dendrogram orijinal benzemezlikleri iyi yansıtıyor. İyi kümeleme!
- $|\text{cpcc}| \approx 0$: Dendrogram hiçbir yapıyı yakalamıyor. Kötü kümeleme.
- Bir korelasyon katsayısı olduğundan: $|\text{cpcc}| \in [-1, 1]$.
- *Not:* İki matrisin korelasyonu, her iki matrisin karşılıklı köşegen dışı elemanlarının nokta olarak ele alınmasıyla hesaplanır.
- **Pratik kullanım — model seçimi:**
 - Üç bağlantı türünü de dene: single, complete, average.
 - En yüksek $|\text{cpcc}|$ ’ye sahip bağlantıyı seç.
 - Bu bağlantı, orijinal mesafe yapısını en iyi koruyan dendrogramı üretir.

13 Pratik Notlar: Bağlantı Türü Seçimi

- **Tek Bağlantı (Single) — zincir etkisi:**
 - İki kümeyi birleştirmek için yalnızca bir yakın çift yeterlidir.
 - Uzun, ince, zincir benzeri kümeler oluşturabilir.

- **Kullan:** Gerçek kümeler uzun, hilal biçimli veya eğri şeklindeyse.
- **Kaçın:** Gerçek kümeler birbirine yakın kompakt kümelerden oluşuyorsa — yanlış birleşme kaçınılmaz.
- **Tam Bağlantı (Complete):**
 - En uzak çiftin yakın olmasını şart koşar.
 - Kompakt, elipsoidal kümeler üretir.
 - Gerçek yapı farklı olsa bile elipsoidal şekli dayatır.
 - **Kullan:** Kümeler yuvarlak, kompakt kümeler olarak bekleniyorsa.
- **Ortalama Bağlantı (Average):**
 - İki arasında bir denge — genellikle en güvenli varsayılan seçim.
 - Tam bağlantıya göre daha hafif elipsoidal önyargı.
- **Özet tablo:**

Bağlantı Türü	Üretilen küme şekli	Bilinen sorun
Tek (Single)	Uzun, düzensiz	Zincir etkisi
Tam (Complete)	Kompakt, elipsoidal	Zorla elipsoidal şekil
Ortalama (Avg.)	Kompakt, orta düzey	Hafif elipsoidal önyargı