

20 - Regression: CART and Linear Regression

Applied Statistics

Unat Teksen

April 23, 2026

1 The Big Picture

- **Goal of Regression:** Given a training set of n observations, each with p input variables (covariates) $\underline{x}_i \in \mathbb{R}^p$ and a real-valued output $y_i \in \mathbb{R}$, we want to estimate the **regression function**:

$$f(\underline{x}) = \mathbb{E}[Y \mid \underline{X} = \underline{x}] \quad (1)$$

- We cannot know f exactly. We use the training data $\mathbb{X}$ to build an estimate $\hat{f}$.
- The training data is organized as an $n \times (p + 1)$ matrix:

$$\mathbb{X} = \begin{pmatrix} x_{11} & \cdots & x_{1p} & y_1 \\ \vdots & & \vdots & \vdots \\ x_{n1} & \cdots & x_{np} & y_n \end{pmatrix} = \begin{bmatrix} \underline{x}_1^T & \ell_1 \\ \vdots & \vdots \\ \underline{x}_n^T & \ell_n \end{bmatrix} \quad (2)$$

- **Note:** The $\underline{x}_i$ are the independent variables (covariates); y is the dependent variable (output). We want to *explain* the distribution (variability) of y in terms of $\underline{x}_i$.
- **Note:** If y is a label (category) instead of a number, the problem becomes *classification*.
- **Note:** If y were a deterministic constant, there would be no statistics to perform.
- **Two main approaches:**
 - **Non-parametric (data-driven):** Make no assumptions about f . Good when we know little about f . Good for prediction if the bias-variance trade-off is handled well, but prone to overfitting. Examples: **CART**, Random Forest, Boosting.
 - **Parametric (model-based):** Use prior knowledge about the problem. Good for both prediction and interpretation — we can quantify uncertainty about predictions and fitted parameters. Examples: **Linear Regression**, GLM, LMM, Kriging.
- **Note:** We focus mainly on the parametric approach, but first discuss CART as a useful non-parametric tool and building block.




Figure 1: CART

2 CART — Classification and Regression Trees

2.1 Core Idea

- Assume $\hat{f}$ is **piecewise constant**: the feature space $\mathbb{R}^p$ is partitioned into j non-overlapping **hyper-rectangular** regions $\{R_1, \dots, R_j\}$.
- CART takes the mean of the y values observed in a given region as the constant associated to $\hat{f}$ over that region:

$$\bar{y}_i = \frac{1}{\#R_i} \sum_{\underline{x}_k \in R_i} y_k \quad \forall i = 1, \dots, j \quad (3)$$

- The estimator is therefore:

$$\hat{f}(\underline{x}) = \sum_{i=1}^j \bar{y}_i \cdot \mathbf{1}[\underline{x} \in R_i] \quad (4)$$

where $\mathbf{1}[\underline{x} \in R_i] = 1$ if $\underline{x}$ falls in region R_i , else 0.

- **Requirement:** Each region must contain at least one training point:

$$R_i \cap \{\underline{x}_1, \dots, \underline{x}_n\} \neq \emptyset \quad \forall i = 1, \dots, j \quad (5)$$

- **Note:** j (the number of regions) is finite but unknown — it is part of what we must learn from data.
- **Intuition:** Think of coloring a city map into neighborhoods, each with a single average house price. CART finds the best boundaries automatically.

2.2 The Cost Function

- We want the regions to be **pure**: all y values inside a region should be close to their mean. We introduce a cost function which imposes that the mean is a good representative for all y values in each region.
- **Objective:** Minimize the total within-region variance of y :

$$\arg \min_{\{R_1, \dots, R_j\}, j} \sum_{i=1}^j \sum_{\underline{x}_k \in R_i} (y_k - \bar{y}_i)^2 \quad (6)$$

- **Note:** We are finding groups among the $\underline{x}_i$'s (clusters) that minimize the variability of the y_i 's — which is what we want to predict. This is similar in spirit to k -means clustering.
- **Why not minimize to zero?** The optimal situation is one point per region: zero cost, but completely overfits. Zero training error but huge prediction error on new data.

2.3 The Greedy Algorithm — How CART Splits

- Finding the globally optimal partition is computationally intractable. CART uses a **greedy** algorithm: split one region at a time, always choosing the locally best split. There are many solutions to this optimisation problem.
- **Step 1 — Find the best cut s_1 for variable x_1 :**
 - For each candidate threshold $s_1 \in \mathbb{R}$, compute the **variance reduction**:

$$\sum_{i=1}^n (y_i - \bar{y})^2 - \left[\sum_{x_{j1} < s_1} (y_j - \bar{y}_1)^2 + \sum_{x_{j1} \geq s_1} (y_j - \bar{y}_2)^2 \right] \quad (7)$$

- Choose s_1 that **maximizes** this quantity — the split that makes the two groups after the split have less variability than the total variability before the split.
- Here:

$$\bar{y}_1 = \frac{1}{\#\{j : x_{j1} < s_1\}} \sum_{x_{j1} < s_1} y_j, \quad \bar{y}_2 = \frac{1}{\#\{j : x_{j1} \geq s_1\}} \sum_{x_{j1} \geq s_1} y_j \quad (8)$$

- Repeat for all p variables $x_2, \dots, x_p$, obtaining optimal thresholds $s_1^*, \dots, s_p^*$.
- **Choose** the variable and threshold pair (x_j^*, s_j^*) that yields the largest variance reduction. This defines:

$$R_1 = \{\underline{x} \in \mathbb{R}^p : x_j \leq s_j^*\}, \quad R_2 = \{\underline{x} \in \mathbb{R}^p : x_j > s_j^*\} \quad (9)$$

- **Iterate Step 1** on each resulting region recursively $\Rightarrow$ builds a **binary tree**.
- **Stop condition:** Stop splitting region R_j when $\#R_j < C$, where C is a minimum-size threshold we decide. We do not stop at $C = 1$ — that leads to perfect overfitting.
- **Note:** The partition consists of hyper-rectangles in $\mathbb{R}^p$, but can be generalised to different shapes.
- **Note:** We can divide in the same direction more than once, for different rectangles.




Figure 2: Cart Tree Splitting

2.4 Pruning — Controlling Overfitting

- The problem is overfitting: we must minimise bias and avoid maximising variability, which would maximise prediction error.
- **Strategy:** Grow a large tree following the above algorithm, then **prune** the tree bottom-up by merging some rectangles — we penalise large trees.
- **Note:** In linear models this is analogous to penalising models with too many variables.
- **Penalized cost function:**

$$W(m, \alpha) = \sum_{i=1}^m (y_i - \bar{y})^2 + \alpha m \quad (10)$$

where m is the number of leaf regions and $\alpha > 0$ is the **complexity penalty**.

- This function depends on both m and α : fix α , plot W vs. m , choose m with the **elbow method**.
- **Interpretation of α :**
 - Large $\alpha \Rightarrow$ heavily penalise many regions $\Rightarrow$ few leaves $\Rightarrow$ simple tree.
 - Small $\alpha \Rightarrow$ allow many regions $\Rightarrow$ many leaves $\Rightarrow$ complex tree.
- **How to choose α :** By **cross-validation** (grow large tree, prune bottom-up to minimise $W(\alpha)$; α can be gotten from cross-validation).

2.5 CART for Classification — The Gini Index

- When y is a class label (categories $1, \dots, k$), replace the variance criterion with the **Gini index**:

$$\sum_{\underline{x}_j \in R} \sum_{k=1}^K p_k (1 - p_k) \quad (11)$$

where p_k is the frequency (proportion) of label k in region R .

- **Interpretation:** Gini = 0 means a perfectly pure region (all one class). We maximise purity at each split.

2.6 Beyond CART — Random Forest

- **CART don't beat linear models**, but they are building blocks of more efficient methods which do beat linear models.
- **Random Forest**: Build many trees from many different (bootstrap) training sets. We have an ensemble of trees that are not too correlated. The final prediction is the average of all tree predictions.
 - We build many training sets by **bootstrap** (random subsampling with replacement).
 - We can also **bootstrap the variables** (random subset of features at each split).
 - Averaging reduces variance significantly.
- **Only problem**: We lose interpretation of the prediction.

3 Linear Models for Regression

3.1 The Parametric Setup

- **Idea**: Assume the regression function f is linear in some (possibly transformed) variables. We use some prior knowledge about the problem.
- Define **transformed features** $z_1, \dots, z_r$, where each $z_k = h_k(\underline{X}_1, \dots, \underline{X}_p)$ is a known function of the original covariates that we need to “cook up”.
 - Examples: $z_1 = x_1^2$, $z_2 = \log(x_3)$, $z_3 = x_1 \cdot x_2$.
 - The model is **linear in the z 's** (and in the β 's) but can be **non-linear** in the original x 's. So we can model non-linear behaviour in the original variables.

- **Linear model**:

$$\mathbb{E}[Y \mid z_1, \dots, z_r] = \beta_0 + \beta_1 z_1 + \dots + \beta_r z_r \quad (12)$$

where the β_i are the unknowns — there are $r + 1$ parameters in total.

- **Model for Y** : Given $\underline{z} = (1, z_1, \dots, z_r)^T$:
 - $Y = f(\underline{z}) + \varepsilon$
 - f captures all the information the data gives us in terms of estimating the mean; ε is the part left out, called the **residual**.
 - $f(\underline{z}) = \beta_0 + \beta_1 z_1 + \dots + \beta_r z_r$
 - $\mathbb{E}[\varepsilon] = 0$ and $\varepsilon \perp\!\!\!\perp \underline{z}$

3.2 The Design Matrix

- Now we build the **design matrix** $\mathbb{Z}$, an $n \times (r + 1)$ matrix, where the columns $z_1, \dots, z_r$ are known functions (transformations) of $x_1, \dots, x_p$:

$$\mathbb{Z} = \begin{bmatrix} 1 & z_{11} & z_{12} & \cdots & z_{1r} \\ 1 & z_{21} & z_{22} & \cdots & z_{2r} \\ \vdots & \vdots & \vdots & & \vdots \\ 1 & z_{n1} & z_{n2} & \cdots & z_{nr} \end{bmatrix} = f \left(\begin{bmatrix} x_1^T \\ \vdots \\ x_n^T \end{bmatrix} \right) \quad (13)$$

- The first column of ones corresponds to the intercept β_0 .
- Consider the data $\underline{y} = (y_1, \dots, y_n)^T$ (which could even be a transformed version of the original target variable).

3.3 The Full Model

- In matrix form, the linear model is:

$$\underline{y} = \mathbb{Z} \underline{\beta} + \underline{\varepsilon} \quad (14)$$

where $\underline{\beta} = (\beta_0, \dots, \beta_r)^T$ and $\underline{\varepsilon} \in \mathbb{R}^n$ is such that $\mathbb{E}[\underline{\varepsilon}] = \underline{0}$.

- **Components:**

- $\underline{y} = (y_1, \dots, y_n)^T \in \mathbb{R}^n$ — observed outputs.
- $\underline{\beta} = (\beta_0, \beta_1, \dots, \beta_r)^T \in \mathbb{R}^{r+1}$ — unknown parameters to be estimated.
- $\underline{\varepsilon} = (\varepsilon_1, \dots, \varepsilon_n)^T \in \mathbb{R}^n$ — error vector (residuals).

- **Assumption:** Suppose $\text{Cov}(\underline{\varepsilon}) = \sigma^2 I$, so errors are not independent but just **uncorrelated**. Note that σ^2 needs to be estimated.

$$\mathbb{E}[\underline{\varepsilon}] = \underline{0}, \quad \text{Cov}(\underline{\varepsilon}) = \sigma^2 I, \quad \underline{\varepsilon} \perp\!\!\!\perp X_1, \dots, X_p \quad (15)$$

- Individual model equation: $y_i = \beta_0 + \beta_1 z_{i1} + \dots + \beta_r z_{ir} + \varepsilon_i$, with $\varepsilon_1, \dots, \varepsilon_n$ uncorrelated with same variance and mean zero, independent of the z_i .
- **Note:** We are *not* assuming Gaussianity. Normality of ε is only needed for inference (confidence intervals, hypothesis tests).
- **Linear models are very flexible:** For instance, one-way ANOVA is a particular case of a linear model.

4 Linear Models and ANOVA

4.1 ANOVA as a Special Linear Model

- **Key insight:** ANOVA is a special case of $\underline{y} = \mathbb{Z} \underline{\beta} + \underline{\varepsilon}$ with a cleverly designed $\mathbb{Z}$.
- **ANOVA setup:** We have g independent groups. Within group i , we observe n_i measurements:

$$X_{11}, \dots, X_{1n_1} \stackrel{\text{iid}}{\sim} \mathcal{N}(\mu_1, \sigma^2), \quad \dots, \quad X_{g1}, \dots, X_{gn_g} \stackrel{\text{iid}}{\sim} \mathcal{N}(\mu_g, \sigma^2) \quad (16)$$

- Define $\underline{y} = (X_{11}, \dots, X_{1n_1}, X_{21}, \dots, X_{gn_g})^T \in \mathbb{R}^n$ where $n = n_1 + \dots + n_g$.
- Take $\mathbb{Z}$ to be the matrix with n_i ones in the positions related to X_{ij} (dummy variable columns $\underline{z}_0, \underline{z}_1, \dots, \underline{z}_g$):
 - $\underline{z}_0 = (1, 1, \dots, 1)^T$ (intercept, all ones)
 - $\underline{z}_i$ has 1 in rows corresponding to group i , 0 elsewhere
- **ANOVA model:** $x_{ij} = \mu + \tau_i + \varepsilon_{ij}$, so $\underline{\beta} = (\mu, \tau_1, \dots, \tau_g)^T$.
- To have ANOVA we need: $\underline{\varepsilon} \sim \mathcal{N}(\underline{0}, \sigma^2 I)$, thus:

$$x_{ij} = \mu + \tau_i + \varepsilon_{ij}, \quad \varepsilon_{ij} \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2), \quad i = 1, \dots, g, \quad j = 1, \dots, n_i \quad (17)$$

4.2 The Rank Problem and the Constraint

- **Problem:** In the above, $\mathbb{Z}$ is **not full rank** — summing the columns from the second to the last gives the first column. This is an **over-parametrisation**, as we have seen in ANOVA.
- **Consequence:** We cannot uniquely identify all parameters $(\mu, \tau_1, \dots, \tau_g)$.
- **Fix — impose the constraint:**

$$\sum_{i=1}^g n_i \tau_i = 0 \quad \Longleftrightarrow \quad \tau_g = -\frac{1}{n_g} \sum_{i=1}^{g-1} n_i \tau_i \quad (18)$$

- To satisfy this constraint, rebuild $\mathbb{Z}$ with modified columns: $\underline{z}_1, \dots, \underline{z}_{g-1}$ as before, and $\underline{z}_g$ replaced by entries $-n_i/n_g$ in the rows of group g (and $-n_i/n_g$ for earlier groups' rows in that column).
- In this case $\mathbb{Z}$ is an $n \times g$ **full-rank** matrix (was $n \times (g+1)$ and not full rank before).
- **Note:** The dummy columns $\underline{z}_1, \dots, \underline{z}_g$ are not derived from the data — they are just there to remind us of the group information we are analysing, coming from the different groups of the experimental design.
- From the linear constraint: $\tau_g = -\frac{1}{n_g} \sum_{i=1}^g n_i \tau_i$, so the last group's effect is determined by the others.

4.3 ANCOVA

- **ANCOVA (Analysis of Covariance)** extends ANOVA by adding quantitative (continuous) covariates to the design matrix — we can enrich the ANOVA to get ANCOVA.
- Example model:

$$X_{ij} = \mu + \tau_i + \beta W_i + \varepsilon_{ij} \quad (19)$$

where W_i is a continuous covariate (e.g. a pre-treatment measurement or additional quantitative variable).

- This allows us to **separate** the group effect τ_i from the continuous covariate effect βW_i .
- **Note:** ANOVA, ANCOVA, and linear regression are all special cases of $\underline{y} = \mathbb{Z} \underline{\beta} + \underline{\varepsilon}$.

5 Key Intuitions Summary

- **CART:** Think of coloring a city map into regions. Each region gets one prediction (the average y). The algorithm finds the best boundaries by asking one yes/no question per variable at a time.
- **Overfitting:** Fitting the training data too perfectly is bad. A model with one point per region has zero training error but fails on new data. Pruning (the α penalty) controls this.
- **α interpretation:** Like a price per region. Large $\alpha \Rightarrow$ few regions (simple model). Small $\alpha \Rightarrow$ many regions (complex model). Choose via cross-validation.
- **“Linear” model warning:** The word “linear” refers to linearity in the parameters β , *not* in the original variables. You can fit $y = \beta_0 + \beta_1 x + \beta_2 x^2 + \beta_3 \log(x)$ — still a linear model.
- **ANOVA = Regression:** Once group indicators are converted to dummy variables, ANOVA is exactly linear regression with the same matrix equation $\underline{y} = \mathbb{Z} \underline{\beta} + \underline{\varepsilon}$.
- **Bias-Variance Trade-off:**
 - Simple model $\Rightarrow$ high bias (wrong on average), low variance (consistent predictions).
 - Complex model $\Rightarrow$ low bias, high variance (inconsistent across datasets).
 - Pruning and cross-validation find the sweet spot.
- **Random Forest beats CART:** Averaging many uncorrelated trees dramatically reduces variance while keeping low bias. Cost: interpretability.
- **Professor’s key point:** Imagine the partition as a map — the key intuition is that CART groups the $\underline{x}$ ’s in space to minimise variability of y , not of $\underline{x}$ itself.

Türkçe Açıklamalar

1. Problem Nedir? Ne Yapmaya Çalışıyoruz?

- Elimizde bir veri seti var. Her gözlem için **girdiler** (covariate) $\underline{x}_i$ ve tahmin etmek istediğimiz bir **çıkıtı** y_i var.
- **Örnek:** Metrekare, oda sayısı, şehir merkezine uzaklık bilinen bir evin kira fiyatını tahmin etmek.
- Regresyon, girdilerden çıktıya giden bir fonksiyon bulmaktır:

$$\hat{f}(\text{girdi}) \approx \text{çıkıtı} \quad (20)$$

- **Not:** $\underline{x}_i$ 'ler bağımsız değişkenler (covariate), y ise bağımlı değişkendir. Amacımız y 'nin dağılımını (değişkenliğini) $\underline{x}_i$ cinsinden açıklamaktır.
- **Not:** y deterministik bir sabit olsaydı yapılacak istatistik olmazdı.
- **İki temel yaklaşım:**
 - **Non-parametrik (veri güdümlü):** f hakkında hiçbir şey varsaymıyoruz. Bias-varyans dengesi iyi yönetilirse tahmin için iyidir; ancak overfitting riski yüksektir. → **CART**, Random Forest, Boosting.
 - **Parametrik (model tabanlı):** Problem hakkında önceden bilgi kullanıyoruz. Hem tahmin hem yorum için iyidir; parametreler ve tahminler üzerindeki belirsizliği ölçebiliriz. → **Doğrusal Regresyon**, GLM, LMM.
- **Not:** y bir sayı değil etiket (kategori) ise problem *sınıflandırma* (classification) olur.

2. CART — “Harita Çiz, Bölge Bölge Tahmin Et”

- **Temel fikir:** $\hat{f}$ 'nin parça parça sabit (piecewise constant) olduğunu varsay. Özellik uzayı $\mathbb{R}^p$, j tane örtüşmeyen **hiperkütle** (hyper-rectangle) bölgeye ayrılır.
- CART, her bölgedeki gözlemlerin y ortalamasını o bölgenin tahmini olarak kullanır:

$$\bar{y}_i = \frac{1}{\#R_i} \sum_{\underline{x}_k \in R_i} y_k, \quad \hat{f}(\underline{x}) = \sum_{i=1}^j \bar{y}_i \cdot \mathbf{1}[\underline{x} \in R_i] \quad (21)$$

- **Sezgi:** Türkiye'yi kira fiyatlarına göre renkli bölgelere ayırmak gibi. İstanbul: 15.000, Ankara: 8.000, Taşra: 3.000. CART bu sınırları otomatik ve çok boyutlu olarak buluyor.
- **Maliyet fonksiyonu:** Grup içi varyansı minimize et — ortalamanın tüm y değerleri için iyi bir temsilci olmasını zorunlu kılıyoruz:

$$\arg \min \sum_{i=1}^j \sum_{\underline{x}_k \in R_i} (y_k - \bar{y}_i)^2 \quad (22)$$

- **Not:** Aslında $\underline{x}_i$ 'ler arasında kümeleme yapıyoruz ama amacımız y_i 'lerin değişkenliğini minimize etmek. k -means'e benziyor ama orada $\underline{x}$ 'lerin değişkenliği minimize ediliyor.
- **Bölme adımı (greedy algoritma):** Her değişken için en iyi kesim noktası s bulunur — bölmeden önce ile sonrasındaki varyans farkını maksimize eden s :

$$\sum_{i=1}^n (y_i - \bar{y})^2 - \left[\sum_{x_{j1} < s} (y_j - \bar{y}_1)^2 + \sum_{x_{j1} \geq s} (y_j - \bar{y}_2)^2 \right] \quad \text{maksimize edilir} \quad (23)$$

Tüm p değişken için tekrarlanır, en büyük farkı veren değişken ve kesim noktası seçilir.

- **Duruş koşulu:** Bir bölgedeki nokta sayısı C 'nin altına düştüğünde bölmeyi durdur. $C = 1$ 'de durursak mükemmel overfitting olur.
- **Not:** Bölünme aynı yönde birden fazla kez, farklı dikdörtgenler için yapılabilir.
- **Neden sonsuza kadar bölmüyoruz?** Her noktayı kendi bölgesine koymak eğitim hatasını sıfırlar ama yeni veriyi tahmin edemez hale getirir. Bu **overfitting (aşırı uydurma)**dır.
- **Budama (Pruning):** Büyük bir ağaç kurulur, sonra ceza fonksiyonu ile aşağıdan yukarıya budanır:

$$W(m, \alpha) = \sum_{i=1}^m (y_i - \bar{y})^2 + \alpha m \quad (24)$$

m = yaprak bölge sayısı, α = karmaşıklık cezası.

- α büyükse $\rightarrow$ çok bölge cezalandırılır $\rightarrow$ basit ağaç (az yaprak).
- α küçükse $\rightarrow$ çok bölgeye izin verilir $\rightarrow$ karmaşık ağaç (çok yaprak).
- α , **çapraz doğrulama** ile seçilir. α sabitlenir, W ile m grafiği çizilir, **dirsek yöntemi** ile m seçilir.
- **Not:** Bu, doğrusal modellerde çok fazla değişken içeren modelleri cezalandırmaya (LASSO gibi) benzer.
- **Gini İndeksi (Sınıflandırma için):** y kategorik ise varyans kriteri yerine Gini kullanılır:

$$\sum_{\underline{x}_j \in R} \sum_{k=1}^K p_k (1 - p_k) \quad (25)$$

Gini = 0 $\Rightarrow$ bölge tamamen saf (tek sınıf). Bölme ile saflık maksimize edilir.

- **Random Forest:** CART tek başına doğrusal modelleri yenemez. Ama birçok CART ağacı, her biri bootstrap ile farklı veri alt kümelerinden öğrenerek kurulur; tahminlerin ortalaması alınır. Değişkenler de bootstraplanabilir. Çok daha güçlü tahmin sağlar. **Tek sorun:** Yorumlama güçleşir.

3. Doğrusal Regresyon — “En İyi Doğruyu Bul”

- **Temel varsayım:** f 'nin (dönüştürülmüş) değişkenlerde doğrusal olduğunu varsayıyoruz.

- Orijinal değişkenler $x_1, \dots, x_p$ dönüştürülür: $z_k = h_k(x_1, \dots, x_p)$.
- **Örnek:** $z_1 = x_1$, $z_2 = x_1^2$, $z_3 = \log(x_3)$ — model hâlâ “doğrusal” çünkü β ’larda doğrusal.
- **Not:** Model z ’lerde doğrusal ama z_i ’ler orijinal x_i ’lerin doğrusal olmayan fonksiyonu olabilir. Yani orijinal değişkenlerde doğrusal olmayan davranışları modelleyebiliriz.
- **Model:** $\mathbb{E}[Y \mid z_1, \dots, z_r] = \beta_0 + \beta_1 z_1 + \dots + \beta_r z_r$, toplamda $r + 1$ bilinmeyen parametre.
- $Y = f(\underline{z}) + \varepsilon$ burada:
 - f ortalamayı tahmin etmek için verinin verdiği tüm bilgiyi yakalar.
 - ε dışarıda bırakılan kısım $\rightarrow$ **artık (residual)** denir.
- **Tasarım matrisi $\mathbb{Z}$:** $n \times (r + 1)$ boyutlu, ilk sütun hep 1 (β_0 için):

$$\mathbb{Z} = \begin{bmatrix} 1 & z_{11} & \dots & z_{1r} \\ \vdots & \vdots & & \vdots \\ 1 & z_{n1} & \dots & z_{nr} \end{bmatrix} \quad (26)$$

- **Model:**

$$\underline{y} = \mathbb{Z} \underline{\beta} + \underline{\varepsilon} \quad (27)$$

- $\underline{y}$: ölçülen çıktılar (orijinal hedef değişkeninin dönüşümü de olabilir).
- $\underline{\beta}$: bilinmeyen parametreler — veriden öğrenilir.
- $\underline{\varepsilon}$: hata vektörü — modelin açıklayamadığı kısım.

- **Hatalar hakkında varsayımlar:**

$$\mathbb{E}[\underline{\varepsilon}] = \underline{0}, \quad \text{Cov}(\underline{\varepsilon}) = \sigma^2 I, \quad \underline{\varepsilon} \perp\!\!\!\perp X_1, \dots, X_p \quad (28)$$

- Hataların ortalaması sıfır.
- Hataların varyansı eşit (σ^2 , homokedastisite) ve birbirinden **korelasyonsuz** (bağımsız değil, sadece korelasyonsuz). σ^2 tahmin edilmesi gerekir.
- Gaussian (normal dağılım) *varsayılmıyor* — sadece hipotez testi ve güven aralıkları için gerekli.

4. ANOVA Aslında Doğrusal Regresyon!

- **Temel içgörü:** g grup varsa, her grup için bir **kukla (dummy) değişken** tanımlanır: o gruptaysa 1, değilse 0. Bu kukla sütunlarla kurulan $\mathbb{Z}$ ile ANOVA tam olarak $\underline{y} = \mathbb{Z} \underline{\beta} + \underline{\varepsilon}$ ’ya dönüşür.
- **ANOVA modeli:**

$$x_{ij} = \mu + \tau_i + \varepsilon_{ij}, \quad \varepsilon_{ij} \stackrel{\text{iid}}{\sim} \mathcal{N}(0, \sigma^2) \quad (29)$$

μ genel ortalama, τ_i i . grubun etkisi, $\underline{\beta} = (\mu, \tau_1, \dots, \tau_g)^T$.

- **Rank problemi:** $g + 1$ sütun (1 sabit + g kukla) kullanırsak $\mathbb{Z}$ **tam rank değil** — kukla sütunların toplamı sabit sütunu veriyor. Bu **aşırı parametrisasyondur**; parametreler özgün olarak belirlenemiyor.

- **Çözüm:** Kısıtı uygula:

$$\sum_{i=1}^g n_i \tau_i = 0 \quad \Longleftrightarrow \quad \tau_g = -\frac{1}{n_g} \sum_{i=1}^{g-1} n_i \tau_i \quad (30)$$

Böylece sadece $g - 1$ kukla sütun kullanılır $\Rightarrow \mathbb{Z}$ artık $n \times g$ boyutunda ve **tam rank**.

- **Not:** Kukla sütunlar veriden türetilmiyor — farklı gruplardan gelen bilginin analize dahil edildiğini hatırlatmak için orada.
- **ANCOVA:** ANOVA'ya sürekli (nicel) kovaryatlar eklenirse ANCOVA elde edilir:

$$X_{ij} = \mu + \tau_i + \beta W_i + \varepsilon_{ij} \quad (31)$$

Grup etkisi τ_i ile sürekli kovaryatın etkisi βW_i birbirinden ayrıştırılmış olur.

- **Sonuç:** ANOVA, ANCOVA ve doğrusal regresyon hepsi $\underline{y} = \mathbb{Z} \underline{\beta} + \underline{\varepsilon}$ çerçevesinin özel halleridir.

5. Temel Sezgiler (Sınav İçin)

- **CART:** Ağaç ne kadar derinleşirse eğitim hatası azalır ama yeni veriye genelleme bozulur. α cezası bu dengeyi kurar.
- **Overfitting:** Eğitim verisini ezberlemek kötüdür. Gerçek hayattaki yeni veriyle karşılaşınca model çuvallar. CART için budama, doğrusal model için değişken seçimi bu sorunu çözer.
- **Bias-Varyans dengesi:** Basit model $\rightarrow$ yüksek bias (yanlış). Karmaşık model $\rightarrow$ yüksek varyans (tutarsız). Çapraz doğrulama ikisi arasındaki en iyi noktayı bulur.
- **“Doğrusal” yanıltması:** Doğrusallık β 'lara göre. x^2 , $\log x$ gibi dönüşümler kullanılabilir — hepsi doğrusal model.
- **ANOVA = Regresyon:** Kukla değişkenler kurulduktan sonra ANOVA ile doğrusal regresyon özdeştir; aynı teori, aynı tahmin, aynı matris denklemi.
- **Random Forest, CART'ı geçer:** Bootstrap ile oluşturulan birbirinden bağımsız ağaçların ortalaması varyansı dramatik biçimde düşürür. Bedeli: yorumlama güçleşir.
- **Hocanın ana sezgisi:** CART, $\underline{x}$ 'leri uzayda gruplarken amacı $\underline{x}$ 'lerin değil $\underline{y}$ 'lerin değişkenliğini minimize etmektir. Haritayı bu amaçla çiziyoruz.