

22 - Inference and Prediction with Linear Models

Inference and prediction with linear models. Confidence region for the vector of beta coefficients. Confidence intervals, one-at-the time and simultaneous, for linear combinations of the beta coefficients. F-test for a finite set of linear combinations of the beta coefficients. F-tests for variable selections. Confidence intervals for the mean of the predicted target. Prediction intervals.

Applied Statistics

Unat Teksen

April 27, 2026

1 Big Picture — Where Are We?

- We have already built a linear regression model:

$$\mathbf{y} = \mathbb{Z}\underline{\beta} + \underline{\varepsilon}$$

- $\mathbf{y}$ is the response, $\mathbb{Z}$ is the design matrix, $\underline{\beta}$ are the true (unknown) coefficients, $\underline{\varepsilon}$ is the error term.
- We estimated $\underline{\beta}$ with OLS, obtaining $\hat{\underline{\beta}}$.
- **Now the questions are:**
 - How reliable are our estimates $\hat{\beta}_i$?
 - Are some coefficients genuinely zero (i.e. some variables useless)?
 - How accurately can we predict a new observation?
- This lecture answers all of these questions through **inference** and **prediction**.

2 Confidence Intervals for a Single β_i

2.1 What Are We Trying to Do?

- We computed $\hat{\beta}_i$ (e.g. “each extra m² increases price by 5000 TL”).
- But this is an estimate from *one* dataset — with different data we’d get a different number.
- **Goal:** Find an interval that contains the *true* β_i with probability $1 - \alpha$.

- R computes **one-at-a-time** confidence intervals by default:

$$CI_{1-\alpha}(\beta_i) = \left[\hat{\beta}_i \pm \sqrt{\text{diag}_i[(\mathbb{Z}^T \mathbb{Z})^{-1}]} S t_{\alpha/2}(n - (r + 1)) \right]$$

- Breaking down the formula:
 - $\hat{\beta}_i$ — our point estimate (center of the interval)
 - $S = \sqrt{\hat{\varepsilon}^T \hat{\varepsilon} / (n - (r + 1))}$ — estimated standard deviation of errors
 - $\text{diag}_i[(\mathbb{Z}^T \mathbb{Z})^{-1}]$ — the i -th diagonal entry; captures the uncertainty specific to $\hat{\beta}_i$
 - $t_{\alpha/2}(n - (r + 1))$ — critical value from the t -distribution with $n - (r + 1)$ degrees of freedom
 - $n - (r + 1)$ degrees of freedom: we have n observations but used $r + 1$ of them to estimate the coefficients

2.2 Example

- Suppose $\hat{\beta}_1 = 5000$ and $S \cdot \sqrt{\text{diag}_1} = 300$.
- For 95% confidence ($t_{\alpha/2} \approx 2$):

$$CI_{0.95}(\beta_1) = [5000 - 2 \cdot 300, 5000 + 2 \cdot 300] = [4400, 5600]$$

- Interpretation: “The true β_1 lies between 4400 and 5600 with 95% probability.”

3 Simultaneous Confidence Intervals

3.1 The Multiple Testing Problem

- If we compute separate 95% CIs for k coefficients, the probability that *all* of them simultaneously contain their true values is **less than 95%**.
- Analogy: rolling 10 dice and wanting all to show 6 is much harder than wanting just one to show 6.
- **Fix:** Use intervals that hold *jointly* with probability $1 - \alpha$.

3.2 Bonferroni Correction

- If you want overall level $1 - \alpha$ for k intervals, ask R for individual intervals at level $1 - \alpha/k$.
- Simple but conservative.

3.3 Simultaneous Confidence Intervals (F-based)

- A stronger approach uses the F distribution:

$$\text{Sim}CI_{1-\alpha}(\beta_i) = \left[\hat{\beta}_i \pm \sqrt{\text{diag}_i[(\mathbb{Z}^T \mathbb{Z})^{-1}]} S \sqrt{(r + 1) \cdot F_{\alpha}(r + 1, n - (r + 1))} \right]$$

- The only change: replace $t_{\alpha/2}$ with a *larger* critical value $\sqrt{(r+1)F_\alpha}$.
- Result: **wider** intervals, but now all $r+1$ intervals hold simultaneously with probability $1 - \alpha$.
- Wider net $\Rightarrow$ catch all coefficients at once.

4 F-Test for a Set of β_i — Testing Linear Combinations

4.1 What Are We Trying to Do?

- Suppose we have 5 variables: size, rooms, age, floor, gated community.
- Question: **Are age, floor, and gated community together useless?** (i.e. are their β 's all zero?)
- We test p linear combinations of $\underline{\beta}$ simultaneously using a matrix C :

$$H_0 : C\underline{\beta} = \underline{0} \quad \text{vs} \quad H_1 : C\underline{\beta} \neq \underline{0}$$

- C is a $p \times (r+1)$ matrix — each row defines one linear combination to test.
- More generally: $H_0 : C\underline{\beta} = \underline{k}_0$ vs $H_1 : C\underline{\beta} \neq \underline{k}_0$, but $\underline{k}_0 = \underline{0}$ is the most common case.

4.2 Distribution of $C\hat{\underline{\beta}}$

- Since $\underline{\hat{\beta}} \sim \mathcal{N}_{r+1}(\underline{\beta}, \sigma^2(\mathbb{Z}^T\mathbb{Z})^{-1})$, taking a linear transformation gives:

$$C\underline{\hat{\beta}} \sim \mathcal{N}_p(\underline{0}, \sigma^2 C(\mathbb{Z}^T\mathbb{Z})^{-1}C^T) \quad \text{under } H_0$$

- Also recall: $\hat{\varepsilon}^T\hat{\varepsilon} \sim \sigma^2\chi^2(n - (r+1))$, and it is **independent** of $C\underline{\hat{\beta}}$.

4.3 The F-Test Statistic

- Taking the ratio of the two (a chi-squared divided by another chi-squared) yields an F distribution:

$$\frac{1}{S^2}(C\underline{\hat{\beta}})^T [C(\mathbb{Z}^T\mathbb{Z})^{-1}C^T]^{-1}(C\underline{\hat{\beta}}) \sim p \cdot F(p, n - (r+1))$$

- **Reject H_0 at level α if:**

$$\frac{1}{S^2}(C\underline{\hat{\beta}})^T [C(\mathbb{Z}^T\mathbb{Z})^{-1}C^T]^{-1}(C\underline{\hat{\beta}}) > p \cdot F_\alpha(p, n - (r+1))$$

- **Intuition:** The numerator measures “how far is $C\underline{\hat{\beta}}$ from 0?” in a variance-adjusted sense. If large relative to noise S^2 , we reject H_0 . It is signal vs. noise.

5 F-Test for Variable Selection — Geometry

5.1 Two Nested Models

- Write $\mathbb{Z} = [\mathbb{Z}_1, \mathbb{Z}_2]$ where $\mathbb{Z}_2$ contains the last p columns (the variables we want to test removing).
- **Big model:** $\mathbf{y} = \mathbb{Z}\underline{\beta} + \underline{\varepsilon}$ — projects $\mathbf{y}$ onto $\mathcal{L}(\mathbb{Z})$
- **Small model:** $\mathbf{y} = \mathbb{Z}_1\underline{\beta}_1 + \underline{\varepsilon}_1$ — projects $\mathbf{y}$ onto $\mathcal{L}(\mathbb{Z}_1) \subset \mathcal{L}(\mathbb{Z})$
- Since $\mathcal{L}(\mathbb{Z}_1)$ is a smaller space, the small model always has **larger residuals**.
- **Key question:** How much more does the big model explain?

5.2 Comparing Residual Sums of Squares

- Define:
 - $SS_{res}(\mathbb{Z}) = \hat{\varepsilon}^T \hat{\varepsilon}$ — residuals from the big model
 - $SS_{res}(\mathbb{Z}_1) = \hat{\varepsilon}_1^T \hat{\varepsilon}_1$ — residuals from the small model
- We **reject** H_0 (the last p coefficients are zero) when the following is large:

$$\frac{1}{S^2 p} (SS_{res}(\mathbb{Z}_1) - SS_{res}(\mathbb{Z})) \sim F(p, n - (r + 1))$$

- **Intuition:** $SS_{res}(\mathbb{Z}_1) - SS_{res}(\mathbb{Z})$ is the extra variation explained by adding those p predictors. Large value $\Rightarrow$ they are useful. Small value $\Rightarrow$ they just fit noise.
- Note that $S^2 = \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n - (r + 1)} = \frac{SS_{res}(\mathbb{Z})}{n - (r + 1)}$

5.3 Special Case: Overall Significance of the Model

- Test: $H_0 : \beta_1 = \beta_2 = \dots = \beta_r = 0$ (all slope coefficients zero)
- Small model becomes $\mathbb{Z}_1 = [1, \dots, 1]^T$ (intercept only — predict $\bar{y}$ for everyone), so $p = r$
- Then $\hat{\varepsilon}_1^T \hat{\varepsilon}_1 = \sum_{i=1}^n (y_i - \bar{y})^2$
- The F-statistic becomes:

$$F = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2 / r}{\sum_{i=1}^n \hat{\varepsilon}_i^2 / (n - (r + 1))} \sim F(r, n - (r + 1))$$

- **This is exactly the F-statistic in R's regression summary output!**
- Large $F \Rightarrow$ model explains much more than noise $\Rightarrow$ model is meaningful.

6 Confidence Intervals for the Mean of the Predicted Target

6.1 Setup

- Model trained. New feature vector arrives: $\underline{z}_0 = (1, z_{01}, \dots, z_{0r})^T$
- True value: $y_0 = \underline{z}_0^T \underline{\beta} + \varepsilon_0$, where $\varepsilon_0 \sim \mathcal{N}(0, \sigma^2)$ and $\varepsilon_0 \perp \underline{\varepsilon}$
- Point estimate: $\underline{z}_0^T \hat{\underline{\beta}}$
- By **Gauss-Markov Theorem**: $\underline{z}_0^T \hat{\underline{\beta}}$ is **BLUE** — Best Linear Unbiased Estimator for $\mathbb{E}[y_0 | \underline{z}_0] = \underline{z}_0^T \underline{\beta}$

6.2 Distribution and Pivotal Quantity

- Since $\hat{\underline{\beta}} \sim \mathcal{N}_{r+1}(\underline{\beta}, \sigma^2(\mathbb{Z}^T \mathbb{Z})^{-1})$:

$$\underline{z}_0^T \hat{\underline{\beta}} \sim \mathcal{N}_1(\underline{z}_0^T \underline{\beta}, \sigma^2 \underline{z}_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} \underline{z}_0)$$

- Since $\hat{\varepsilon}^T \hat{\varepsilon}$ is independent of $\underline{z}_0^T \hat{\underline{\beta}}$, dividing gives:

$$\frac{\underline{z}_0^T \hat{\underline{\beta}} - \underline{z}_0^T \underline{\beta}}{S \sqrt{\underline{z}_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} \underline{z}_0}} \sim t(n - (r + 1))$$

6.3 Confidence Interval for $\mathbb{E}[y_0 | \underline{z}_0]$

$$CI_{1-\alpha}(\underline{z}_0^T \underline{\beta}) = \left[\underline{z}_0^T \hat{\underline{\beta}} \pm S \sqrt{\underline{z}_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} \underline{z}_0} t_{\alpha/2}(n - (r + 1)) \right]$$

- **Key geometric insight**: The term $\sqrt{\underline{z}_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} \underline{z}_0}$ **increases** as $\underline{z}_0$ moves away from the baricenter $\bar{z}$ of the training data.
- Confidence intervals are **narrowest at the center** of the data and **widen as you extrapolate**.
- Example: if you trained on houses of 50–150 m², you're most confident predicting 100 m² houses and least confident predicting 300 m² houses.

6.4 Simultaneous CI for the Regression Line

- One-at-a-time CIs form an envelope region R , but R does **not** simultaneously contain the true regression line with probability $1 - \alpha$.
- For simultaneous coverage over all $\underline{z}_0$:

$$SimCI_{1-\alpha}(\underline{z}_0^T \underline{\beta}) = \left[\underline{z}_0^T \hat{\underline{\beta}} \pm S \sqrt{\underline{z}_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} \underline{z}_0} \sqrt{(r + 1) F_{\alpha}(r + 1, n - (r + 1))} \right]$$

- This gives a **larger band** that contains the true regression function with probability $1 - \alpha$ for *all* $\underline{z}_0$ simultaneously.

7 Prediction Intervals

7.1 CI vs PI — The Most Important Distinction

- **Confidence Interval (CI):** For the **mean** $\mathbb{E}[y_0|z_0]$ — what is the average outcome for this type of input?
- **Prediction Interval (PI):** For the **actual individual observation** y_0 — what will this specific new data point be?
- **PI is always wider than CI** because there are two sources of uncertainty:
 1. Uncertainty about the mean: $\underline{z}_0^T \hat{\underline{\beta}}$ vs $\underline{z}_0^T \underline{\beta}$ (variance: $\sigma^2 \underline{z}_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} \underline{z}_0$)
 2. Intrinsic variability of y_0 around its mean (variance: σ^2)

7.2 Derivation

- Since $y_0 \perp \underline{z}_0^T \hat{\underline{\beta}}$ (new observation independent of training):

$$y_0 - \underline{z}_0^T \hat{\underline{\beta}} \sim \mathcal{N}(0, \sigma^2(1 + \underline{z}_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} \underline{z}_0))$$

- Note the **+1** compared to the CI case — this accounts for the intrinsic variability of y_0 .
- Combined with $\hat{\varepsilon}^T \hat{\varepsilon} \sim \sigma^2 \chi^2(n - (r + 1))$ (independent of $y_0 - \underline{z}_0^T \hat{\underline{\beta}}$):

$$\frac{y_0 - \underline{z}_0^T \hat{\underline{\beta}}}{S \sqrt{1 + \underline{z}_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} \underline{z}_0}} \sim t(n - (r + 1))$$

7.3 Prediction Interval Formula

$$PI_{1-\alpha}(y_0) = \left[\underline{z}_0^T \hat{\underline{\beta}} \pm S \sqrt{1 + \underline{z}_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} \underline{z}_0} t_{\alpha/2}(n - (r + 1)) \right]$$

- The only difference from CI: **+1 inside the square root**.
- **Intuition example:**
 - “What is the average sleep duration in Istanbul?” → CI (for the mean)
 - “How long will Ahmet sleep tomorrow?” → PI (for an individual)
 - Ahmet’s sleep varies randomly around the average, so PI is wider.

7.4 Simultaneous Prediction Intervals

- If we plot all one-at-a-time PIs, we **do not** get a prediction region for y with simultaneous coverage.
- For simultaneous prediction:

$$SimPI_{1-\alpha} = \left[\underline{z}_0^T \hat{\underline{\beta}} \pm S \sqrt{1 + \underline{z}_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} \underline{z}_0} \sqrt{(r + 2) F_{\alpha}(r + 2, n - (r + 1))} \right]$$

- Note: F has $r+2$ degrees of freedom here (one extra compared to SimCI), accounting for the extra variability of y_0 itself.

7.5 Summary of CI vs PI

- **Conclusion:**
 - Confidence intervals $\rightarrow$ for the *mean* of what we predict
 - Prediction intervals $\rightarrow$ for the *actual value* we predict; they also account for the variability σ^2 of the distribution, so they are always larger

8 Generalised Least Squares (GLS)

8.1 The Problem with OLS

- OLS assumes $\text{Cov}(\underline{\varepsilon}) = \sigma^2 I$ — errors are uncorrelated with equal variance.
- This fails when:
 - Repeated measurements on the same individual (correlated errors)
 - Data from groups of very different sizes (different variances)
- Example: average wage in Istanbul (1M people) vs. average wage in Bartın (10K people) — Istanbul's average is far more reliable.

8.2 GLS Setup

- Now: $\text{Cov}(\underline{\varepsilon}) = W\sigma^2$ where W is a known $n \times n$ positive definite matrix.
- **GLS minimizes the Mahalanobis distance:**

$$\hat{\underline{\beta}} = \arg \min_{\underline{\beta}} (\mathbf{y} - \mathbb{Z}\underline{\beta})^T W^{-1} (\mathbf{y} - \mathbb{Z}\underline{\beta})$$

- Closed-form solution:

$$\hat{\underline{\beta}}_{GLS} = (\mathbb{Z}^T W^{-1} \mathbb{Z})^{-1} \mathbb{Z}^T W^{-1} \mathbf{y}$$

- If $W = I$ we recover OLS. The W^{-1} notation is used for notational reasons.

8.3 GLS = Transform + OLS

- Key insight: set $\tilde{\mathbf{y}} = W^{-1/2} \mathbf{y}$ and $\tilde{\mathbb{Z}} = W^{-1/2} \mathbb{Z}$.
- Then $W^{-1/2} \mathbf{y} = W^{-1/2} \mathbb{Z} \underline{\beta} + W^{-1/2} \underline{\varepsilon}$ and:

$$\text{Cov}(W^{-1/2} \underline{\varepsilon}) = \sigma^2 W^{-1/2} W W^{-1/2} = \sigma^2 I \quad \leftarrow \text{back to OLS!}$$

- **GLS = transform the data to uncorrelate the errors, then apply OLS.**
- Mahalanobis distance in the original space $\equiv$ Euclidean distance in the transformed space.
- In the first step (computing $\hat{\underline{\beta}}$) we use Mahalanobis Distance. Once the covariance structure is such that errors are uncorrelated, we can use the Euclidean distance.

9 Weighted Least Squares (WLS) — Special Case of GLS

9.1 Setup

- If $\text{Cov}(\underline{\varepsilon}) = \sigma^2 \text{diag}(w_1, \dots, w_n)$ — errors independent but different variances — then $W = \text{diag}(w_1, \dots, w_n)$.
- WLS minimizes a **weighted sum of squared residuals**:

$$\hat{\underline{\beta}}_{WLS} = \arg \min_{\underline{\beta}} \sum_{i=1}^n \frac{1}{w_i} (y_i - \underline{z}_i^T \underline{\beta})^2$$

- Small w_i (small variance, reliable observation) $\Rightarrow$ large weight $1/w_i \Rightarrow$ **more influence on the fit**.

9.2 Example 1 — City Averages

- y_i = average wage in city i , computed from n_i people.
- $\text{Var}(y_i) = \sigma^2/n_i$, so $W = \text{diag}(1/n_1, \dots, 1/n_n)$ and weight = n_i .
- Cities with more people have smaller variance $\Rightarrow$ get more weight. Correct!

9.3 Example 2 — City Totals (COVID Cases)

- y_i = total COVID cases in city i (sum of n_i observations).
- $\text{Var}(y_i) = n_i \sigma^2$, so $W = \text{diag}(1/n_1, \dots, 1/n_n)$ and weight = $1/n_i$.
- Larger cities have **more variance** (larger total counts scatter more) $\Rightarrow$ get **less weight**.
- **Important:** You cannot simply divide cases by population and treat all cities equally — the variance of the total count scales with population size. WLS correctly handles this.

9.4 Conclusion

- **Weighted Least Squares can be seen in two equivalent ways:**
 - As a **change of metric** (Mahalanobis instead of Euclidean distance)
 - As a **transformation of data** (multiply by $W^{-1/2}$, then OLS)

10 Summary Table

Question	Tool	Key feature
How reliable is $\hat{\beta}_i$?	One-at-a-time CI	Uses S , $t_{\alpha/2}$, diag of $(\mathbb{Z}^T \mathbb{Z})^{-1}$
All $\hat{\beta}_i$ reliable jointly?	Simultaneous CI	Larger critical value via F
Are these p variables useless?	F-test (matrix C)	Compare SS_{res} of two models
Is the model meaningful at all?	Global F-test	R's summary F-statistic
What is $\mathbb{E}[y_0 \underline{z}_0]$?	CI for prediction	Width grows away from $\bar{z}$
What will y_0 actually be?	Prediction Interval	Extra +1 in square root
Errors not equal/correlated?	GLS / WLS	Weighted or transformed OLS

Core theme: Uncertainty grows when you are far from the data center, when you test many things at once, or when you try to predict individual observations rather than means.

Türkçe Özet — Basit Anlatım

Büyük Resim — Neredeyiz?

- Elimizde bir doğrusal regresyon modeli var:

$$\mathbf{y} = \mathbb{Z}\underline{\beta} + \underline{\varepsilon}$$

- $\mathbf{y}$ = tahmin etmek istediğimiz şey, $\mathbb{Z}$ = tasarım matrisi, $\underline{\beta}$ = gerçek (bilinmeyen) katsayılar, $\underline{\varepsilon}$ = hata terimi.
- OLS ile $\hat{\underline{\beta}}$ 'yi hesapladık. Şimdi soru: **bu tahminlere ne kadar güvenebiliriz?**
- Bu dersin tamamı şu üç soruya cevap verir:
 - $\hat{\beta}_i$ değerleri ne kadar güvenilir?
 - Bazı katsayılar gerçekten sıfır mı (yani bazı değişkenler gereksiz mi)?
 - Yeni bir gözlem için ne kadar doğru tahmin yapabiliriz?
- Bu sorulara **çıkarm (inference)** ve **tahmin (prediction)** yöntemleriyle cevap veriyoruz.

Tek Tek Güven Aralığı — “Katsayıya Ne Kadar Güveniyoruz?”

- $\hat{\beta}_1 = 5000$ bulduk diyelim: her ekstra m² fiyatı 5000 TL artırıyor.
- Ama bu sadece bir tahmin. Başka veri olsaydı 4800 veya 5200 çıkabilirdi.
- Soru: **Gerçek β_1 'in %95 ihtimalle hangi aralıkta olduğunu söyleyebilir miyim?**
- R'in verdiği tek-tek güven aralığı:

$$CI_{1-\alpha}(\beta_i) = \left[\hat{\beta}_i \pm \sqrt{\text{diag}_i[(\mathbb{Z}^T \mathbb{Z})^{-1}] S t_{\alpha/2}(n - (r + 1))} \right]$$

- Formülün parçaları:
 - $\hat{\beta}_i$ — nokta tahminimiz (aralığın merkezi)
 - $S = \sqrt{\hat{\varepsilon}^T \hat{\varepsilon} / (n - (r + 1))}$ — hataların tahmini standart sapması
 - $\text{diag}_i[(\mathbb{Z}^T \mathbb{Z})^{-1}]$ — i -inci köşegen eleman; $\hat{\beta}_i$ 'ye özgü belirsizliği verir
 - $t_{\alpha/2}(n - (r + 1))$ — t dağılımından kritik değer
 - $n - (r + 1)$ serbestlik derecesi: n gözlem var, $r + 1$ katsayı tahmin ettik, geri kalanı serbest
- Örnek: $\hat{\beta}_1 = 5000$, $S \cdot \sqrt{\text{diag}_1} = 300$, $t_{\alpha/2} \approx 2$ ise:

$$CI_{0.95}(\beta_1) = [5000 - 2 \cdot 300, 5000 + 2 \cdot 300] = [4400, 5600]$$

- “Gerçek β_1 , %95 ihtimalle 4400 ile 5600 arasındadır.”
- **Önemli problem:** R her katsayıyı ayrı ayrı %95 ile verir. Ama bu aralıkların *hepsinin aynı anda* doğru olma ihtimali %95'ten azdır. Bunu düzeltmek gerekir.

Eş Zamanlı Güven Aralıkları

- Problem: 10 katsayı için ayrı ayrı %95 CI hesaplırsak, hepsinin aynı anda doğru olma ihtimali %95'ten azdır.
- Benzetme: 10 zar atıyorsun, hepsinin 6 gelmesini istiyorsun — tek birinin 6 gelmesinden çok daha zor.
- **Bonferroni düzeltmesi:** k aralık için genel $1 - \alpha$ istiyorsan, her birini $1 - \alpha/k$ güvenle hesapla. Basit ama muhafazakar.
- Daha güçlü yöntem — F dağılımı kullanarak:

$$\text{SimCI}_{1-\alpha}(\beta_i) = \left[\hat{\beta}_i \pm \sqrt{\text{diag}_i[(\mathbb{Z}^T \mathbb{Z})^{-1}] S \sqrt{(r+1) \cdot F_{\alpha}(r+1, n - (r+1))}} \right]$$

- Tek fark: $t_{\alpha/2}$ yerine daha büyük kritik değer $\sqrt{(r+1)F_{\alpha}}$ kullanılıyor.
- Sonuç: **daha geniş** aralıklar, ama tüm $r+1$ aralık aynı anda $1 - \alpha$ olasılıkla doğru.
- Daha geniş ağ at $\Rightarrow$ hepsini aynı anda yakala.

F-Testi — “Bu Katsayılar Gerçekten İşe Yarıyor Mu?”

- 5 değişkenin var: metrekare, oda sayısı, yaş, kat, site içi mi?
- Soru: **Yaş, kat ve site katsayıları hep sıfır mı? Bunlar modelden çıkarılabilir mi?**
- p tane doğrusal kombinasyonu aynı anda test etmek için C matrisi kullanıyoruz:

$$H_0 : C\underline{\beta} = \underline{0} \quad \text{vs} \quad H_1 : C\underline{\beta} \neq \underline{0}$$

- C , $p \times (r+1)$ boyutlu bir matris; her satırı test etmek istediğimiz bir doğrusal kombinasyonu tanımlar.
- Daha genel: $H_0 : C\underline{\beta} = \underline{k}_0$ vs $H_1 : C\underline{\beta} \neq \underline{k}_0$, ama $\underline{k}_0 = \underline{0}$ en yaygın durum.
- $\underline{\hat{\beta}} \sim \mathcal{N}_{r+1}(\underline{\beta}, \sigma^2(\mathbb{Z}^T \mathbb{Z})^{-1})$ olduğundan, H_0 altında:

$$C\underline{\hat{\beta}} \sim \mathcal{N}_p(\underline{0}, \sigma^2 C(\mathbb{Z}^T \mathbb{Z})^{-1} C^T)$$

- Ayrıca $\hat{\varepsilon}^T \hat{\varepsilon} \sim \sigma^2 \chi^2(n - (r+1))$ ve $C\underline{\hat{\beta}}$ 'dan **bağımsız**.
- İkisinin oranından F dağılımı elde edilir. **Test istatistiği:**

$$\frac{1}{S^2} (C\underline{\hat{\beta}})^T [C(\mathbb{Z}^T \mathbb{Z})^{-1} C^T]^{-1} (C\underline{\hat{\beta}}) \sim p \cdot F(p, n - (r+1))$$

- **α düzeyinde H_0 reddedilir, eğer:**

$$\frac{1}{S^2} (C\underline{\hat{\beta}})^T [C(\mathbb{Z}^T \mathbb{Z})^{-1} C^T]^{-1} (C\underline{\hat{\beta}}) > p \cdot F_{\alpha}(p, n - (r+1))$$

- **Sezgi:** Pay, “ $C\underline{\hat{\beta}}$ sıfırdan ne kadar uzak?” sorusunu varyansa göre düzeltilmiş biçimde ölçer. Gürültüye (S^2) göre büyükse H_0 'ı reddet. Yani: sinyal mi, gürültü mü?

Değişken Seçimi için F-Testi — Geometri

- $\mathbb{Z} = [\mathbb{Z}_1, \mathbb{Z}_2]$ yaz; $\mathbb{Z}_2$ çıkarmak istediğimiz son p sütunu içeriyor.
- **Büyük model:** $\mathbf{y} = \mathbb{Z}\beta + \varepsilon$ — $\mathbf{y}$ 'yi $\mathcal{L}(\mathbb{Z})$ üzerine yansıt
- **Küçük model:** $\mathbf{y} = \mathbb{Z}_1\beta_1 + \varepsilon_1$ — $\mathbf{y}$ 'yi $\mathcal{L}(\mathbb{Z}_1) \subset \mathcal{L}(\mathbb{Z})$ üzerine yansıt
- $\mathcal{L}(\mathbb{Z}_1)$ daha küçük bir uzay olduğundan küçük modelin artıkları her zaman daha büyük.
- **Kilit soru:** Büyük model ne kadar daha fazla şey açıklıyor?
- Her modelin artık kareler toplamını (SS_{res}) hesapla:
 - $SS_{res}(\mathbb{Z}) = \hat{\varepsilon}^T \hat{\varepsilon}$ — büyük modelin artıkları
 - $SS_{res}(\mathbb{Z}_1) = \hat{\varepsilon}_1^T \hat{\varepsilon}_1$ — küçük modelin artıkları
- **H_0 reddedilir** (son p katsayı sıfır değil) eğer şu büyükse:

$$\frac{SS_{res}(\mathbb{Z}_1) - SS_{res}(\mathbb{Z})}{S^2 \cdot p} \sim F(p, n - (r + 1))$$

- Not: $S^2 = \frac{\hat{\varepsilon}^T \hat{\varepsilon}}{n - (r + 1)} = \frac{SS_{res}(\mathbb{Z})}{n - (r + 1)}$
- **Sezgi:** $SS_{res}(\mathbb{Z}_1) - SS_{res}(\mathbb{Z})$, o p değişkeni ekleyince “fazladan açıklanan varyasyon” dur. Büyükse değişkenler işe yarıyor. Küçükse sadece gürültüyü fit ediyorlar $\Rightarrow$ at.

Özel Durum: Modelin Genel Anlamlılığı

- Test: $H_0 : \beta_1 = \beta_2 = \dots = \beta_r = 0$ (tüm eğim katsayıları sıfır)
- Küçük model: $\mathbb{Z}_1 = [1, \dots, 1]^T$ (sadece sabit terim — herkes için $\bar{y}$ tahmin et), $p = r$
- O zaman $\hat{\varepsilon}_1^T \hat{\varepsilon}_1 = \sum_{i=1}^n (y_i - \bar{y})^2$
- F istatistiği:

$$F = \frac{\sum_{i=1}^n (\hat{y}_i - \bar{y})^2 / r}{\sum_{i=1}^n \hat{\varepsilon}_i^2 / (n - (r + 1))} \sim F(r, n - (r + 1))$$

- **Bu, R'in regresyon özetindeki F istatistiğinin ta kendisi!**
- Büyük $F \Rightarrow$ model gürültüden çok daha fazlasını açıklıyor $\Rightarrow$ model anlamlı.
- Küçük $F \Rightarrow$ model sadece ortalamayı tahmin etmekten farklı değil.

Tahmin için Güven Aralığı — $\mathbb{E}[y_0|z_0]$

- Model eğitildi. Yeni gözlem geldi: $z_0 = (1, z_{01}, \dots, z_{0r})^T$
- Gerçek değer: $y_0 = z_0^T \underline{\beta} + \varepsilon_0$, burada $\varepsilon_0 \sim \mathcal{N}(0, \sigma^2)$ ve $\varepsilon_0 \perp \underline{\varepsilon}$
- Nokta tahmini: $z_0^T \hat{\underline{\beta}}$
- **Gauss-Markov Teoremi:** $z_0^T \hat{\underline{\beta}}, \mathbb{E}[y_0|z_0] = z_0^T \underline{\beta}$ için **BLUE** (En İyi Doğrusal Yansız Tahminleyici).
- Dağılım:

$$z_0^T \hat{\underline{\beta}} \sim \mathcal{N}_1(z_0^T \underline{\beta}, \sigma^2 z_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} z_0)$$

- $\hat{\varepsilon}^T \hat{\varepsilon}, z_0^T \hat{\underline{\beta}}$ 'dan bağımsız olduğundan pivotal nicelik:

$$\frac{z_0^T \hat{\underline{\beta}} - z_0^T \underline{\beta}}{S \sqrt{z_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} z_0}} \sim t(n - (r + 1))$$

- $\mathbb{E}[y_0|z_0]$ için güven aralığı:

$$CI_{1-\alpha}(z_0^T \underline{\beta}) = \left[z_0^T \hat{\underline{\beta}} \pm S \sqrt{z_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} z_0} t_{\alpha/2}(n - (r + 1)) \right]$$

- **Geometrik sezgi:** $\sqrt{z_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} z_0}$ terimi, z_0 eğitim verisinin merkezinden (barisentrum $\bar{z}$) uzaklaştıkça **büyür**.
- Güven aralıkları **verinin merkezinde en dar**, dışarı çıktıkça genişler.
- Örnek: 50–150 m² evler üzerinde eğittik $\Rightarrow$ 100 m² için harika tahmin, 300 m² için kötü tahmin. Model bunu otomatik yansıtır.
- **Tek-tek CI'ların problemi:** Tüm z_0 için CI'lar çizip zarfı (R bölgesi) alırsak, bu zarfın gerçek regresyon doğrusunu $1 - \alpha$ olasılıkla içerdiği **garanti edilmez**.
- Çözüm — tüm z_0 için eş zamanlı CI:

$$SimCI_{1-\alpha}(z_0^T \underline{\beta}) = \left[z_0^T \hat{\underline{\beta}} \pm S \sqrt{z_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} z_0} \sqrt{(r + 1) F_{\alpha}(r + 1, n - (r + 1))} \right]$$

- Bu daha geniş bir bant verir; gerçek regresyon fonksiyonu tüm z_0 için aynı anda $1 - \alpha$ olasılıkla bu bandın içinde kalır.

CI vs PI — En Önemli Ayrım

- **Güven Aralığı (CI):** $\mathbb{E}[y_0|z_0]$ için — bu girdi için *ortalama* sonuç nedir?
- **Tahmin Aralığı (PI):** Gerçek bireysel y_0 için — bu spesifik yeni gözlem ne olacak?
- **PI her zaman CI'dan geniştir** — iki belirsizlik kaynağı var:
 1. Ortalamayı tam bilmiyoruz: $z_0^T \hat{\underline{\beta}}$ ile $z_0^T \underline{\beta}$ arasındaki fark (varyans: $\sigma^2 z_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} z_0$)
 2. y_0 'ın kendi ortalamasından rastgele sapması (varyans: σ^2)

- $y_0 \perp \underline{z}_0^T \hat{\underline{\beta}}$ (yeni gözlem eğitim setinden bağımsız) olduğundan:

$$y_0 - \underline{z}_0^T \hat{\underline{\beta}} \sim \mathcal{N}(0, \sigma^2(1 + \underline{z}_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} \underline{z}_0))$$

- CI ile karşılaştır: orada $\sigma^2 \underline{z}_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} \underline{z}_0$ vardı, burada **+1** eklendi.
- Bu +1 = y_0 'ın kendine özgü rastgeleliği (ε_0).
- $\hat{\varepsilon}^T \hat{\varepsilon}$ 'dan bağımsızlık ve chi-kare ile:

$$\frac{y_0 - \underline{z}_0^T \hat{\underline{\beta}}}{S \sqrt{1 + \underline{z}_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} \underline{z}_0}} \sim t(n - (r + 1))$$

- **Tahmin Aralığı formülü:**

$$PI_{1-\alpha}(y_0) = \left[\underline{z}_0^T \hat{\underline{\beta}} \pm S \sqrt{1 + \underline{z}_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} \underline{z}_0} t_{\alpha/2}(n - (r + 1)) \right]$$

- **Örnek:**

- “İstanbul’da insanlar ortalama kaç saat uyuyor?” → CI (ortalama için)
- “Ahmet yarın kaç saat uyuyacak?” → PI (tek gözlem için)
- Ahmet’in uykusu ortalamasının etrafında rastgele değişir ⇒ PI daha geniş.

- **Sonuç:**

- Güven aralıkları → tahmin ettiğimiz şeyin *ortalaması* için
- Tahmin aralıkları → tahmin ettiğimiz *gerçek değer* için; dağılımın σ^2 varyansını da hesaba katar, bu yüzden her zaman daha geniştir

- Eş zamanlı tahmin aralıkları (tüm y_0 için aynı anda):

$$SimPI_{1-\alpha} = \left[\underline{z}_0^T \hat{\underline{\beta}} \pm S \sqrt{1 + \underline{z}_0^T (\mathbb{Z}^T \mathbb{Z})^{-1} \underline{z}_0} \sqrt{(r + 2) F_{\alpha}(r + 2, n - (r + 1))} \right]$$

- Not: F burada $r + 2$ serbestlik derecesine sahip (SimCI’den bir fazla), y_0 ’ın ekstra değişkenliğini de hesaba katar.

GLS — Hatalar Eşit Değilse

- OLS varsayımı: $\text{Cov}(\underline{\varepsilon}) = \sigma^2 I$ (eşit varyans, bağımsız). Bu her zaman doğru değil.
- Başarısız olduğu durumlar:
 - Aynı kişi üzerinde tekrarlı ölçümler (korelasyonlu hatalar)
 - Çok farklı büyüklükteki gruplardan gelen veri (farklı varyanslar)
- Örnek: İstanbul ortalaması (1M kişi) vs Bartın ortalaması (10K kişi) — İstanbul çok daha güvenilir.
- Şimdi: $\text{Cov}(\underline{\varepsilon}) = W \sigma^2$, burada W bilinen $n \times n$ pozitif tanımlı matris.

- **GLS, Mahalanobis mesafesini minimize eder:**

$$\hat{\underline{\beta}} = \arg \min_{\underline{\beta}} (\mathbf{y} - \mathbb{Z}\underline{\beta})^T W^{-1} (\mathbf{y} - \mathbb{Z}\underline{\beta})$$

- Kapalı form çözüm:

$$\hat{\underline{\beta}}_{GLS} = (\mathbb{Z}^T W^{-1} \mathbb{Z})^{-1} \mathbb{Z}^T W^{-1} \mathbf{y}$$

- $W = I$ ise OLS'ye dönülür.

- **GLS = Dönüştür + OLS:** $\tilde{\mathbf{y}} = W^{-1/2} \mathbf{y}$ ve $\tilde{\mathbb{Z}} = W^{-1/2} \mathbb{Z}$ tanımla:

$$W^{-1/2} \mathbf{y} = W^{-1/2} \mathbb{Z} \underline{\beta} + W^{-1/2} \underline{\varepsilon}$$

$$\text{Cov}(W^{-1/2} \underline{\varepsilon}) = \sigma^2 W^{-1/2} W W^{-1/2} = \sigma^2 I \quad \leftarrow \text{OLS varsayımına döndük!}$$

- **Sezgi:** Hataları korelasyonsuz hale getirecek şekilde veriyi dönüştür, sonra normal OLS uygula.
- Orijinal uzayda Mahalanobis mesafesi $\equiv$ dönüştürülmüş uzayda Öklid mesafesi.
- İlk adımda ($\hat{\underline{\beta}}$ hesaplanırken) Mahalanobis mesafesi kullanılır. Hatalar korelasyonsuz hale gelince Öklid mesafesi kullanılabilir.

WLS — GLS'nin Özel Hali

- Eğer $\text{Cov}(\underline{\varepsilon}) = \sigma^2 \text{diag}(w_1, \dots, w_n)$ (hatalar bağımsız ama farklı varyanslı) ise $W = \text{diag}(w_1, \dots, w_n)$ ve **Ağırlıklı En Küçük Kareler (WLS)** elde edilir:

$$\hat{\underline{\beta}}_{WLS} = \arg \min_{\underline{\beta}} \sum_{i=1}^n \frac{1}{w_i} (y_i - \mathbb{z}_i^T \underline{\beta})^2$$

- Küçük w_i (küçük varyans, güvenilir gözlem) $\Rightarrow$ büyük ağırlık $1/w_i \Rightarrow$ modele daha çok etki eder.
- Daha az belirsiz olduğumuz gözlemlere daha fazla ağırlık veriyoruz.
- **Örnek 1 — Şehir Ortalamaları:**
 - y_i = şehir i 'nin ortalama ücreti, n_i kişiden hesaplandı
 - $\text{Var}(y_i) = \sigma^2/n_i$, dolayısıyla $W = \text{diag}(1/n_1, \dots, 1/n_n)$, ağırlık = n_i
 - Büyük şehir $\Rightarrow$ daha az varyans $\Rightarrow$ daha fazla ağırlık. Doğru!
- **Örnek 2 — Şehir Toplamları (COVID Vakaları):**
 - y_i = şehir i 'deki toplam vaka sayısı (n_i gözlemin toplamı)
 - $\text{Var}(y_i) = n_i \sigma^2$, dolayısıyla $W = \text{diag}(n_1, \dots, n_n)$, ağırlık = $1/n_i$
 - Büyük şehir $\Rightarrow$ daha fazla varyans $\Rightarrow$ daha az ağırlık
 - **Önemli:** Vaka sayısını nüfusa bölüp herkese eşit davranamassın — toplam sayının varyansı nüfus büyüklüğüyle orantılı. WLS bunu doğru şekilde ele alır.
- **Sonuç:** WLS iki eşdeğer bakışla görülebilir:
 - **Metrik değişimi** olarak: Öklid yerine Mahalanobis mesafesi kullanmak
 - **Veri dönüşümü** olarak: $W^{-1/2}$ ile çarp, sonra OLS uygula

Özet Tablo

Soru	Araç	Anahtar Özellik
$\hat{\beta}_i$ ne kadar güvenilir?	Tek-tek CI	$S, t_{\alpha/2}, (\mathbb{Z}^T \mathbb{Z})^{-1}$ köşegeni
Hepsi birden güvenilir mi?	Eş zamanlı CI	F ile daha büyük kritik değer
Bu p değişken gereksiz mi?	F-testi (C matrisi)	İki modelin SS_{res} 'ini karşılaştır
Model anlamlı mı?	Global F-testi	R özetindeki F istatistiği
$\mathbb{E}[y_0 z_0]$ nedir?	Tahmin CI'sı	Merkez uzaklaştıkça genişler
y_0 gerçekte ne olacak?	Tahmin Aralığı (PI)	Karekök içinde +1 var
Hatalar eşit değil/korelasyonlu?	GLS / WLS	Ağırlıklı veya dönüştürülmüş OLS

Ana fikir: Belirsizlik; verinin merkezinden uzaklaştığında, aynı anda çok şeyi test ettiğinde veya ortalamaları değil bireysel gözlemleri tahmin etmeye çalıştığında artar.