

23 - Diagnostics for Linear Models: Residual Analysis, Studentized Residuals, Outliers, Leverages, Influential Points, Cook's Distance, Collinearity and the Variance Inflation Factor

Applied Statistics

Unat Teksen

April 30, 2026

1 Big Picture — Why Diagnostics?

- R^2 alone is **not enough** to validate a model.
- After fitting, we must ask: are the assumptions satisfied? Do the results make sense?
- This process is called **model criticism** and it usually leads to a better model.
- Box described data analysis as an iterative cycle:
 1. **Problem** (data, model, assumptions)
 2. **Estimation procedure**
 3. **Outputs** (estimates, confidence intervals, conclusions)
 4. **Criticism / Diagnostics** → back to step 1
- **Take-home message:** Criticise the model!
- Three main diagnostic tools:
 - **Residuals Analysis** — check model fit, assumptions, outliers
 - **Influential Cases** — check if single observations dominate the analysis
 - **Collinearity** — check if regressors carry redundant information

2 Residuals Analysis

2.1 Error Term vs. Residuals

- The linear model is:

$$\underline{y} = \mathbb{Z}\underline{\beta} + \underline{\varepsilon}, \quad \underline{\varepsilon} \in \mathbb{R}^n, \quad \mathbb{E}[\underline{\varepsilon}] = \underline{0}, \quad \text{Cov}(\underline{\varepsilon}) = \sigma^2 I \quad (1)$$

- The **error term** $\underline{\varepsilon}$ is the true noise — it is **never observable**.
- The **residual vector** is what we actually compute:

$$\hat{\underline{\varepsilon}} = (I - H)\underline{y} \quad (2)$$

where $H = \mathbb{Z}(\mathbb{Z}^T \mathbb{Z})^{-1} \mathbb{Z}^T$ is the hat matrix.

- $\hat{\underline{\varepsilon}}$ is the projection of $\underline{y}$ onto $\mathcal{L}^\perp(\mathbb{Z})$; it has n components but lives in a lower-dimensional subspace: $\hat{\underline{\varepsilon}} \in \mathcal{L}^\perp(\mathbb{Z})$.
- Key properties of residuals:

$$\mathbb{E}[\hat{\underline{\varepsilon}}] = \underline{0}, \quad \text{Cov}(\hat{\underline{\varepsilon}}) = \sigma^2(I - H) \quad (3)$$

- Because $\text{Cov}(\hat{\underline{\varepsilon}}) = \sigma^2(I - H) \neq \sigma^2 I$, the residuals are **correlated** with each other — unlike the true errors.
- If $\underline{\varepsilon}$ is Gaussian:

$$\hat{\underline{\varepsilon}} \sim \mathcal{N}_n(\underline{0}, \sigma^2(I - H)) \quad (4)$$

This is a *singular* Gaussian ($I - H$ is not full rank), so $\hat{\varepsilon}_i$ are **not** i.i.d. realisations of ε_i .

2.2 The Residual Plot

- **Goal:** Detect problems in the model by visualising residuals.
- **What to plot:** Fitted values $\hat{y}_i$ on the x -axis vs. residuals $\hat{\varepsilon}_i$ on the y -axis.
- **What you want to see:** A random cloud centred at zero — no pattern, no shape.
- **Problem patterns:**
 - **Funnel shape** $\Rightarrow$ heteroscedasticity (non-constant variance). Fix: weighted regression or a variance-stabilising transformation (e.g. $\log y$).
 - **Curved shape** $\Rightarrow$ non-linear relationship not captured; add polynomial terms.
 - **Isolated far-off points** $\Rightarrow$ outliers; investigate before removing.
- You can also plot $\hat{\varepsilon}_i$ vs. each regressor z_{ik} ($k = 1, \dots, r$). A pattern suggests a missing polynomial relationship.
- **On outliers:** Do not remove them automatically. Ask why they exist — data error, different population, or genuine signal?

2.3 Studentized Residuals

- Individual residual variances differ:

$$\text{Var}(\hat{\varepsilon}_i) = \sigma^2(1 - h_{ii}), \quad \text{where } h_{ii} = \text{diag}_i(H) \quad (5)$$

- Direct comparison of raw residuals is **misleading** — a larger $\hat{\varepsilon}_i$ may simply reflect a larger natural variance.




Figure 1: Leverage

- We standardise by dividing by the estimated standard deviation:

$$\text{Studentized Residual}_i = \frac{\hat{\varepsilon}_i}{\sqrt{S^2(1 - h_{ii})}} \quad (6)$$

where S^2 is the residual mean square (estimator of σ^2).

- **Outlier rule:** Flag observation i as an outlier if $|\text{Studentized Residual}_i| > 3$ (or > 4 for a stricter threshold).
- **Gaussianity check:** Use a **QQ-plot** of the residuals (or Studentized residuals). If points fall roughly on a straight line, normality is approximately satisfied. The residuals will never be exactly Gaussian; we only need them to be not too far from it.
- **Auto-correlation:** In time-series settings, use the **Durbin–Watson test** to check for correlation between consecutive residuals.

3 Influential Cases

3.1 Leverage

- **Goal:** Identify single observations that dominate the entire regression analysis.
- The diagonal entries of the hat matrix are called **leverages**:

$$h_{ii} = \text{diag}_i(\mathbb{Z}(\mathbb{Z}^T\mathbb{Z})^{-1}\mathbb{Z}^T) \quad (7)$$

- Key facts about h_{ii} :
 - $0 \leq h_{ii} \leq 1$ (follows from $H = H^T$ and $H^2 = H$).
 - h_{ii} depends **only on the design matrix $\mathbb{Z}$** , not on $\underline{y}$. Leverages can be computed *before* fitting the model.
 - A high h_{ii} means observation i is far from the centre of the data in the predictor space (the x -space).

- **The dangerous consequence:** If $h_{ii} \approx 1$:

$$\text{Var}(\hat{\varepsilon}_i) = \sigma^2(1 - h_{ii}) \approx 0 \implies \hat{\varepsilon}_i \approx 0 \quad (8)$$

A high-leverage point is **forced to have a near-zero residual** — it looks like it fits the model perfectly, even if it is a genuine anomaly. This can be used to *lie with statistics*.

- **Rule of thumb:** Flag observations with $h_{ii} > \frac{2(r+1)}{n}$.

3.2 Cook's Distance

- **Idea:** Remove observation i and refit — how much does $\hat{\underline{\beta}}$ change?
 - Full data fit: $\underline{y} = \mathbb{Z}\underline{\beta} + \underline{\varepsilon} \Rightarrow \hat{\underline{\beta}} \in \mathbb{R}^{r+1}$
 - Without observation i : $\underline{y}_{-i} = \mathbb{Z}_{-i}\underline{\beta} + \underline{\varepsilon}_{-i} \Rightarrow \hat{\underline{\beta}}^{(i)} \in \mathbb{R}^{r+1}$
- If $\hat{\underline{\beta}}^{(i)}$ and $\hat{\underline{\beta}}$ are very different, case i is **influential**.
- **Cook's Distance** measures this difference via a Mahalanobis-type distance:

$$D_i = \frac{(\hat{\underline{\beta}}^{(i)} - \hat{\underline{\beta}})^T (\mathbb{Z}^T \mathbb{Z}) (\hat{\underline{\beta}}^{(i)} - \hat{\underline{\beta}})}{S^2(r+1)} \quad (9)$$

- **Equivalent formula** — connects Cook's Distance to Studentized residuals and leverage:

$$D_i = \left(\frac{\hat{\varepsilon}_i}{S\sqrt{1-h_{ii}}} \right)^2 \cdot \frac{h_{ii}}{1-h_{ii}} \cdot \frac{1}{r+1} \quad (10)$$

- First factor: square of the Studentized residual (how badly the point fits).
- Second factor: monotone function of leverage h_{ii} (how extreme the point is in x -space).
- A point needs **both** a large residual and high leverage to be truly influential.
- **Decision rules:**
 - Compare D_i to quantiles of $F(r+1, n-(r+1))$. If $\hat{\underline{\beta}}^{(i)}$ falls outside the confidence region centred at $\hat{\underline{\beta}}$, the two are very different.
 - **Rule of thumb:** $D_i > 1 \Rightarrow$ case i is influential (the median of $F(r+1, n-(r+1))$ is always close to 1).

4 Collinearity and the Variance Inflation Factor

4.1 What is Collinearity?

- **Definition:** One regressor z_j is (almost) a linear combination of the other regressors.
- When columns of $\mathbb{Z}$ are nearly linearly dependent:

- $\mathbb{Z}^T \mathbb{Z}$ is almost singular $\Rightarrow \underline{\hat{\beta}}$ is barely computable.
- $\text{Cov}(\underline{\hat{\beta}}) = \sigma^2 (\mathbb{Z}^T \mathbb{Z})^{-1} \rightarrow \infty$.
- **Why dangerous:** The variance of $\hat{\beta}_j$ is so large that even its **sign** is unreliable.
- **Real-world example:** Suppose $\hat{\beta}_j > 0$ suggests unemployment is positively correlated with inflation, and a policy is made to reduce inflation. Due to collinearity, the true β_j may be negative. The policy then reduces inflation but *increases* unemployment — the opposite of what was intended.

4.2 Variance Formula for $\hat{\beta}_j$

- Using Gram-Schmidt orthogonalisation on the columns of $\mathbb{Z} = [\underline{1} \ z_1 \ \dots \ z_r]$, one derives:

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{\sum_{i=1}^n (z_{ij} - \bar{z}_j)^2 (1 - R_j^2)} = \frac{\sigma^2}{(n-1)S_j^2} \cdot \frac{1}{1 - R_j^2} \quad (11)$$

where:

- $S_j^2 = \frac{1}{n-1} \sum_{i=1}^n (z_{ij} - \bar{z}_j)^2$ is the sample variance of the j -th regressor.
- R_j^2 is the R^2 obtained by **regressing z_j on all other regressors** (treating z_j as the response).
- **Interpretations:**
 - $\text{Var}(\hat{\beta}_j)$ **decreases** when $\sum (z_{ij} - \bar{z}_j)^2$ is large — spreading out the regressor values gives more information.
 - $\text{Var}(\hat{\beta}_j)$ **increases** (to ∞) when $R_j^2 \rightarrow 1$ — meaning z_j is almost perfectly predicted by the other regressors: collinearity!

4.3 The Variance Inflation Factor (VIF)

- **Definition:**

$$\text{VIF}(\hat{\beta}_j) = \frac{1}{1 - R_j^2} \quad (12)$$

- $\text{VIF}(\hat{\beta}_j)$ is the factor by which the variance of $\hat{\beta}_j$ is *inflated* relative to the ideal case where all regressors are orthogonal ($R_j^2 = 0 \Rightarrow \text{VIF} = 1$).
- **Decision rules:**
 - $\text{VIF} = 1$: no collinearity — ideal.
 - $\text{VIF} > 5$: warning — consider investigating.
 - $\text{VIF} > 10$: serious collinearity — consider removing that variable.
- **Note:** This formula holds for any regressor $j = 1, \dots, r$ since we can change the order of regressors in the Gram-Schmidt procedure.

— Türkçe Özet —

5 Büyük Resim — Neden Teşhis Yapıyoruz?

- R^2 tek başına modeli doğrulamak için **yeterli değildir**.
- Model kurulduktan sonra şunu sormalıyız: varsayımlar gerçekten sağlanıyor mu, sonuçlar mantıklı mı?
- Bu sürece **model eleştirisi** denir ve genellikle daha iyi bir modele götürür.
- Box'ın veri analizi döngüsü: Problem $\rightarrow$ Tahmin $\rightarrow$ Çıktılar $\rightarrow$ **Eleştiri / Teşhis** $\rightarrow$ başa dön.
- **Ana mesaj:** Modeli eleştir!
- Üç ana teşhis aracı:
 - **Artık Analizi** — model uyumunu, varsayımları ve aykırı değerleri kontrol et.
 - **Etkili Gözlemler** — tek bir gözlemin analizi ele geçirip geçirmediğini kontrol et.
 - **Çoklu Doğrusallık (Collinearity)** — regressörlerin birbirini tekrar edip etmediğini kontrol et.

6 Artıklar (Residuals)

6.1 Hata Terimi ile Artık Arasındaki Fark

- Doğrusal model:

$$\underline{y} = \underline{Z}\underline{\beta} + \underline{\varepsilon}, \quad \underline{\varepsilon} \in \mathbb{R}^n, \quad \mathbb{E}[\underline{\varepsilon}] = \underline{0}, \quad \text{Cov}(\underline{\varepsilon}) = \sigma^2 I \quad (13)$$

- **Hata terimi** $\underline{\varepsilon}$: gerçek gürültü — asla gözlemleyemeyiz.
- **Artık vektörü** bizim hesapladığımız tahmin hatasıdır:

$$\hat{\underline{\varepsilon}} = (I - H)\underline{y} \quad (14)$$

burada $H = \underline{Z}(\underline{Z}^T \underline{Z})^{-1} \underline{Z}^T$ hat matrisidir.

- $\hat{\underline{\varepsilon}}$, $\underline{y}$ 'nin $\mathcal{L}^\perp(\underline{Z})$ uzayına izdüşümüdür; n bileşeni vardır ama daha düşük boyutlu bir alt uzayda yaşar: $\hat{\underline{\varepsilon}} \in \mathcal{L}^\perp(\underline{Z})$.
- Artıkların temel özellikleri:

$$\mathbb{E}[\hat{\underline{\varepsilon}}] = \underline{0}, \quad \text{Cov}(\hat{\underline{\varepsilon}}) = \sigma^2(I - H) \quad (15)$$

- $\text{Cov}(\hat{\underline{\varepsilon}}) = \sigma^2(I - H) \neq \sigma^2 I$ olduğundan artıklar birbirleriyle **ilişkilidir** — gerçek hata terimlerinden farklı olarak.
- Eğer $\underline{\varepsilon}$ Gaussian ise:

$$\hat{\underline{\varepsilon}} \sim \mathcal{N}_n(\underline{0}, \sigma^2(I - H)) \quad (16)$$

Bu *tekil* (singular) bir Gaussian'dır ($I - H$ tam rank değildir), dolayısıyla $\hat{\varepsilon}_i$ 'ler ε_i 'nin i.i.d. gerçekleştirmeleri **değildir**.

- Farkları özetlersek:
 - Hata terimleri ε_i bağımsız ve aynı varyanslıdır (σ^2).
 - Artıklar $\hat{\varepsilon}_i$ birbirleriyle **ilişkilidir** ve varyansları farklı farklıdır: $\text{Var}(\hat{\varepsilon}_i) = \sigma^2(1 - h_{ii})$.

6.2 Artık Grafiği (Residual Plot)

- **Amaç:** Artıkları görselleştirerek modeldeki sorunları tespit etmek.
- **Ne çizilir:** Yatay eksene $\hat{y}_i$ (tahmin), dikey eksene $\hat{\varepsilon}_i$ (artık).
- **Ne görmek istiyoruz:** Ortalaması sıfır olan, rastgele, şekilsiz bir bulut.
- **Sorun örüntüleri:**
 - **Huni şekli** $\Rightarrow$ değişen varyans (heteroscedasticity). Çözüm: ağırlıklı regresyon veya varyans dengeleyici dönüşüm (örn. $\log y$).
 - **Eğri şekil** $\Rightarrow$ doğrusal olmayan ilişki; polinom terim ekle.
 - **Uzak noktalar** $\Rightarrow$ aykırı değer; silmeden önce nedenini araştır.
- Her regressör z_{ik} ($k = 1, \dots, r$) için de $\hat{\varepsilon}_i$ 'ye karşı grafik çizilebilir. Bir örüntü varsa o regressörle ilgili eksik bir ilişki var demektir.
- **Aykırı değerler hakkında:** Otomatik olarak silme. Neden aykırı olduklarını sor — veri hatası mı, farklı bir popülasyon mu, yoksa gerçek bir sinyal mi?

6.3 Studentized Artıklar

- Her artığın varyansı farklı olduğundan ham artıkları karşılaştırmak yanıltıcıdır.
- Bireysel artık varyansı:

$$\text{Var}(\hat{\varepsilon}_i) = \sigma^2(1 - h_{ii}), \quad \text{burada } h_{ii} = \text{diag}_i(H) \quad (17)$$

- Çözüm: her artığı tahmini standart sapmasına böl:

$$\text{Studentized Artık}_i = \frac{\hat{\varepsilon}_i}{\sqrt{S^2(1 - h_{ii})}} \quad (18)$$

burada S^2 artık ortalama karesidir (σ^2 'nin tahmincisi).

- **Analoji:** 60 cm kar Antalya'da aykırıdır, Erzurum'da değil. Studentized artık, her gözlemi kendi “doğal standardına” göre ölçer.
- **Aykırı değer kuralı:** $|\text{Studentized Artık}_i| > 3$ (veya daha katı eşik için > 4) ise gözlem **aykırı değer** sayılır.
- **Normallik kontrolü:** Artıkların (veya Studentized artıkların) **QQ-plot**'unu çiz. Noktalar düz bir doğruya yakınsa normallik varsayımı yaklaşık olarak sağlanıyor demektir. Artıklar hiçbir zaman tam Gaussian olmaz; sadece çok uzak olmamalarını kontrol ederiz.
- **Oto-korelasyon:** Zaman serisi verilerinde ardışık artıklar arasındaki korelasyonu kontrol etmek için **Durbin-Watson testi** kullanılır.

7 Etkili Gözlemler (Influential Cases)

7.1 Leverage (h_{ii})

- **Amaç:** Tüm regresyon analizini tek başına etkileyen gözlemleri tespit etmek.
- **Sezgi:** Bir scatter plot düşün — noktaların çoğu ortada kümelenmiş, bir tanesi çok sağda. O tek nokta tüm doğruyu kendine doğru çeker. Bu **leverage etkisidir**.
- Hat matrisinin köşegen elemanları **leverage** olarak adlandırılır:

$$h_{ii} = \text{diag}_i(\mathbb{Z}(\mathbb{Z}^T\mathbb{Z})^{-1}\mathbb{Z}^T), \quad 0 \leq h_{ii} \leq 1 \quad (19)$$

- $0 \leq h_{ii} \leq 1$ olduğu $H = H^T$ ve $H^2 = H$ özelliklerinden kanıtlanır.
- h_{ii} sadece **tasarım matrisine** ($\mathbb{Z}$) bağlıdır, $\underline{y}$ 'ye değil. Regresyonu yapmadan önce bile hesaplanabilir.
- h_{ii} büyükse $\Rightarrow$ gözlem i , X uzayında veri merkezinden çok uzakta demektir.
- **Tehlikeli sonuç:** $h_{ii} \approx 1$ ise:

$$\text{Var}(\hat{\varepsilon}_i) = \sigma^2(1 - h_{ii}) \approx 0 \implies \hat{\varepsilon}_i \approx 0 \quad (20)$$

Yüksek leverage'lı bir nokta artığı sıfıra yakın **görünmek zorunda kalır** — sanki modele mükemmel uyuyormuş gibi görünür, oysa gerçekten anormal bir gözlem olabilir. Bu **istatistikle yalan söylemenin** klasik yoludur.

- **Pratik kural:** $h_{ii} > \frac{2(r+1)}{n}$ olan gözlemleri işaretle.

7.2 Cook's Distance (D_i)

- **Fikir:** Gözlem i 'yi veri setinden çıkar ve modeli yeniden kur. $\hat{\underline{\beta}}$ ne kadar değişti?
 - Tüm veriyle: $\underline{y} = \mathbb{Z}\underline{\beta} + \underline{\varepsilon} \Rightarrow \hat{\underline{\beta}} \in \mathbb{R}^{r+1}$
 - Gözlem i çıkarılınca: $\underline{y}_{-i} = \mathbb{Z}_{-i}\underline{\beta} + \underline{\varepsilon}_{-i} \Rightarrow \hat{\underline{\beta}}^{(i)} \in \mathbb{R}^{r+1}$
- Eğer $\hat{\underline{\beta}}^{(i)}$ ile $\hat{\underline{\beta}}$ çok farklıysa, gözlem i **etkilidir**.
- **Cook's Distance** bu farkı Mahalanobis tipi bir uzaklıkla ölçer:

$$D_i = \frac{(\hat{\underline{\beta}}^{(i)} - \hat{\underline{\beta}})^T (\mathbb{Z}^T\mathbb{Z}) (\hat{\underline{\beta}}^{(i)} - \hat{\underline{\beta}})}{S^2(r+1)} \quad (21)$$

- **Eşdeğer formül** — Cook's Distance'ı Studentized artıklar ve leverage ile ilişkilendirir:

$$D_i = \left(\frac{\hat{\varepsilon}_i}{S\sqrt{1-h_{ii}}} \right)^2 \cdot \frac{h_{ii}}{1-h_{ii}} \cdot \frac{1}{r+1} \quad (22)$$

- Birinci faktör: Studentized artığın karesi — modele uyum ne kadar kötü.
- İkinci faktör: Leverage fonksiyonu — X uzayında ne kadar uçta.

- Bir nokta hem büyük artığa hem yüksek leverage’a sahipse gerçekten **tehlikelidir**.
- Not: Yüksek leverage’lı bir nokta artığı sıfıra zorladığı için “küçük artık, büyük Cook’s Distance” durumu da mümkündür.
- **Karar kuralları:**
 - D_i ’yi $F(r+1, n-(r+1))$ dağılımının kantilleriyle karşılaştır. $\hat{\beta}^{(i)}$, $\hat{\beta}$ merkezli güven bölgesinin dışına çıkıyorsa ikisi gerçekten çok farklıdır.
 - **Pratik kural:** $D_i > 1 \Rightarrow$ gözlem **etkili** sayılır ($F(r+1, n-(r+1))$ ’in medyanı makul r, n değerleri için her zaman 1’e yakındır).

8 Çoklu Doğrusallık ve VIF

8.1 Çoklu Doğrusallık Nedir?

- **Tanım:** Bir regressör z_j diğer regressörlerin neredeyse doğrusal bir kombinasyonuysa **collinearity** (çoklu doğrusallık) vardır.
- **Örnek:** Modele hem “boy (cm)” hem “boy (inch)” koyarsan, bu iki değişken birbirinin tam kopyası — $\mathbb{Z}^T \mathbb{Z}$ tekil olur, $\hat{\beta}$ ’yı hesaplayamazsın bile. Gerçekte tam kopya olmasa da *neredeyse* doğrusal bağımlılık ciddi sorun yaratır.
- $\mathbb{Z}^T \mathbb{Z}$ neredeyse tekil olduğunda:
 - $\hat{\beta}$ hesaplanamaz hale gelir.
 - $\text{Cov}(\hat{\beta}) = \sigma^2 (\mathbb{Z}^T \mathbb{Z})^{-1} \rightarrow \infty$.
- **Neden tehlikeli:** $\hat{\beta}_j$ ’nin varyansı o kadar büyür ki **işareti bile yanlış** çıkabilir.
- **Gerçek dünya örneği:** Enflasyon ile işsizliğin aynı modelde bulunduğunu varsay. Collinearity yüzünden $\hat{\beta}_j > 0$ çıkabilir (işsizlik enflasyonu artırıyor der). Buna göre yapılan politika enflasyonu düşürür ama işsizliği artırır — tam ters etki!

8.2 $\hat{\beta}_j$ için Varyans Formülü

- $\mathbb{Z} = [\underline{1} \ \underline{z}_1 \ \cdots \ \underline{z}_r]$ sütunlarına Gram-Schmidt uygulanarak türetilir:

$$\text{Var}(\hat{\beta}_j) = \frac{\sigma^2}{\sum_{i=1}^n (z_{ij} - \bar{z}_j)^2 (1 - R_j^2)} = \frac{\sigma^2}{(n-1)S_j^2} \cdot \frac{1}{1 - R_j^2} \quad (23)$$

burada:

- $S_j^2 = \frac{1}{n-1} \sum_{i=1}^n (z_{ij} - \bar{z}_j)^2$: j ’inci regressörün örneklem varyansı.
- R_j^2 : z_j ’yi **diğer tüm regressörlere regresyon yapınca** elde edilen R^2 (yani z_j yanıt değişkeni, diğerleri açıklayıcı değişken olarak alınır).
- **Yorumlar:**
 - $\sum (z_{ij} - \bar{z}_j)^2$ büyüdükçe $\text{Var}(\hat{\beta}_j)$ **azalır** — regressörün değerleri ne kadar yayılmışsa o kadar bilgi taşır.

- $R_j^2 \rightarrow 1$ oldukça $\text{Var}(\hat{\beta}_j) \rightarrow \infty$ — z_j diğerlerinden neredeyse tamamen tahmin edilebilir demektir: collinearity!

8.3 Variance Inflation Factor (VIF)

- **Tanım:**

$$\text{VIF}(\hat{\beta}_j) = \frac{1}{1 - R_j^2} \quad (24)$$

- VIF, $\hat{\beta}_j$ 'nin varyansının ideal duruma (tüm regressörler ortogonal, $R_j^2 = 0 \Rightarrow \text{VIF} = 1$) kıyasla kaç katına *şıştiğini* gösterir.
- Bu formül herhangi bir $j = 1, \dots, r$ için geçerlidir; çünkü Gram-Schmidt sürecinde regressörlerin sırası değiştirilebilir.
- **Karar kuralları:**
 - VIF = 1: sorun yok — ideal durum, regressörler birbirine dik.
 - VIF > 5: uyarı — varyans 5 kat şışmış, incelenmeli.
 - VIF > 10: ciddi sorun — varyans 10 kat şışmış, o değişkeni modelden çıkarmayı düşün.