

25 - Ensemble Methods: Bootstrap and Bagging, Random Forests, Variable Importance Plot, Shapley Value

Applied Statistics

Unat Teksen

May 8, 2026

1 The Big Picture

- A single decision tree (CART) tends to **overfit** the training data: it memorises rather than generalises.
- Consequence: **low bias, high variance** — change the training set slightly and you get a completely different tree.
- **Goal of ensemble methods:** keep bias low while *reducing* variance, by combining many models.
- Core intuition: one person's opinion is noisy; the average of many independent opinions is stable.

2 The Problem — Bias–Variance Tradeoff

2.1 Model Setup

- Supervised learning model:

$$y = f(\underline{x}) + \epsilon, \quad E[\epsilon] = 0, \quad \epsilon \perp \underline{x}$$

- y : observed response, $f(\underline{x})$: true unknown function, ϵ : irreducible noise.
- We fit a model $\hat{f}_{\mathbb{X}}$ from training data $\mathbb{X}$.
- At a new test point $\underline{x}_0 \notin \mathbb{X}$, the true value is $y_0 = f(\underline{x}_0) + \epsilon_0$.

2.2 Bias–Variance Decomposition

- The expected prediction error decomposes as:

$$E\left[(y_0 - \hat{f}_{\mathbb{X}}(\underline{x}_0))^2\right] = \underbrace{\left[f(\underline{x}_0) - E[\hat{f}_{\mathbb{X}}(\underline{x}_0)]\right]^2}_{\text{bias}^2} + \underbrace{\text{Var}\left(\hat{f}_{\mathbb{X}}(\underline{x}_0)\right)}_{\text{variance}} + \underbrace{\text{Var}(\epsilon_0)}_{\text{irreducible}}$$

- **Bias²**: systematic error — how far is the average prediction from the truth?
- **Variance**: sensitivity error — how much does the model change with different training data?
- **Irreducible noise**: cannot be eliminated regardless of the model.
- **CART problem**: low bias but high variance $\Rightarrow$ ensemble methods target variance reduction.

3 The Ensemble Technique

3.1 Why Averaging Works

- Simple example: $y_1, \dots, y_n \stackrel{\text{iid}}{\sim} (\mu, \sigma^2)$, model is $y = \mu + \epsilon$.
- **Predictor 1 — single observation**: $\hat{f} = y_1$

$$\text{Total error} = 0 + \sigma^2 + \sigma^2 = 2\sigma^2$$

- **Predictor 2 — sample mean**: $\hat{f} = \bar{y}_n = \frac{1}{n} \sum_{i=1}^n y_i$

$$E[(y_0 - \hat{f})^2] = \frac{1}{n}\sigma^2 + \sigma^2 \leq 2\sigma^2$$

- As $n \rightarrow \infty$, the variance term $\frac{\sigma^2}{n} \rightarrow 0$. **Averaging kills variance.**

3.2 General Ensemble Principle

- Suppose we have B independent copies of the fitted model:

$$\hat{f}_{\mathbb{X}_1}, \hat{f}_{\mathbb{X}_2}, \dots, \hat{f}_{\mathbb{X}_B} \stackrel{\text{iid}}{\sim} \hat{f}_{\mathbb{X}}$$

- Define the ensemble predictor:

$$\hat{f}_B = \frac{1}{B} \sum_{b=1}^B \hat{f}_{\mathbb{X}_b}$$

- Key properties:

$$E[\hat{f}_B] = E[\hat{f}_{\mathbb{X}}], \quad \text{Var}(\hat{f}_B) = \frac{1}{B} \text{Var}(\hat{f}_{\mathbb{X}})$$

- Expected prediction error improves:

$$E[(y_0 - \hat{f}_B(\underline{x}_0))^2] = \left[f(\underline{x}_0) - E[\hat{f}_{\mathbb{X}}(\underline{x}_0)] \right]^2 + \frac{1}{B} \text{Var}(\hat{f}_{\mathbb{X}}(\underline{x}_0)) + \text{Var}(\epsilon_0) \leq E[(y_0 - \hat{f}_{\mathbb{X}}(\underline{x}_0))^2]$$

- **Problem in practice**: obtaining B truly independent training sets $\mathbb{X}_1, \dots, \mathbb{X}_B \in \mathbb{R}^{n \times (p+1)}$ is extremely expensive. Solution: **Bootstrap**.

4 Bagging — Bootstrap and Aggregating

4.1 Bootstrap

- Introduced by Efron (1979).
- Given dataset $\mathbb{X}$ of n observations, draw n units **with replacement**:

$$\mathbb{X}^* = \begin{bmatrix} \underline{x}_1^* \\ \vdots \\ \underline{x}_n^* \end{bmatrix}$$

- Same observation can appear multiple times; some may not appear at all.
- **Example:** Original data = $\{A, B, C, D, E\}$. One bootstrap sample: $\{A, A, C, E, C\}$.
- Probability that a fixed unit $(\underline{x}_i, y_i)$ appears in $\mathbb{X}^*$:

$$P[(\underline{x}_i, y_i) \in \mathbb{X}^*] = 1 - \left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} 1 - e^{-1} \approx 0.632$$

- Any two bootstrap samples share approximately **63.2%** of their data.

4.2 Bagging Algorithm

- Introduced by Breiman (1994). Solves the problem of having only one training set $\mathbb{X}$.
- **Algorithm:**
 1. Generate B bootstrap samples: $\mathbb{X}_1^*, \dots, \mathbb{X}_B^*$
 2. Train a separate model on each: $\hat{f}_{\mathbb{X}_1^*}, \dots, \hat{f}_{\mathbb{X}_B^*}$
 3. Aggregate:

$$\hat{f}_B = \frac{1}{B} \sum_{b=1}^B \hat{f}_{\mathbb{X}_b^*}$$

- **Result:** Variance is reduced; bias stays the same.
- **Limitation:** Bootstrap samples are correlated (share $\sim 63\%$ data) $\Rightarrow$ trees are correlated $\Rightarrow$ variance reduction is limited. Random Forest fixes this.

5 Random Forest (RF)

5.1 Motivation and Algorithm

- Introduced by Breiman (2001).
- **Key idea:** At each split of each tree, instead of searching all p features, randomly select only $m < p$ features and find the best split among those m only.
- This random selection is *refreshed at every split*, making trees more different from each other.
- Reduces correlation between trees $\Rightarrow$ averaging is more effective.

5.2 Choosing m

- $m = p$: reduces to Bagging (no feature randomisation).

- **Regression:**

$$m = \frac{1}{3}p$$

- **Classification:**

$$m = \sqrt{p}$$

- These are empirical rules of thumb, not derived theoretically.

5.3 RF Predictor

- **Regression** — average over all trees:

$$\hat{f}_B(\underline{x}_0) = \frac{1}{B} \sum_{b=1}^B \hat{f}_{\mathbb{X}_b^*}(\underline{x}_0)$$

- **Classification** — majority vote:

$$\hat{f}_B(\underline{x}_0) = \text{mode} \left\{ \hat{f}_{\mathbb{X}_1^*}(\underline{x}_0), \dots, \hat{f}_{\mathbb{X}_B^*}(\underline{x}_0) \right\}$$

- **Analogy:** 500 doctors, each saw slightly different patients and checked different symptoms at each step. You go with the majority diagnosis. In Bagging, all 500 doctors are nearly identical — they read the same textbook.

6 Random Forest Explainability

6.1 The Problem

- A single decision tree is interpretable: you follow the branches.
- A forest of 500 trees is a black box: you cannot directly explain why a specific prediction was made.
- Two main approaches to recover interpretability:

6.2 Variable Importance

- Every time feature X_i is used for a split, record the **reduction in RSS / Gini impurity** caused by that split.
- Sum these reductions across all splits and all trees $\Rightarrow$ **Variable Importance score** for X_i .
- Features with the largest scores are the most influential globally.
- Visualised as a ranked bar chart: the **Variable Importance Plot**.
- **Limitation:** tells you which features matter globally, not why a specific prediction was made.

6.3 Shapley Value

6.3.1 Game Theory Origin

- Introduced by Shapley (1951) in game theory; later adapted for ML explainability.
- Setup:** p players $\{1, \dots, p\}$, set of all coalitions:

$$\mathcal{P} = \{S \mid S \subseteq \{1, \dots, p\}\}$$

- Worth function $V : \mathcal{P} \rightarrow \mathbb{R}$: $V(S)$ is the reward earned by coalition S .
- Marginal contribution of player $i \notin S$ joining coalition S :

$$V(S \cup \{i\}) - V(S)$$

- Number of coalitions of size $|S|$ not containing i :

$$p \binom{p-1}{|S|} = \frac{p!}{|S|! (p - |S| - 1)!}$$

- Shapley value** of player i — weighted average marginal contribution over all coalitions:

$$\phi_i = \sum_{S \subseteq \{1, \dots, p\} \setminus \{i\}} \frac{p!}{|S|! (p - |S| - 1)!} (V(S \cup \{i\}) - V(S))$$

6.3.2 Properties of Shapley Values

- Efficiency:** $\sum_{i=1}^p \phi_i = V(\{1, \dots, p\})$ — total reward is fully distributed.
- Null Player:** If $V(S \cup \{i\}) = V(S) \forall S \in \mathcal{P}$, then $\phi_i = 0$.
- Symmetry:** If $V(S \cup \{i\}) = V(S \cup \{j\}) \forall S \in \mathcal{P}$, then $\phi_i = \phi_j$.
- Linearity:** For two games v, w and $a, b \in \mathbb{R}$:

$$\phi_i^{av+bw} = a \phi_i^v + b \phi_i^w \quad \forall i = 1, \dots, p$$

6.3.3 Shapley Values in Statistics / ML

- Players $\leftrightarrow$ features $X_1, \dots, X_p$.
- Prediction using only features in S is $\hat{f}_{\mathbb{X}|S}(\underline{x}_0 \mid S)$.
- Worth function for a specific test point $\underline{x}_0$:

$$V(S) = \hat{f}_{\mathbb{X}|S}(\underline{x}_0 \mid S) - \bar{y}$$

where $\bar{y}$ is the baseline prediction (average response, no features used).

- Note: $\bar{y}$ is the part of the prediction that can be done *without* any features.
- Shapley value of feature X_i** for prediction at $\underline{x}_0$:

$$\phi_i = \sum_{S \subseteq \{1, \dots, p\} \setminus \{i\}} \frac{p!}{|S|! (p - |S| - 1)!} \left(\hat{f}_{\mathbb{X}|S \cup \{i\}}(\underline{x}_0) - \hat{f}_{\mathbb{X}|S}(\underline{x}_0) \right)$$

- Interpretation: on average over all possible subsets of other features, how much does adding X_i change the prediction?

6.3.4 Per-Unit Analysis

- For a fixed feature i , compute $\phi_i(\underline{x}_k)$ for every $k = 1, \dots, n$ in the dataset.
- Large variation in $\phi_i(\underline{x}_k)$ across units $\Rightarrow X_i$ is very important but acts differently on different observations.
- Normalise to compare features:

$$\sum_{k=1}^n |\phi_i(\underline{x}_k)|$$

6.3.5 Computational Cost and Algorithms

- Exact computation requires summing over all 2^p subsets $\Rightarrow$ exponential cost, infeasible for large p .
- Approximation algorithms:
 - **SHAP** (Lundberg & Lee, 2017) — general-purpose fast approximation.
 - **TreeSHAP** (Lundberg, Erion & Lee, 2019) — specific to tree-based models (RF, GBM); much faster.
- Further reading: *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable*, C. Molnar (2025), available free on GitHub.

Türkçe Özet — Sıfırdan Anlatım

Büyük Resim: Ne Yapmaya Çalışıyoruz?

- Elimizde bir veri seti var ve bir model kurmak istiyoruz.
- **Tek bir karar ağacı (CART)** genellikle eğitim verisini **ezberler** $\Rightarrow$ yüksek varyans.
- **Çözüm:** Tek model yerine **birçok model kur, sonuçlarını birleştir.**
- Temel sezgi: Bir kişinin tahmini gürültülüdür; çok sayıda bağımsız tahminin ortalaması karardır.

Bölüm 2 — Sorun: Bias ve Variance

- Gerçek dünya modeli:

$$y = f(\underline{x}) + \epsilon, \quad E[\epsilon] = 0, \quad \epsilon \perp \underline{x}$$

- y : gerçek değer, $f(\underline{x})$: bilinmeyen gerçek fonksiyon, ϵ : gürültü (şans faktörü).
- Toplam tahmin hatası üç parçaya ayrılır:

$$\text{Toplam Hata} = \underbrace{\text{Bias}^2}_{\text{sistemik yanlışlık}} + \underbrace{\text{Variance}}_{\text{tutarsızlık}} + \underbrace{\text{Gürültü}}_{\text{elimizde değil}}$$

- **Bias:** Model sürekli aynı yönde yanlış yapıyorsa — örneğin her tahminin gerçekten 10 puan düşük çıkıyor.
- **Variance:** Farklı veri setleriyle model kurduğumuzda tahminler çok değişiyorsa — bir seferinde 60, öbüründe 90 tahmin ediyor.
- **CART sorunu:** Düşük bias ama çok yüksek variance. Hedefimiz: bias'ı koruyarak variance'ı azaltmak.

Bölüm 3 — Fikir: Ortalama Almak Variance'ı Öldürür

- Basit örnek: $y_1, \dots, y_n \stackrel{\text{iid}}{\sim} (\mu, \sigma^2)$
- **Seçenek 1 — tek gözlem:** $\hat{f} = y_1 \Rightarrow \text{hata} = 2\sigma^2$
- **Seçenek 2 — örneklem ortalaması:** $\hat{f} = \bar{y}_n$

$$E[(y_0 - \hat{f})^2] = \frac{1}{n}\sigma^2 + \sigma^2 \leq 2\sigma^2$$

- $n \rightarrow \infty$ iken $\frac{\sigma^2}{n} \rightarrow 0$. **Ortalama almak variance'ı yok eder.**
- B bağımsız modelin ortalaması:

$$\hat{f}_B = \frac{1}{B} \sum_{b=1}^B \hat{f}_{\mathbb{X}_b} \quad \Rightarrow \quad \text{Var}(\hat{f}_B) = \frac{1}{B} \text{Var}(\hat{f}_{\mathbb{X}})$$

- **Sorun:** B tane bağımsız veri seti bulmak çok pahalı $\Rightarrow$ Çözüm: Bootstrap.

Bölüm 4 — Bagging: Bootstrap ile Yapay Veri Setleri

- **Bootstrap (Efron, 1979):** Mevcut n satırlık veri setinden, **yerine koyarak** n satır çek.
- Örnek: Veri = $\{A, B, C, D, E\} \Rightarrow$ Bootstrap örneği: $\{A, A, C, E, C\}$
- Herhangi bir gözlemin bootstrap örneğine girme olasılığı:

$$P[(\underline{x}_i, y_i) \in \mathbb{X}^*] \approx 1 - e^{-1} \approx 0.632$$

- İki farklı bootstrap örneği **%63 oranında aynı veriyi paylaşıyor.**
- **Bagging (Breiman, 1994):** B bootstrap örneği üret, her birine model kur, ortalama:

$$\hat{f}_B = \frac{1}{B} \sum_{b=1}^B \hat{f}_{\mathbb{X}_b^*}$$

- **Sonuç:** Variance azalır, bias aynı kalır.
- **Sınırlılık:** Örnekler %63 örtüşüyor $\Rightarrow$ ağaçlar birbirine benziyor $\Rightarrow$ variance azalması sınırlı. Bunu Random Forest çözüyor.

Bölüm 5 — Random Forest

- **Fikir:** Ağaçlar birbirine benziyorsa ortalama almak o kadar işe yaramaz. Ağaçları birbirinden farklılaştır.
- Her ağacın her düğümünde: tüm p değişken yerine, **rastgele $m < p$ değişken seç**, sadece bunlar arasından en iyi bölünmeyi bul.
- Bu seçim her düğümde yeniden yapılır $\Rightarrow$ ağaçlar daha farklı $\Rightarrow$ korelasyon azalır $\Rightarrow$ ortalama daha etkili.
- **m seçimi:** Regresyon: $m = \frac{1}{3}p$ Sınıflandırma: $m = \sqrt{p}$
- **Tahmin — Regresyon:**

$$\hat{f}_B(\underline{x}_0) = \frac{1}{B} \sum_{b=1}^B \hat{f}_{\mathbb{X}_b^*}(\underline{x}_0)$$

- **Tahmin — Sınıflandırma (çoğunluk oylaması):**

$$\hat{f}_B(\underline{x}_0) = \text{mode}\left\{\hat{f}_{\mathbb{X}_1^*}(\underline{x}_0), \dots, \hat{f}_{\mathbb{X}_B^*}(\underline{x}_0)\right\}$$

- **Analoji:** 500 doktor var. Her biri biraz farklı bir hasta grubuna baktı ve her birinin muayenede dikkat ettiği semptomlar farklı. Çoğunun söylediği tanıyı al. Bagging'de ise 500 doktor neredeyse aynı — hepsi aynı kitabı okumuş.

Bölüm 6 — Modeli Açıklamak

Variable Importance (Değişken Önemi)

- Her değişken her kullanıldığında hatayı ne kadar azalttığını kaydet.
- Tüm ağaçlarda bu değerleri topla $\Rightarrow$ o değişkenin önem skoru.
- En çok azaltana en yüksek skor $\Rightarrow$ **Variable Importance Plot** (sıralı çubuk grafik).
- **Sınırlılık:** Hangi değişkenin genel olarak önemli olduğunu söyler; ama belirli bir tahmini neden yaptığını açıklamaz.

Shapley Değeri

- **Sezgi:** Ali, Bora ve Can birlikte iş kuruyor, toplam kâr 900. Kimin katkısı ne kadar? Her olası katılım sırasını düşün, her sırada katkıyı hesapla, ortalama $\Rightarrow$ bu Shapley değeri.
- ML’de oyuncular = değişkenler. Ödül = tahmin değeri. Shapley değeri şunu sorar: “ X_i bu tahmini ne kadar değiştirdi, diğer değişkenlerin her kombinasyonunu düşününce?”

- **Worth fonksiyonu:**

$$V(S) = \hat{f}_{\mathbb{X}|S}(\underline{x}_0 | S) - \bar{y}$$

- **Shapley değeri formülü:**

$$\phi_i = \sum_{S \subseteq \{1, \dots, p\} \setminus \{i\}} \frac{p!}{|S|!(p - |S| - 1)!} \left(\hat{f}_{\mathbb{X}|S \cup \{i\}}(\underline{x}_0) - \hat{f}_{\mathbb{X}|S}(\underline{x}_0) \right)$$

- **4 temel özellik:**

1. **Efficiency:** $\sum_{i=1}^p \phi_i = V(\{1, \dots, p\})$ — toplam katkı tamamen dağıtılır.
2. **Null Player:** Hiç katkısı yoksa $\phi_i = 0$.
3. **Symmetry:** Aynı katkıyı yapanlar aynı değeri alır: $\phi_i = \phi_j$.
4. **Linearity:** $\phi_i^{av+bw} = a\phi_i^v + b\phi_i^w$

- **Birim bazlı analiz:** $\phi_i(\underline{x}_k)$ ’yi her $k = 1, \dots, n$ için hesapla. Büyük değişim $\Rightarrow X_i$ önemli ama gözlemlere göre farklı davranıyor. Karşılaştırma için normalize et: $\sum_{k=1}^n |\phi_i(\underline{x}_k)|$
- **Pratik sorun:** Kesin hesaplama 2^p alt küme gerektirir — büyük p için imkânsız.
- **Yaklaşım algoritmaları:**
 - **SHAP** (Lundberg & Lee, 2017) — genel amaçlı hızlı yaklaşım.
 - **TreeSHAP** (Lundberg, Erion & Lee, 2019) — RF gibi ağaç tabanlı modellere özel, çok daha hızlı.