

26 - Linear Models with Heteroscedastic and Correlated Errors. Random Effects.

Applied Statistics

Unat Teksen

May 11, 2026

1 Big Picture — Why Do We Need This?

- **Core problem:** Standard linear regression assumes errors are *independent* and *homoscedastic* (equal variance). In real-world data, both assumptions regularly fail.
- **Motivating example:** Measuring exam scores across 20 schools.
 - Students in the same school are *not independent* — they share a teacher, culture, building.
 - Some schools are more variable than others — variances differ.
 - Some schools are systematically higher/lower — group effect exists.
- **The journey of this chapter:**
 - Start from the Classical Linear Model (LM).
 - Relax homoscedasticity → Heteroscedastic LM (§15.3–15.5).
 - Relax independence → Correlated LM (§15.6–15.7).
 - Add group-level random effects → Linear Mixed Model / LMM (§15.8).
- **What LMM gives us:** Correct inference even when data has group structure, unequal variances, and within-group correlations.

2 Classical Linear Model — The Benchmark (§15.2)

- **Model:**

$$\underline{y} = \mathbb{X}\underline{\beta} + \underline{\varepsilon}, \quad \underline{\varepsilon} \sim N(0, R), \quad R = \sigma^2 I_n \in \mathbb{R}^{n \times n}$$

- $R = \sigma^2 I_n$ encodes two things simultaneously:
 - All errors have the *same variance* σ^2 (homoscedasticity).
 - No two errors are correlated (independence) — off-diagonal entries are zero.
- **Key properties:**

$$E[y_j] = \mu_j = \underline{x}_j^T \underline{\beta}, \quad \text{Var}[y_j] = \sigma^2$$

- **Three estimation methods — why the difference matters:**

- **OLS** (Ordinary Least Squares):

$$\hat{\underline{\beta}}_{OLS} = (\mathbb{X}^T \mathbb{X})^{-1} \mathbb{X}^T \underline{y}$$

$$\hat{\sigma}_{OLS}^2 = \frac{1}{n - (p + 1)} (\underline{y} - \mathbb{X} \hat{\underline{\beta}}_{OLS})^T (\underline{y} - \mathbb{X} \hat{\underline{\beta}}_{OLS})$$

Denominator $n - (p + 1)$ corrects for degrees of freedom used by $\beta \Rightarrow$ *unbiased*.

- **ML** (Maximum Likelihood): Same $\hat{\beta}$ as OLS, but biased σ^2 :

$$\hat{\sigma}_{ML}^2 = \frac{1}{n} \sum_{j=1}^n (y_j - x_j^T \hat{\underline{\beta}}_{ML})^2$$

Divides by n instead of $n - (p + 1) \Rightarrow$ systematically *underestimates* σ^2 .

- **REML** (Restricted Maximum Likelihood): Profiles out β first, then estimates σ^2 :

$$\hat{\sigma}_{REML}^2 = \frac{1}{n - (p + 1)} \sum_{j=1}^n r_j^2$$

Unbiased. **Always preferred** in mixed models for variance component estimation.

3 Relaxing Homoscedasticity (§15.3)

- **New assumption:** Each observation can have its own variance.

$$\varepsilon_j \sim N(0, \sigma_j^2), \quad \Rightarrow \quad V[y_j] = \sigma_j^2$$

- **Example:** Factory measurements — morning shift is consistent (small σ^2), night shift is erratic (large σ^2). One common σ^2 misrepresents both.
- **The problem this creates:** We now have $n + p + 1$ parameters but only n observations. The model is *not identifiable* — too many unknowns.
- **Solution:** Use a **Variance Function** (§15.4) to parameterise all variances with a small set of parameters.

4 Variance Function (§15.4)

- **Goal:** Instead of estimating n free variances, express all of them as a function of a *small* parameter set.
- **Variance function:**

$$\lambda^2(\underline{\delta}, \mu_j; \underline{v}_j)$$

- $\underline{v}_j$: vector of *known* covariates for observation j .
- $\underline{\delta}$: small set of *unknown* variance parameters, shared across all observations.
- μ_j : expected value (mean) of observation j .

		Depends on δ ?	
		No	Yes
Depends on μ ?	No	Known weights $\lambda(\cdot) = \lambda(v)$ Algorithm: WLS Weights are given, not estimated	$\langle \delta \rangle$-group $\lambda(\cdot) = \lambda(\delta; v)$ Algorithm: ML or REML δ estimated, μ not involved
	Yes	$\langle \mu \rangle$-group $\lambda(\cdot) = \lambda(\mu; v)$ Algorithm: IRLS Variance depends on mean	$\langle \delta, \mu \rangle$-group $\lambda(\cdot) = \lambda(\delta, \mu; v)$ Algorithm: ML/REML-based GLS Most general form

Figure 1: 4 Types of Var Func

– Function is continuous and differentiable w.r.t. $\underline{\delta}$.

• **Variance of each error:**

$$V[\varepsilon_j] = \sigma^2 \lambda^2(\delta, \mu_j; v_j)$$

• **Full error distribution:**

$$\varepsilon \sim N(0, R), \quad R = \sigma^2 \Lambda, \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_n) \in \mathbb{R}^{n \times n}$$

$$\lambda_j^2 = \lambda^2(\underline{\delta}, \mu_j; \underline{v}_j)$$

• **Analogy:** Instead of measuring every house's variance separately, say “variance is proportional to house price squared.” One parameter controls all variances.

• **Four types of variance functions:**

- **Known weights** $\lambda(\cdot) = \lambda(v)$: Weights fully pre-specified. Algorithm: **WLS**.
- **$\langle \delta \rangle$ -group** $\lambda(\cdot) = \lambda(\delta; v)$: Depends on δ but not μ . Algorithm: **ML or REML**.
- **$\langle \delta, \mu \rangle$ -group** $\lambda(\cdot) = \lambda(\delta, \mu; v)$: Most general. Algorithm: **REML-based GLS**.
- **$\langle \mu \rangle$ -group** $\lambda(\cdot) = \lambda(\mu; v)$: Depends on μ only. Algorithm: **IRLS**.

5 Profiled Likelihood (§15.5)

• **Goal:** Estimate β , σ^2 , and δ simultaneously — but doing this jointly is hard. Profiling solves it step by step.

• **Full log-likelihood:**

$$\ell(\underline{\beta}, \sigma^2, \underline{\delta}) = -\frac{n}{2} \log(\sigma^2) - \frac{1}{2} \sum_{j=1}^n \log(\lambda_j^2) - \frac{1}{2\sigma^2} \sum_{j=1}^n \lambda_j^{-2} (y_j - \underline{x}_j^T \underline{\beta})^2$$

• **Three-step profiling strategy:**

- **Step 1:** Fix $\delta \rightarrow$ maximise over $\beta \rightarrow$ get $\hat{\beta}(\delta)$.
- **Step 2:** Plug $\hat{\beta}(\delta)$ in $\rightarrow$ maximise over $\sigma^2 \rightarrow$ get $\hat{\sigma}_{ML}^2(\delta)$.
- **Step 3:** Only δ remains $\rightarrow$ maximise $l_{ML}^*(\delta)$ (the profiled likelihood).
- **Intuition:** Like finding the highest point on a 3D landscape. For every value of δ , automatically find the best β and σ^2 — reduces the search to one dimension.
- When $\lambda = \lambda(\delta)$ (no μ dependence), profiling reduces back to the standard ML/REML case.

6 Relaxing Independence — Correlated Errors (§15.6)

- **New assumption:** Observations within the same group can be correlated.
- **Setup:** N groups, group i has n_i observations.

$$y_i = \mathbb{X}_i \underline{\beta} + \varepsilon_i, \quad \varepsilon_i \sim N_{n_i}(0, \mathcal{R}_i), \quad \mathcal{R}_i = \sigma^2 R_i$$

- R_i is now a full $n_i \times n_i$ matrix — off-diagonal entries allowed (within-group correlation).
- **Properties:**

$$E[y_{ij}] = \mu_{ij} = z_{ij}^T \underline{\beta} \quad \wedge \quad V[y_i] = V[\varepsilon_i] = \sigma^2 R_i$$

- **MRI Example:** n individuals, 8 different scanners, randomly assigned. Measurements from the same scanner share systematic biases $\Rightarrow$ correlated. Modelled through R_i .

7 Correlation Function (§15.7)

- **Goal:** Just as the Variance Function parametrises variances compactly, the Correlation Function parametrises off-diagonal entries of R with a small parameter set.
- **Correlation function:**

$$\text{Corr}(\varepsilon_{ij}, \varepsilon_{ij}^T) = h[d(t_{ij}, t_{ij}, \mathcal{Q})]$$

- $\mathcal{Q}$: vector of unknown correlation parameters (estimated from data).
- d : distance function — how far apart are two observations?
- h : continuous, ranges in $[-1, 1]$, with $h(0, \mathcal{Q}) = 1$ (self-correlation = 1).
- **Intuition:** Two houses next door are very similar in price. Two houses 10 km apart are less similar. The correlation function formalises this “distance $\uparrow \Rightarrow$ correlation $\downarrow$ ” idea.
- **Two main structure types:**
 - **Serial structures:** Time-series or longitudinal data. Example: autocorrelation. Blood pressure today vs. tomorrow: highly correlated.




Figure 2: LMM

- **Spatial structures:** Data spread in physical space. Example: semivariogram. Two wheat plants 1 m apart are more similar than those 100 m apart.
- Estimation carried out by WLS or likelihood-based methods.
- **Why this helps:** Without it, R_i has up to $n_i(n_i - 1)/2$ free parameters. The correlation function replaces all of them with just $\mathcal{Q}$.

8 Random Effects and the Full LMM (§15.8)

- **Goal:** Model group-level differences as *random draws* rather than fixed parameters.
- **Why not add a dummy variable for each group?**
 - With 500 schools $\Rightarrow$ 500 extra coefficients $\Rightarrow$ model bloats.
 - Cannot generalise to a new school not seen in training data.
 - Small groups (e.g. 2 students) give unreliable estimates.

- **LMM at group level i :**

$$y_i = \underline{X}_i \underline{\beta} + Z_i \underline{b}_i + \varepsilon_i, \quad \underline{b}_i \sim N_q(\underline{0}, D), \quad \varepsilon_i \sim N_{n_i}(\underline{0}, R_i)$$

with the critical condition: $\underline{b}_i \perp \varepsilon_i$.

- **Full model (all data stacked):**

$$y = \mathbb{X} \underline{\beta} + \mathbb{Z} \underline{b} + \underline{\varepsilon}, \quad \underline{b} \sim N(0, \sigma_b^2 D), \quad \underline{\varepsilon} \sim N(\underline{0}, \sigma_\varepsilon^2 R)$$

- **What each term means:**

- $\mathbb{X} \underline{\beta}$: **Fixed effects** — population-level coefficients, same for every group, *estimated*.
- $Z_i \underline{b}_i$: **Random effects** — group-specific deviation, drawn from $N_q(0, D)$, *predicted* (not estimated).
- ε_i : Within-group residual error.

- D : Covariance matrix of random effects (how much groups vary from each other).
- **Diagram intuition:**
 - Fixed effects only: all groups forced onto one regression line.
 - With random effects: each group gets its own intercept shift (b_i), but all share the same slope β .
- **Shrinkage / partial pooling intuition:**
 - School A has only 2 students $\Rightarrow$ LMM does not trust those 2 data points fully. It pulls the school's estimate back toward the population mean. This is called **shrinkage**.
 - School B has 500 students $\Rightarrow$ LMM trusts the data; estimate stays close to the school's raw mean.
 - This is “partial pooling” — between no pooling (separate models) and complete pooling (one model ignoring groups).
- **BLUP — Best Linear Unbiased Predictor** (added note, not in original slides):

$$\hat{b}_i = DZ_i^T (\sigma^2 R_i + Z_i D Z_i^T)^{-1} (y_i - X_i \hat{\beta})$$

The predicted random effect is proportional to how much group i 's residuals deviate from what the fixed effects predict.

9 Summary — What Did We Do and What Did We Gain?

- Each section removed one restrictive assumption from the classical LM:

Section	Assumption removed	Tool	Result
§15.2	None (benchmark)	OLS / ML / REML	$\hat{\beta}, \hat{\sigma}^2$
§15.3	Equal variance	—	σ_j^2 per observation
§15.4	Equal variance (parametric)	Variance function λ^2	Compact variance model
§15.5	—	Profiled likelihood	Sequential estimation of β, σ^2
§15.6	Independence	R_i matrix	Within-group correlation
§15.7	Independence (parametric)	Correlation function h	Compact correlation model
§15.8	All of the above	LMM: $y = X\beta + Zb + \varepsilon$	Group effects as random draws

- **Final answer to “why LMM?”:** Real-world data is clustered, correlated, and heteroscedastic. LMM handles all of this under one roof, gives correct uncertainty estimates, and generalises to new groups never seen in training data — something plain regression can never do.

Türkçe Açıklamalar

Neden Bu Konuyu Öğreniyoruz? — Büyük Soru

- **Temel problem:** Basit regresyon, hataların *bağımsız* ve *eşit varyanslı* (homoscedastic) olduğunu varsayar. Gerçek dünyada her ikisi de çoğu zaman sağlanmaz.
- **Somut örnek:** 20 farklı okuldaki öğrencilerin sınav notları.
 - Aynı okuldaki öğrenciler birbirine benziyor $\Rightarrow$ bağımsız değiller.
 - Bazı okullar çok değişken, bazıları homojen $\Rightarrow$ varyanslar farklı.
 - Bazı okullar genel olarak daha yüksek not alıyor $\Rightarrow$ grup etkisi var.
- **Bu bölümün yol haritası:**
 - Klasik Doğrusal Model’den başla.
 - Eşit varyans varsayımını kaldır $\rightarrow$ Heterokedastik LM (§15.3–15.5).
 - Bağımsızlık varsayımını kaldır $\rightarrow$ Korelasyonlu LM (§15.6–15.7).
 - Grup düzeyinde rastgele etkiler ekle $\rightarrow$ Doğrusal Karma Model / LMM (§15.8).
- **LMM ne sağlar:** Grup yapısı, farklı varyanslar ve grup içi korelasyon olduğunda bile doğru istatistiksel çıkarım yapılabilir.

Klasik Doğrusal Model — Başlangıç Noktası (§15.2)

- **Model:**

$$\underline{y} = \mathbb{X}\underline{\beta} + \underline{\varepsilon}, \quad \underline{\varepsilon} \sim N(0, R), \quad R = \sigma^2 I_n$$
- $R = \sigma^2 I_n$ iki şeyi aynı anda söyler:
 - Tüm hataların varyansı aynı: σ^2 (homoskedastisite).
 - Hiçbir hata çifti korelasyonlu değil (bağımsızlık).
- **Üç tahmin yöntemi — fark neden önemli:**
 - **OLS:** $\hat{\sigma}_{OLS}^2$ paydada $n - (p + 1)$ kullanır $\Rightarrow$ sapmasız.
 - **ML:** $\hat{\sigma}_{ML}^2$ paydada n kullanır $\Rightarrow \sigma^2$ ’yi küçük tahmin eder (yanlı).
 - **REML:** β ’yi önce “profilleyip” dışarıya alır, sonra σ^2 ’yi tahmin eder $\Rightarrow$ sapmasız. Karma modellerde **her zaman tercih edilir**.

Heterokedastisite — Varyanslar Farklıysa (§15.3)

- **Yeni varsayım:** Her gözlemin kendi varyansı olabilir.

$$\varepsilon_j \sim N(0, \sigma_j^2) \quad \Rightarrow \quad V[y_j] = \sigma_j^2$$

- **Örnek:** Fabrikada sabah vardiyası tutarlı (küçük σ^2), gece vardiyası değişken (büyük σ^2). Tek bir σ^2 her ikisini de yanlış temsil eder.
- **Problem:** n gözlemden n ayrı σ_j^2 tahmin etmek imkânsız $\Rightarrow$ model tanımlanamaz.
- **Çözüm:** Varyans Fonksiyonu (§15.4).

Varyans Fonksiyonu — Varyansları Akıllıca Modellemek (§15.4)

- **Amaç:** n tane serbest varyans tahmin etmek yerine, hepsini küçük bir parametre setiyle ifade etmek.
- **Varyans fonksiyonu:** $\lambda^2(\underline{\delta}, \mu_j; \underline{v}_j)$
 - $\underline{v}_j$: gözlem j için bilinen kovaryatlar (zaten ölçülmüş).
 - $\underline{\delta}$: küçük bilinmeyen parametre seti (tüm gözlemler için ortak, tahmin edilecek).
 - μ_j : gözlem j 'nin beklenen değeri.

- **Hata varyansı:**

$$V[\varepsilon_j] = \sigma^2 \lambda^2(\delta, \mu_j; v_j)$$

- **Hata dağılımı:**

$$\varepsilon \sim N(0, R), \quad R = \sigma^2 \Lambda, \quad \Lambda = \text{diag}(\lambda_1, \dots, \lambda_n)$$

- **Analoji:** Ev fiyatlarındaki varyansı her ev için ayrı ayrı ölçmek yerine “varyans, fiyatın karesiyle orantılı” demek gibi. Tek parametre tüm varyansları kontrol eder.
- **Dört tip varyans fonksiyonu:**
 - **Bilinen ağırlıklar** $\lambda(\cdot) = \lambda(v)$: Ağırlıklar önceden belli. Yöntem: **WLS**.
 - **$\langle \delta \rangle$ -grubu** $\lambda(\cdot) = \lambda(\delta; v)$: Sadece δ 'ya bağlı. Yöntem: **ML veya REML**.
 - **$\langle \delta, \mu \rangle$ -grubu** $\lambda(\cdot) = \lambda(\delta, \mu; v)$: En genel durum. Yöntem: **REML tabanlı GLS**.
 - **$\langle \mu \rangle$ -grubu** $\lambda(\cdot) = \lambda(\mu; v)$: Sadece μ 'ya bağlı. Yöntem: **IRLS**.

Profillenmiş Olabilirlik — Parametreleri Nasıl Tahmin Ederiz? (§15.5)

- **Amaç:** β , σ^2 , δ 'yı aynı anda optimize etmek zor. Profilleme bunları sırayla çözer.
- **Log-olabilirlik:**

$$\ell(\underline{\beta}, \sigma^2, \underline{\delta}) = -\frac{n}{2} \log(\sigma^2) - \frac{1}{2} \sum_{j=1}^n \log(\lambda_j^2) - \frac{1}{2\sigma^2} \sum_{j=1}^n \lambda_j^{-2} (y_j - \underline{x}_j^T \underline{\beta})^2$$

- **Üç adımlı strateji:**

- **Adım 1:** δ sabit $\rightarrow \beta$ 'yı maksimize et $\rightarrow \hat{\underline{\beta}}(\delta)$.
- **Adım 2:** $\hat{\underline{\beta}}(\delta)$ 'yı yerine koy $\rightarrow \sigma^2$ 'yi maksimize et $\rightarrow \hat{\sigma}_{ML}^2(\delta)$.
- **Adım 3:** Sadece δ kalır $\rightarrow l_{ML}^*(\delta)$ 'yı maksimize et.
- **Sezgi:** 3 boyutlu bir arazide en yüksek noktayı aramak gibi. Her δ değeri için otomatik olarak en iyi β ve σ^2 'yi bul, meseleyi tek boyuta indir.

Bağımsızlık Varsayımını Kaldırmak — Korelasyonlu Hatalar (§15.6)

- **Yeni durum:** Aynı gruptaki gözlemler birbirine korelasyonlu olabilir.
- **Model:** N grup, grup i 'de n_i gözlem.

$$y_i = \mathbb{X}_i \underline{\beta} + \varepsilon_i, \quad \varepsilon_i \sim N_{n_i}(0, \mathcal{R}_i), \quad \mathcal{R}_i = \sigma^2 R_i$$

- R_i artık tam bir $n_i \times n_i$ matris — köşegen dışı elemanlar sıfır değil.
- **Özellikler:**

$$E[y_{ij}] = \mu_{ij} = z_{ij}^T \underline{\beta}, \quad V[y_i] = \sigma^2 R_i$$

- **MRI örneği:** n kişi, 8 farklı tarayıcı, rastgele atanmış. Aynı tarayıcıyla çekilen taramalar sistematik olarak benziyor $\Rightarrow$ korelasyonlu. Bu R_i ile modellenir.

Korelasyon Fonksiyonu — Korelasyonu Akıllıca Modellemek (§15.7)

- **Amaç:** Varyans Fonksiyonu'nun yaptığı gibi, korelasyonu da küçük bir parametre setiyle ifade etmek.
- **Korelasyon fonksiyonu:**

$$\text{Corr}(\varepsilon_{ij}, \varepsilon_{ij}^T) = h[d(t_{ij}, t_{ij}, \mathcal{Q})]$$

- $\mathcal{Q}$: bilinmeyen korelasyon parametreleri.
- d : mesafe fonksiyonu.
- h : $[-1, 1]$ aralığında, $h(0, \mathcal{Q}) = 1$.
- **Sezgi:** Yan yana iki evin fiyatı çok benzer; 10 km uzaktakilerin daha az. Korelasyon fonksiyonu “mesafe artar $\Rightarrow$ korelasyon azalır” fikrini matematikleştirir.
- **İki ana yapı:**
 - **Seri yapılar:** Zaman serisi / uzunlamasına veri. Örnek: otokorelasyon.
 - **Uzaysal yapılar:** Uzayda yayılmış veri. Örnek: semivaryogram.
- **Neden yardımcı olur:** R_i tam matris olsaydı $n_i(n_i - 1)/2$ parametre tahmin edilmesi gerekirdi. Korelasyon fonksiyonu bunu sadece $\mathcal{Q}$ 'ya indirir.

Rastgele Etkiler ve Tam LMM (§15.8)

- **Amaç:** Grup düzeyindeki farklılıkları sabit parametre olarak değil, *rastgele çekiliş* olarak modellemek.
- **Neden her gruba dummy değişken eklemek yetmez?**
 - 500 okul $\Rightarrow$ 500 ek katsayı $\Rightarrow$ model şişer.
 - Hiç görmediğimiz yeni okul için tahmin yapılamaz.
 - Az gözlemlili gruplarda (örn. 2 öğrenci) tahmin güvenilirmez.

- **Grup i için LMM:**

$$y_i = \underline{X}_i \underline{\beta} + Z_i \underline{b}_i + \varepsilon_i, \quad \underline{b}_i \sim N_q(\underline{0}, D), \quad \varepsilon_i \sim N_{n_i}(\underline{0}, R_i)$$

ve kritik koşul: $\underline{b}_i \perp \varepsilon_i$.

- **Tüm veri için model:**

$$y = \mathbb{X} \underline{\beta} + \mathbb{Z} \underline{b} + \underline{\varepsilon}, \quad \underline{b} \sim N(0, \sigma_b^2 D), \quad \underline{\varepsilon} \sim N(\underline{0}, \sigma_\varepsilon^2 R)$$

- **Her terimin anlamı:**

- $\mathbb{X} \underline{\beta}$: **Sabit etkiler** — tüm gruplar için ortak, *tahmin edilir*.
- $Z_i \underline{b}_i$: **Rastgele etkiler** — gruba özel sapma, $N_q(0, D)$ 'den çekilir, *öngörülür* (BLUP).
- ε_i : Grup içi bireysel hata.
- D : Rastgele etkilerin kovaryans matrisi (gruplar arası farklılığı ölçer).

- **Diyagram sezgisi:**

- Sadece sabit etkiler: tüm gruplar tek bir regresyon çizgisine zorlanır.
- Rastgele etkilerle: her grup kendi intercept kaymasını (b_i) alır, eğim (β) ortaktır.

- **Büzme / kısmi havuzlama sezgisi:**

- Okul A'da sadece 2 öğrenci $\Rightarrow$ LMM bu veriye tam güvenmez, tahmini genel ortalamaya doğru çeker (**shrinkage**).
- Okul B'de 500 öğrenci $\Rightarrow$ LMM veriye güvenir, tahmin ham veriye yakın kalır.
- Bu “kısmi havuzlama”: hiç havuzlama yapmamak (her gruba ayrı model) ile tam havuzlama (grupları yok saymak) arasında denge.

- **BLUP — En İyi Doğrusal Sapmasız Öngörü** (notlarda eksik, eklenen not):

$$\hat{\underline{b}}_i = D Z_i^T (\sigma^2 R_i + Z_i D Z_i^T)^{-1} (y_i - X_i \hat{\underline{\beta}})$$

Öngörülen rastgele etki, grup i 'nin artıklarının sabit etkilerden ne kadar saptığıyla orantılıdır.

Özet — Ne Yaptık, Ne Elde Ettik?

- Her bölüm klasik LM'den bir kısıtlayıcı varsayımı kaldırdı:

Bölüm	Kaldırılan varsayım	Araç	Kazanılan
§15.2	Hiçbiri (başlangıç)	OLS / ML / REML	$\hat{\beta}, \hat{\sigma}^2$
§15.3	Eşit varyans	—	Her gözlem için σ_j^2
§15.4	Eşit varyans (parametrik)	Varyans fonks. λ^2	Kompakt varyans modeli
§15.5	—	Profillenmiş olabilirlik	β, σ^2, δ sıralı tahmini
§15.6	Bağımsızlık	R_i matrisi	Grup içi korelasyon
§15.7	Bağımsızlık (parametrik)	Korelasyon fonks. h	Kompakt korelasyon modeli
§15.8	Hepsi birden	LMM: $y = X\beta + Zb + \varepsilon$	Grup etkisi rastgele çekiliş

- **“Neden LMM?” sorusunun son cevabı:** Gerçek dünya verisi kümelenmiş, korelasyonlu ve heterokedastiktir. LMM tüm bunları tek çatı altında ele alır, doğru belirsizlik tahminleri verir ve hiç görmediği yeni gruplara genelleme yapabilir — bunlar basit regresyonun asla yapamayacağı şeylerdir.

10 Exam Questions

Q1 — What is intended by heteroscedasticity?

- **Residuals do not have zero mean (FALSE)**
 - Bu heterokedastisite ile ilgili değil.
 - OLS’un ayrı bir varsayımı: hataların ortalaması sıfır olmalı.
 - Heterokedastisite bunu söylemez.
- **Residuals are serially correlated (FALSE)**
 - Bu §15.6–15.7’nin konusu: bağımsızlık varsayımının ihlali.
 - Heterokedastisite bu değil, tamamen ayrı bir sorun.
- **Residuals do not have equal variance (TRUE)**
 - Tam olarak bu. §15.3’te gördük: klasik LM’de tüm gözlemler için

$$Var[\varepsilon_j] = \sigma^2$$

olması gerekiyordu. Heterokedastisite bu eşitliğin bozulması demek:

$$Var[\varepsilon_j] = \sigma_j^2 \quad (\text{her gözlem için farklı})$$

- **Fabrika örneği:** Sabah vardiyası tutarlı (küçük σ^2), gece vardiyası değişken (büyük σ^2). Tek bir σ^2 her ikisini de yanlış temsil eder.
- **Residuals are not normally distributed (FALSE)**
 - Normallik ayrı bir varsayım.
 - Heterokedastisite olmadan da normallik bozulabilir, ya da tam tersi.
 - İkisi birbirinden tamamen bağımsızdır.